

# 深層学習を用いたアンサンブルモデルによる株主価値推定モデルの提案

## Model for Evaluation of Stock Values by Ensemble Model Using Deep Learning

田村 浩一郎  
Koichiro Tamura

東京大学 工学系研究科技術経営戦略学専攻  
Department of Technology Management for Innovation, School of Engineering University of Tokyo  
koichiro11@weblab.t.u.tokyo.ac.jp, <http://koichirotamura.com/>

上野山 勝也  
Katsuya Uenoyama

(同 上)  
uenoyama@weblab.t.u-tokyo.ac.jp

飯塚 修平  
Shuhei Iitsuka

(同 上)  
iitsuka@weblab.t.u-tokyo.ac.jp

松尾 豊  
Yutaka Matsuo

(同 上)  
matsuo@weblab.t.u-tokyo.ac.jp

**keywords:** stock value, deep learning, ensemble, enterprise value evaluation, summary of financial statements of company

### Summary

In order to encourage individual asset flow into the Japanese market through long-term investments, it is important to evaluate stock values of companies because stock prices of companies are determined not only by internal values, which are independent of other companies, but also by market fundamentalism. However, there are few studies conducted in this area in the machine learning community, while there are many studies about prediction of stock price trends. These studies use a single factor approach (such as textual or numerical) and focus on internal values only. We propose a model where we combine two major financial approaches to evaluate stock values: technical analysis and fundamental analysis. The technical analysis is conducted using Long-Short Term Memory and technical indexes as input data. On the other hand, the fundamental analysis is conducted transversely and relatively by creating a program which can retrieve data on financial statements of all listed companies in Japan and put them into a database. From the experiments, compared to single technical analysis proposed model's accuracy in classification was 11.92% more accurate and the relative error of regression was 3.77% smaller on average. In addition, compared to single factor approaches the accuracy in classification was 6.16% more accurate and the relative error of regression was 3.22% smaller on average. The proposed model has the potential to be combined with other prediction methods, such as textual approaches or even traditional financial approaches, which would improve accuracy and increase practicality of this model.

### 1. はじめに

株価は多様な因子が相互に影響しあう複雑な現象の結果であり、予測の可能性やモデリングの手法に関して、多様な分野で学問的関心を集めてきた。株式分析の手法は、ファンダメンタル分析 [Lev 93, Dornbusch 76] とテクニカル分析 [Frankel 85, Frankel 90, Brock 92] に大分され、[Murphy 86] では、「テクニカル分析は市場の動きの研究に専念するのに対し、ファンダメンタル分析は価格を上下させたり、あるいは同じレベルにとどめさせたりする原因となる、需要と供給関係に焦点をあてる」としている。

株式市場分析の研究にも機械学習の手法が用いられている。大規模なデータからパターンを学習することができる機械学習は、テクニカル分析に基づいた短期的なトレーディングのためのトレンド予測に用いられることが多い。

しかし、健全な市場を形成し、より多くの投資を促進するという観点からすれば、中長期的な投資が重要な役割を担っている。1600兆円を超える日本の個人資産をより多く市場に流入させるためには、公正でかつ中長期的な投資を推進することが必要である。実際に、[川崎 16]によれば、金融庁は「早耳情報に基づく短期的なトレーディングではなく、中長期的な視点に立って投資を行うという投資家の意識変革を促す」という目的で、企業が未公表の重要情報を選択的に伝えることを禁じる「フェアディスクロージャー（FD）規制」の導入を進めている。

中長期的な投資を行うためには、企業の財務諸表、経営状態、競争優位性などから、市場における価値に着目するファンダメンタル分析も重要である。なぜなら、上場企業の株価は、中長期的には市場原理に基づき、市場における企業の価値の評価によって決定しているからで

ある。例えば、類似する A 社と B 社があるとして、A 社がより良い業績を発表した場合、B 社の投資価値そのものが下がったわけではないのに、A 社の価値が B 社よりも高いとして、B 社の株が売られ A 社の株が買われることが考えられる。また、C 社の業績自体は向上している場合でも、市場が期待していた水準ではないと認知された場合、実際の企業の価値が、期待されていた企業の価値よりも低いために C 社の株価が下がるということもある。よって、中長期的な投資においては、例え最終的な推定対象が株価であっても、株価そのもののトレンドの動きを直接推定するテクニカル分析だけでなく、市場における評価価値である株主価値に着目したファンダメンタル分析が重要である。

しかし、トレンドを推定するようなテクニカル分析に加えて、株主価値を推定するファンダメンタル分析を組み合わせた機械学習による手法は筆者の知る限り存在していない。確かに、テクニカル指標だけでなくファンダメンタル指標を扱う機械学習モデルは提案されているが、それはファンダメンタル指標を予測対象企業に帰属する入力変数として用いているにすぎず、需要と供給の関係を考慮し、株式市場における価値に着目するファンダメンタル分析ではない。

機械学習の分野において、株主価値に着目したファンダメンタル分析を行うモデルが提案されていない一方で、経済学的な分野では、一度株主価値を推定するファンダメンタル分析を用いた後に、株主価値を発行株式数で割ることで、株価を推定することが一般的である。

証券アナリストは、インタビューを通して対象企業や業界を分析することで、表層的な財務情報だけでなく、詳細な商品や事業内容などの解像度の高い情報を元に、ファンダメンタル分析に基づいた経済学的な企業価値推定モデル（以下経済学的ファンダメンタル分析と呼ぶ）を用いて企業価値推定や投資価値推定を行っている。しかし、先述した F D 規制によって、そうした解像度の高い情報の入手が難しくなり、人間による経済学的ファンダメンタル分析では予測が困難になってしまった [川崎 16]。

機械学習が飛躍的な発展を遂げ、企業情報を取得することが可能になった今、市場における株主価値を考慮するファンダメンタル分析の機械学習モデルを用いることの価値は相対的に高まっており、今後も高まり続けると考えることができる。

そこで本研究では、既存のテクニカル分析の機械学習手法を用いるだけでなく、市場における価値に着目したファンダメンタル分析を機械学習を用いて行い、アンサンブル学習を用いた複合的な株主価値推定モデルを提案する。市場における株主価値を考慮するファンダメンタル分析の機械学習を実現するために、XBRL(eXtensible Business Reporting Language) ファイルを利用することによって、全ての上場企業の決算短信をはじめとした企業情報を取得するシステムを構築し、企業情報を一元化

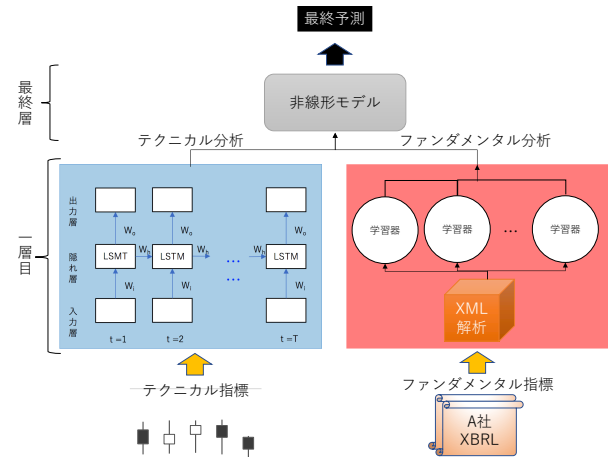


図 1 提案モデル概要

する。そして、株価といった企業ごとにスケールが違う値を株主価値に標準化し、推定対象とする。提案モデルの概要を図 1 に示す。

本研究では、2013 年第 1 四半期から 2014 年第 4 四半期の 8 期において、日本の上場企業約 3000 企業、5 年間のデータを用いて学習を行い、分類・回帰予測の両方について、提案モデルを評価した。検証の結果、

- 経済学的ファンダメンタル分析に対して、提案モデルのファンダメンタル分析がより正確な推定を行えること
- テクニカル分析に加えてファンダメンタル分析を組み合わせた提案モデルが、テクニカル分析、さらにはファンダメンタル分析の各単体手法よりも高い精度の株主価値推定を行えること
- XGBoost [Chen 16] の決定木の情報利得を利用した重要度分析により、予測対象が長期化するほど、ファンダメンタル分析が有効であること

を示した。

本論文は、2 章で株式評価、株価予測の関連研究を俯瞰し、本研究の学術的見地を明確にする。3 章で提案モデルについて説明し、4 章で提案モデルの検証実験について説明し、結果を述べる。5 章では、検証実験結果に基づき提案モデルの有用性や今後の展望について考察する。最後に、6 章でまとめを述べる。

## 2. 関連研究

1 章で述べたように、株式市場分析に機械学習を用いることを提案している先行研究は数多くある。その大半はテクニカル分析 [Frankel 85, Frankel 90, Brock 92] に基づき指数のトレンド予測を行う研究である。Time Delay Neural Networks を用いて株価のトレンド予測をおこなった研究 [Kreesuradej 94], Recurrent Neural Networks を用いて翌日の株価指数を予測する研究 [Saad 96] などが 2000 年以前に行われている。2000 年以後、Neu-

ral Networks と他の予測モデルを組み合わせたハイブリッド型のモデル [Kim 07] が提案され始めた。また、サポートベクターマシンを利用した株価予測 [Cao 01] が精度をあげたことで話題を呼んだ。その後、遺伝子アルゴリズムにより特徴量選択を行い、サポートベクターマシンを利用して株価を予測するハイブリッド型のモデル [Choudhry 08] が提唱され、精度向上を実現した。最近では、深層学習の手法の一つである Recurrent Neural Networks の拡張として提唱された Long Short-Term Memory [Hochreiter 97](以下 LSTM と呼ぶ)を用いて株価指数予測をする研究 [Chen 15] が行われている。

一方で、ファンダメンタルな因子に着目したモデル [Lam 04, Choudhry 08] は数少ない。[Lam 04] はファンダメンタル分析を試みているが、予測対象が株主資本利益率であり、本研究とは目的が異なるうえに、株主資本利益率は財務情報から計算される値であるため、株価をはじめとするテクニカル指標がファンダメンタル指標の説明因子になり得ないと言った点が問題としてあげられる。[Choudhry 08] はファンダメンタル指標を入力変数としているが、予測対象企業に帰属する入力変数として用いているにすぎず、株式市場における価値に着目したファンダメンタル分析を行ってはいない。発行株式数が企業ごとに異なることから、株式市場における価値の企業間比較を行うためには、

$$\text{株主価値} = \text{株価} \times \text{発行株式数}$$

を用いる必要がある。

企業情報を一元化し、推定対象を株主価値に標準化することで、株式市場における価値の比較を試みたファンダメンタル分析を機械学習により行っている研究はなく、そうした分析手法を取り入れた複合的なモデルは筆者の知る限り提案されていない。

### 3. 提案手法

ファンダメンタル分析が中長期的な投資の際に重要であることはすでに 1 章で述べたが、人間による経済学的ファンダメンタル分析の問題として

- (1) 人間が処理できるデータサンプル数の限界
- (2) 人間の認知限界
- (3) 複数の手法の組み合わせ方が体系立てられていないこと

があると洞察できる。「人間が処理できるデータサンプル数の限界」及び「人間の認知限界」は、全企業の時系列データを用いて教師あり機械学習を行うことで、帰納的にパターンを見つけ出し、重要な素性を抽出することで解決できると期待する。XML の規格に従って企業ごとの情報が記載されている XBRL ファイルが、ウェブ上に存在している。複数の企業の XBRL ファイルを取得し解析することにより、複数の企業情報を一元化することが

可能である。複数の企業情報を一元化し、推定対象を株主価値にすることによって、株式市場における相対的な価値を考慮したようなファンダメンタル分析が、機械学習によって実現できる。

3 つ目の「複数の手法の組み合わせ方が体系立てられていない」という問題に関しては、複数の分析手法を組み合わせるアンサンブル学習を用いて解決できると期待できる。

また、1 章で述べた証券アナリストの行う企業価値推定や投資価値推定は、将来株価の上下の分類と、株価の適正価格や目標価格の回帰予測の 2 種類ある。よって本研究も、分類モデルと回帰モデルの 2 つを提案する。

#### 3.1 概要

提案する「深層学習を用いたアンサンブルモデルによる株主価値推定モデル」の概要は図 1 に示した通り。既存の機械学習手法と同様に、テクニカル指標を入力素性としたテクニカル分析の機械学習モデル (以下「提案モデルのテクニカル分析」と呼ぶ) に加えて、XBRL ファイルから取得したファンダメンタル指標を用いて、市場における価値に着目したファンダメンタル分析の機械学習モデル (以下「提案モデルのファンダメンタル分析」と呼ぶ) がある。提案モデルは、提案モデルのテクニカル分析と提案モデルのファンダメンタル分析のモデル (以下ではまとめて「提案モデルの 1 層目」と呼ぶ) の予測結果を入力素性とするアンサンブル学習の非線形モデル (以下では「提案モデルの最終層」と呼ぶ) によって構成される。提案モデルの最終層は、最終予測が分類問題である場合は分類モデル、回帰問題である場合は回帰モデルを採用する。

複数の分析による予測を入力データとする非線形学習器を用いたアンサンブルモデルによって、異なる分析手法を融合し、より予測性能が高いモデルを構築することを試みる本研究では、提案モデルの最終層に XGBoost を使用する。XGBoost を使用する理由は、

- 非線形モデルを使用することによって、分析間における非線形関係を表現できる
- 決定木を用いたアルゴリズムであるため、特徴量の重要度を情報利得から計算することができ、最終的にどの分析がどれだけ予測値に寄与しているかということが指標化できる

といったことがある。情報利得は、以下のように計算される。

$$IG(D_p, f) = I(D_p) - \frac{N_{left}}{N_p} I(D_{left}) - \frac{N_{right}}{N_p} I(D_{right})$$

ただし、 $f$  は分割を行う特徴量であり、 $I$  は不純度を表す関数、 $D_p$  は親のデータセット、 $D_{left}$  及び  $D_{right}$  は子ノードのデータセットである。

### 3.2 企業情報の取得

企業のテクニカル指標は、多くの場合データベース化されており、Web から簡単に取得できる。一方で、企業のファンダメンタル情報は一般的に一元化されて公開されておらず、一元的にデータベース化するシステムを構築する必要がある。

XBRL ファイルとは、財務諸表などのビジネスレポートを XML の規格をベースとして電子化されたものである。本研究では、XBRL ファイルを利用し、すべての企業のビジネスレポートを一元的にデータベース化するシステムを構築した。

システム概要は以下の通り。

- (1) 有報キャッチャー AtomAPI<sup>\*1</sup> を利用して過去の企業の XBRL ファイルをダウンロードする
- (2) 金融庁が公開しているタクソノミ要素リスト<sup>\*2</sup>を元に、各要素の名前空間を作成する
- (3) 作成した名前空間を元に、XML ファイルを解析し、データベースにデータを挿入する

なお、本研究で提案するモデルは、タクソノミ要素リストで定義されている要素のうち、決算短信、損益決算書、貸借対照表、キャッシュフロー表に含まれるものをすべてを入力素性の対象とし、テクニカル指標はトムソン・ロイター DataStream のものを用いた。

### 3.3 テクニカル分析のモデル

テクニカル分析においては、回帰モデルの場合、将来株主価値でなく一旦株価変化率を求める。企業ごとの株主価値は株価に比例しているため、対象企業の時系列データを学習に用いるテクニカル分析によって株価変化率を推定したのち、

$$\text{推定株主価値} = \text{現在株主価値} \times \text{推定株価変化率}$$

として株主価値を推定することができる。

今回、予測対象企業に対する市場の時系列相関を反映させるため、テクニカル指標をすべての企業、マーケット指数に対して計算し、すべての企業、マーケット指数のデータを合算したものを、企業  $k$  の時刻  $t$  における入力データ

$$\mathbf{X}_k^t = (\mathbf{x}_{c1}, \mathbf{x}_{c2}, \mathbf{x}_{c3}, \dots, \mathbf{x}_{cN}, \mathbf{x}_{i1}, \mathbf{x}_{i2}, \dots, \mathbf{x}_{iM})$$

とする。 $\mathbf{x}_{cj}$  は時刻  $t$  における  $j$  ( $j = 1, 2, 3, \dots, N$ ) 社のテクニカル指標ベクトル (始値, 高値, 安値, 終値, 出来高, 及び付録 A に記述するテクニカル指標からなるベクトル),  $\mathbf{x}_{il}$  はマーケット指数  $l$  ( $l = 1, 2, 3, \dots, M$ ) のテクニカル指標ベクトルである。また、企業  $k$  の時刻  $t$  における正解データ  $y_k^t$  は予測対象企業  $k$  の株価変化率とする。

テクニカル分析では長い系列長の時系列データを扱うため、今回、長期的な時系列データを扱うことが可能である LSTM を学習器として用いる。また、再帰的ニューラルネットワークの一つである LSTM を使用することによって、学習の過程で過去の時系列相関を獲得できることが期待される。LSTM の再帰的な学習の過程

$$\mathbf{z}^t = \mathbf{f}(\mathbf{W}_{in}\mathbf{X}^t + \mathbf{W}_z\mathbf{z}^{t-1})$$

( $\mathbf{f}$  は活性化関数,  $\mathbf{W}_{in}$  は入力層から隠れ層の重み行列,  $\mathbf{W}$  は隠れ層の重み行列,  $\mathbf{X}^t$  は時刻  $t$  における入力データ,  $\mathbf{z}^t$  は時刻  $t$  における隠れ層の出力である) によって獲得された重みは、「対象企業の株価に過去の各情報がどれだけの影響を与えるか」という指標と捉えることができる。

一方、経済学の分野では、現代ポートフォリオ理論 [Elton 09] では株価の相関を表す値として

$$\beta = \frac{\frac{1}{n} \sum_{t=1}^T (\Delta A_t - \mu_{\Delta A})(\Delta Index_t - \mu_{\Delta Index})}{\sigma_{\Delta Index}}$$

が用いられているが ( $\Delta A_t, \Delta Index_t$  は時点  $t$  における企業  $A$  の株価  $A$  及び指数株価  $index$  の変化率,  $\mu_{\Delta A}, \mu_{\Delta Index}$  は  $t = 1 \sim T$  における平均値,  $\sigma_{\Delta Index}$  は  $t = 1 \sim T$  における標準偏差である), この数式モデルは時系列性を無視した単純な変化率の相関を導き出しているに過ぎない。再帰的に時系列を扱う LSTM を用いることで企業間の時系列の影響を学習し、より優れた予測を行えることが期待される。

### 3.4 ファンダメンタル分析のモデル

2 章で述べた通り、既存の株価予測研究のモデルの多くはファンダメンタル分析を取り入れたモデルではなかった。今回、全企業のファンダメンタル情報を所得し一元化したこと、及び予測対象を株主価値にすることによって、企業の市場における価値を考慮することが可能になる。

構築した企業情報をデータベース化するシステムによって、XBRL ファイルを取得、解析することで企業活動情報をデータベース化する。そして、取得したデータセットに対して XGBoost を用いて特徴量ごとの重要度を計算し、それに基づいて特徴量選択を行う。特徴量選択によって次元削減された特徴量を用いて複数の学習器 (ロジスティック回帰, 決定木, 非線形サポートベクターマシン, バギング, ランダムフォレスト, Extra Trees, Adaboost, Gradient boosting, XGBoost, 多層パーセプトロン) を学習させる。各学習器の予測を入力データとして, XGBoost を学習・予測をするアンサンブルモデルを構築し, より予測性能が高いファンダメンタル分析のモデルの構築を試みる。

\*1 有報キャッチャー AtomAPI: <http://resource.ufocatch.com/>

\*2 タクソノミ要素リスト: <http://www.fsa.go.jp/search/20160314.html>

## 4. 実験

### 4.1 実験目的

提案モデルに関して検証実験を行うことによって、

- 提案モデルのファンダメンタル分析が経済学的ファンダメンタル分析より高い精度の株主価値推定を行えること
- テクニカル分析に加えてファンダメンタル分析を組み合わせた提案モデルが、テクニカル分析、さらにはファンダメンタル分析の各単体手法よりも高い精度の株主価値推定を行えること

を示す。

### 4.2 実験する手法

本研究では、以下の手法の検証実験を行う。

手法 **EF** 既存の経済学的なファンダメンタル分析

手法 **MT** 提案モデルのテクニカル分析のモデル

手法 **MF** 提案モデルのファンダメンタル分析のモデル

手法 **MTMF** テクニカル分析とファンダメンタル分析をアンサンブルした提案モデル

#### §1 EF

経済学的ファンダメンタル分析は、アセットアプローチ、マーケットアプローチ、インカムアプローチ<sup>\*3</sup>の3つがある。

アセットアプローチでは、簿価純資産法を用いて検証する。今回は簡単のため、純資産額 = 推定株主価値とする。

マーケットアプローチでは市場株価法を用いる。今回の検証実験においては、直近営業日 60 日間の終値平均を用いる。

インカムアプローチでは、Discounted Cash Flow 法 (以下 DCF 法と呼ぶ) を用いる。DCF 法は、将来キャッシュフローをリスク等を勘案した割引率によって現在価値に割り引いた金額を評価額とする評価方法で、ファイナンス理論に最も忠実であり実務的に様々な場面で利用されているものである。今回の検証実験では、四半期ごとのフリーキャッシュフロー (以下 FCF と呼ぶ) に対して割引率を適用する。

DCF 法の具体的な方法は以下の通り。

- (1) Weighted Average Cost of Capital (負債の資本コストと株式の資本コストを負債比率と株式比率で加重平均したもの、以下 WACC と呼ぶ) を CAPM [Sharpe 64] に基づいて計算
- (2) FCF の計算

$$FCF = \text{営業キャッシュフロー} - \text{投資キャッシュフロー}$$

- (3) FCF を WACC を用いて現在価値に割りもどし、定額モデルによって総和を「企業価値」とする

$$\text{企業価値} = \lim_{n \rightarrow \infty} \sum_{k=1}^n FCF \times \left( \frac{1}{1+WACC} \right)^k$$

- (4) 「企業価値」に非事業用資産を足したのち、有利子負債を差し引いたものを株主価値とする

$$\text{株主価値} = \text{企業価値} + \text{非事業用資産} - \text{有利子負債}$$

今回の検証実験において、近年のマイナス金利といった特殊な市場状態を考慮し、安定した予測を行うために  $R_d$  (負債コスト) 及び  $R_m$  (市場期待収益率) に対して、過去の数値の範囲内でパラメタチューニングを行い、仮想的に、 $R_d = 0.05$ ,  $R_m = 0.1$  とした。将来の FCF の予測が困難であることを仮想的に解決するために、本来は知ることのできない検証時点から将来 4 期分 FCF を既知とし、将来 5 期以降の FCF は検証時点から将来 4 期分 FCF の平均が継続すると仮定して、DCF 法を用いる。

経済学的ファンダメンタル分析の最終的な予測は、分類予測の場合、現在の株主価値との比較において単純平均が上であれば上昇予測、下であれば下降予測とする。回帰予測の場合、特にインカム分析の DCF 法では、無限等比数列を計算するため、割引率の計算や将来 FCF の予測値によって大きく値が変動してしまうことを懸念し、3 つの手法の単純平均を予測値とするが、値が現在値から ±100% 以上離れている場合は、予測値を ±100% に制限したものとする。

#### §2 MT

検証の対象となる企業は、基本的に検証期間に上場している日本企業約 3000 企業である。しかし、計算時間の制約から、全期間において全企業の検証をすることは難しいことを考慮し、MT においては、企業ごとにモデルを学習・構築するのではなく、日経平均株価を構成する 225 銘柄 (2016 年 4 月時点) の検証期間から前 5 年間分の週足のデータを学習用データとした代替モデルを構築し、代替モデルを各企業に適用することで評価を行う。そして今回、週足データをデータセットの 1 タイムステップとし、LSTM の入力データを 30 ステップとする。

具体的に、データセットは、test dataset には検証時点から前 30 ステップのデータを用いる。学習用データは、test dataset に用いる 30 週間分のデータの直前から前 5 年間分遡ったデータを用いる。学習用データのうち前半 95% を train dataset、後半 5% を validation dataset に分割し学習を行う。なおデータセットを作成する時、予測を行うモデルを構築する際に未来情報を与えてはいけことに気をつける。

#### §3 MF

MF を以下の手順で作成する。

**step1** 予測対象期間の 1 期前から前 5 年間分 (20 期) の

<sup>\*3</sup> インターナレッジ・パートナーズ: [http://www.ikpi.co.jp/knowledge/valuation/valuation\\_file030.html](http://www.ikpi.co.jp/knowledge/valuation/valuation_file030.html)

train dataset を用意する. train dataset をさらにランダムサンプリングによって, 1 層目の学習器の学習及びハイパーパラメタの最適化に用いる train first dataset と, 2 層目の学習器 (XGBoost) の学習及びハイパーパラメタの最適化に用いる train second dataset に 2 等分割する

**step2** train first dataset を用いてハイパーパラメタの調整を行う

**step3** train first dataset と調整したハイパーパラメタを用いて 1 層目の学習器層目の学習器 (ロジスティック回帰, 決定木, 非線形サポートベクターマシン, バギング, ランダムフォレスト, Extra Trees, Adaboost, Gradient boosting, XGBoost, 多層パーセプトロン) を作成する

**step4** 作成した一層目の学習器を用いて, train second dataset による予測をそれぞれの学習器ごとに出力する. これらの出力を予測データセットとする

**step5** 出力した予測データセットを用いて 2 層目の XGBoost のハイパーパラメタの調整を行う

**step6** 調整したハイパーパラメタと予測データセットを用いて 2 層目の XGBoost を学習させる

#### §4 MTMF

MT と, MF を用いて, MTMF の最終層の XGBoost のパラメタ最適化及び学習を行う.

**step1** 検証期間における, 2013 年第 1 四半期から 2014 年第 4 四半期の MT 及び MF の分類, 回帰予測をそれぞれ行い, 3 章で述べたように入力用の予測データセットを作成する

**step2** 予測データセットのうち, 予測対象期間のものを test dataset, 残りを train dataset とする

train dataset をシャッフルし, データセットを 5 分割する. ハイパーパラメタサーチを行い, 最終層の XGBoost のハイパーパラメタを最適化する

**step3** 最適化されたハイパーパラメタと test dataset を用いて最終層の XGBoost を学習する

#### 4.3 検証実験の設定

**評価方法** 検証実験としての公平性を保つために, 検証する期間は, 2013 年第 1 四半期から 2014 年第 4 四半期までの 8 四半期とする. また, ファンダメンタル分析とテクニカル分析の優位性が予測期間の長さによって異なる可能性を考慮し, 異なる予測期間に対して検証を行う. 証券アナリストが, 3ヶ月後, 1 年後の投資価値評価を行うことは一般的であり, 特に, 決算短信が出てから次の決算短信が出るまで約 60 営業日 (約 3ヶ月) あることを踏まえて, 予測対象期間を 60 営業日, 240 営業日 (約 1 年) の 2 つについて検証する.

ファンダメンタル分析の株主価値の推定に対する寄与度を正確に評価し, できるだけ市場のランダム

要素を排除したい. そこで, 各企業の決算短信が発表された翌日からの, 将来の平均の株主価値を推定し, 分類予測の場合, 株主価値が予測時点から上昇するか下降するかの正解率によって, 回帰予測の場合, 対象企業における株主価値の平均誤差率によって評価する.

**データセット** 企業ごとのテクニカル指標に関して, 始値, 高値, 安値, 終値, 出来高はトムソン・ロイター DataStream<sup>\*4</sup>のデータを用いる. さらに付録 A に記述するテクニカル指標を計算して追加する. MT においては, 日経平均株価を構成する 225 銘柄 (2016 年 4 月時点) の検証時点から前 5 年間分の正規化された週足のデータ, 約 56000 データサンプルを用いて学習する.

企業ごとのファンダメンタル指標は, XBRL ファイルを解析することで得られた決算短信, 損益決算書, 貸借対照表, キャッシュフロー表のデータを用いる. さらに, Yahoo! ファイナンス<sup>\*5</sup>から, 業種分類, 設立年月日, 市場名, 上場年月日, 従業員数 (単独), 従業員数 (連結), 単元株数, 平均年齢, 平均年収 といった企業情報を参照, 特徴量として追加する. なお, 上場年月日, 設立記念日などは現在時刻との差分を計算することによって経過時間を割り出し, 特徴量として追加する. そうして, 取得したデータを用いて付録 B に記述するファンダメンタル指標を計算・追加する. 本検証実験では, 前期のデータを参照する欠損値補完, 外れ値の置換, 標準化をおこなう. また, 取得したデータのうち, 損益決算書, キャッシュフロー表, 及び決算短信の一部に含まれるデータは, 四半期ごとの独立したデータでなく, 年度内の累計データである. そこで, 四半期ごとのデータを並列して対等に扱うため, 累計値から四半期ごとの値を逆算する形で求め, 修正する. MF では, そうして作成される約 3000 企業の 5 年間分の四半期データ, 約 60000 データサンプルを学習に用いる.

**ハイパーパラメタの取り扱い方** 本研究では, ハイパーオプト [Bergstra 13] を用いてハイパーパラメタサーチを行なう. なお, MT における LSTM は計算コストが高いため, ハイパーオプトは行わず, 隠れ層のノード:200, ドロップアウト:0.15, 出力層の活性化関数:[分類問題:softmax, 回帰問題:linear], 学習率:0.00001, 最適化法:RMSprop [Tieleman 12], 損失関数:[分類問題:categorical cross entropy, 回帰問題: mean squared error] とハイパーパラメタや最適化法を設定した.

<sup>\*4</sup> <http://www.datastream.jp/>

<sup>\*5</sup> <http://finance.yahoo.co.jp/>

表 1 検証 5:分類予測における正解率の比較 (%)

検証期間	予測対象	EF	MT	MF	MTMF
2013Q1	60 日	50.46	48.35	53.02	<b>58.43</b>
	240 日	46.57	38.30	69.63	<b>72.76</b>
2013Q2	60 日	45.51	55.72	59.65	<b>62.82</b>
	240 日	54.43	63.57	67.92	<b>71.75</b>
2013Q3	60 日	<b>56.43</b>	54.84	47.80	47.80
	240 日	52.37	50.17	68.96	<b>76.36</b>
2013Q4	60 日	42.92	<b>73.13</b>	63.54	51.84
	240 日	60.58	61.55	74.70	<b>78.50</b>
2014Q1	60 日	52.23	<b>57.11</b>	55.95	56.40
	240 日	53.88	48.70	<b>70.59</b>	69.90
2014Q2	60 日	40.51	35.60	<b>64.66</b>	60.83
	240 日	53.04	59.63	<b>74.21</b>	73.59
2014Q3	60 日	34.97	39.95	<b>67.88</b>	62.49
	240 日	52.61	54.54	65.44	<b>66.15</b>
2014Q4	60 日	52.28	45.35	<b>59.56</b>	59.32
	240 日	54.23	46.05	53.35	<b>54.37</b>

#### 4.4 実験結果

検証実験による結果を表 1, 表 2 に示す。

表 1, 表 2 は, 検証期間が 2013 年第 1 四半期から 2014 年第 4 四半期までの 8 四半期における, 推定対象を営業 60 日平均の株主価値及び営業 240 日平均の株主価値とした場合のそれぞれの評価結果であり, 表 1 は各モデルの株主価値の上下予測の正解率, 表 2 は株主価値の平均誤差率を表している。表 1 分類予測における正解率の比較において, EF と MF の正解率の評価結果を比較すると, 16 検証パターン中 14 パターンで MF の正解率が優れている。同様に, 表 2 回帰予測における平均誤差率の比較

表 2 検証 5:回帰予測における平均誤差率の比較 (%)

検証期間	予測対象	EF	MT	MF	MTMF
2013Q1	60 日	29.96	12.44	14.52	<b>10.25</b>
	240 日	32.39	38.8	19.31	<b>18.44</b>
2013Q2	60 日	30.32	11.54	11.21	<b>8.14</b>
	240 日	31.65	20.58	15.25	<b>14.73</b>
2013Q3	60 日	26.92	<b>9.1</b>	25.55	10.09
	240 日	30.3	20.91	22.5	<b>17.03</b>
2013Q4	60 日	28.5	12.63	11.84	<b>9.06</b>
	240 日	29.54	25.7	16	<b>14.77</b>
2014Q1	60 日	28.7	8.24	9.64	<b>8.23</b>
	240 日	29.16	16.83	15.36	<b>13.71</b>
2014Q2	60 日	28.83	7.9	8.73	<b>7.46</b>
	240 日	27.8	15.64	13.25	<b>12.76</b>
2014Q3	60 日	32.53	10.31	9.07	<b>7.55</b>
	240 日	29.18	14.11	13.48	<b>12.86</b>
2014Q4	60 日	28.06	8.36	8.55	<b>7.59</b>
	240 日	28.46	<b>14.88</b>	16.32	15.02

において, 全ての検証パターンで MF の平均誤差率が優れている。

MT と MTMF を比較すると, 分類問題では 16 検証パターンで 13 パターンにおいて MT よりも MTMF が高い正解率を示していて, 回帰問題では 16 検証パターン中 14 パターンで MT よりも MTMF が優れた平均誤差率を示している。MT の正解率平均は 52.04%であるのに対し, MTMF の正解率平均は 63.96%であり, 11.92 ポイント優れている。MT の誤差率平均は 15.50%であるのに対し, MTMF の誤差率平均は 11.73%であり, 3.77 ポイント優れている。

MT と MF の双方と, MTMF を比較すると, 分類問題では 16 検証パターン中 8 パターンにおいて MT 及び MF よりも MTMF が高い正解率を示していて, 回帰問題では 16 検証パターン中 14 パターンで MT 及び MF よりも MTMF が優れた平均誤差率を示している。特に, 全検証パターンの平均を取ると, 分類予測の場合, 提案モデルを構成する各分析の正解率平均が 57.79%であるのに対し, それらをアンサンブルした提案モデルは 63.96%であり, 6.16 ポイント優れている。回帰予測の場合, 提案モデルを構成する各分析の平均が 14.95%であるのに対し, それらをアンサンブルした提案モデルは 11.73%であり, 3.22 ポイント優れている。

表 3 は, MF の検証過程で, XGBoost に基づいて特徴量ごとに情報利得の平均を計算し, 順位付けを行ったものである。推定時点での株主価値に直接比例する EV(Enterprise Value) や株価, 株主発行数が上位にきているだけでなく, PER(株価収益率)や PBR(株価純資産倍率)といった一般的なファンダメンタル指標も上位にきている。また, 従業員数や法人税等の支払額など, 直接株主資本に関連しないような項目も重要な特徴量として抽出されている。このように, MF は, ファンダメンタル指標から株主価値推定に重要な特徴量を抽出していることがわかる。

また, ファンダメンタル分析の最終的な予測における重要度(最終的な推定結果に対する寄与度)が全体に占める割合を図 2, 図 3 に示す。図 2, 図 3 は, 分類予測及び回帰予測において, 営業 60 日間平均の予測に対して営業 240 日間平均の予測の方がよりファンダメンタル分析の寄与度が有意に大きいことを示している。

## 5. 考察

実験で行った EF と MF の評価結果から, 経済学的なファンダメンタル分析と比較して, 提案モデルのファンダメンタル分析がより正確な株主価値推定を行えることがわかった。機械学習によって, 約 60000 サンプルのデータセットから帰納的な推定を行ったこと, そして表 3 のように重要な特徴量を 1000 項目ほどの企業情報の特徴量から抽出することによって, 人間の処理できるデータサ



表 3 2014 年第 4 四半期・営業 240 日平均の回帰予測におけるファンダメンタル指標の重要度ランキング (上位 10 項目)

順位	項目
1	EV
2	連結総従業員数
3	株価
4	株式発行数
5	PBR
6	PER
7	従業員数
8	配当利回り
9	法人税等の支払額
10	配当金の支払額

ンプル数の限界及び人間の認知限界の問題を解消し、より精度の高い株主価値推定が行えたと考えられる。

また、表 3 において、キャッシュフローに関連する項目が株主価値推定における重要な特徴量の上位にきていないことは興味深い。なぜなら、代表的な経済学的なファンダメンタル分析である DCF 法は、企業価値は将来生み出すキャッシュフローの割引現在価値によって決定するというファイナンス理論に基づいており、キャッシュフローに関連する項目が重要な特徴量として抽出されることが期待できたからである。ファイナンス理論と、実際に機械学習を用いて解析的に得られた結果が必ずしも一致しないと考えられる。

法人税等の支払額が重要な特徴量として抽出されていることにも注目すべきである。ファイナンスの理論で企業価値の推定の際にキャッシュフローに着目するのは、期間業績の適正化から財務会計の基準が企業ごとに異なり、客観的な比較が正確に行えないという理由がある。法人税の計算は法人税等の規定によって会計計算とは切り離されて別個に行われるものであり、法人税は利益に対して計算されるため、法人税等の支払額は実際の利益を比較可能な形で反映していると考察できる。このように、提案モデルによって既存の経済学的なファンダメンタル分析では捉えていなかった項目や指標を抽出し、既存手法では着目していなかった指標や観点から企業価値を評価することが可能になると期待できる。

MT と MTMF の比較から、テクニカル分析に加えてファンダメンタル分析を組み合わせた提案モデルが、テクニカル分析に対して優れた推定を行えることがわかる。また、図 2、図 3 の結果から、予測対象が長期化するほど、ファンダメンタル分析が有効であると推論できる。よって今回のような中長期的な投資の際に、テクニカル分析に加えて、長期的である場合により重要度が高まる株主価値に着目したファンダメンタル分析を行うことによって、より優れた推定を行えると考察する。

さらに、MT と MF、MTMF の評価結果の比較から、ファンダメンタル分析とテクニカル分析を融合させた提

案モデルが、単一の分析手法より汎化性能が高いモデルとなることが示された。

「テクニカル分析は市場の動きの研究に専念するのに対し、ファンダメンタル分析は価格を上下させたり、あるいは同じレベルにとどめさせたりする原因となる、需要と供給関係に焦点をあてる」[Murphy 86] とあるように、ファンダメンタル因子とテクニカル因子は、それぞれ価格変動の原因と観測結果に対応している。ファンダメンタル因子とテクニカル因子という金融データの関係性の特徴として、ノイズトレーダー [Murphy 86] の存在ゆえ、原因と観測結果が非合理である場合が存在する時系列データであることが挙げられる。例えば、ある銘柄 A の株価が下落し、その銘柄 A のファンダメンタル因子から導かれる株価に対して割安になったとする。割安であるならば、その銘柄 A を買うことが合理的な行動であり、銘柄 A の株価は上昇すると期待されるが、株価が下落したことにより、ノイズトレーダーは悲観的な評価を行って銘柄 A を売却するといった非合理的な行動を取り、結果として銘柄 A の株価は一定、またはさらに下落する可能性がある。

本研究は、より一般的に、原因と観測結果に非合理的な関係が存在している時系列のデータに対して、それぞれ原因に着目したモデルと観測結果に着目したモデルを独立に構築し、アンサンブルモデルを用いることで、予測精度を向上することができ、原因と観測結果のデータが予測結果にもたらす影響を定量的に分析できる可能性を示唆している。

例えば、インターネット広告の将来 cost per action(以下 CPA と呼ぶ)を予測する際に、インターネット広告の素性の特徴量(広告の商品、色、予算、入札額、ターゲット層など)と、インターネット広告効果の観測結果の特徴量(インプレッション数やクリック数、CPA など)を用いる場合が考えられる。広告の素性は広告効果の観測結果に影響を与えるという因果関係が存在し、そして広告効果の観測結果は人の気まぐれや誤クリックといった合理的でない行動による結果を含んでいる。このような場合に、本研究の提案モデルのように、広告の素性を入力データとする提案モデルのファンダメンタル分析のモデルと、広告効果の観測結果を入力データとする提案モデルのテクニカル分析のモデルをそれぞれ独立に構築し、アンサンブルモデルを用いることで、予測精度を向上させ、広告の素性と観測結果を切り分けて予測結果に対する定量的な分析を行える可能性がある。

また本研究の提案モデルの適用可能性の他の例として、インターネット通販サイトにおける商品の売上予測を行う場合が考えられる。例えば商品 A と商品 B の 2 つの商品があり、値段以外の素性は全て同じで、商品 A の方が値段が安いとする。この場合、商品 A を購入することが合理的な行動であるが、知人が商品 B を購入していたなどの理由から、商品 B が商品 A に対して多く売れている






図2 分類予測におけるファンダメンタル分析の重要度の割合




図3 回帰予測におけるファンダメンタル分析の重要度の割合

ると消費者が感じた場合、より多く売れている商品を購入したいという消費者の心理が働き、実際には商品 A よりも商品 B がさらに売れるという可能性が考えられる。商品の値段や種類、機能などといった素性のデータを特徴量とする提案モデルのファンダメンタル分析のモデルと、インターネット通販サイトにおけるインプレッションやクリック数、販売個数などの観測結果の時系列データを入力データとする提案モデルのテクニカル分析のモデルをアンサンブルするというように、本研究の提案モデルを適用することで予測精度を向上させ、商品の素性と、観測結果がそれぞれ予測結果に与える影響を定量的に分析できる可能性がある。

今回の検証実験では、60日、240日と2つの期間についての推定を行った。図2、図3から、予測期間が異なれば予測に対する手法の寄与度も異なることがわかったが、十分な学習データが存在していれば、提案モデルは期間に応じて適化された分析手法の組み合わせを実現するため、より短い期間またはより長い期間にも適応することができる。また、今回の検証実験は日本の株式市場に対して行ったが、企業情報を取得するシステムを変更する必要があるが、十分な学習データさえ存在すれば他国の市場に適用することが可能であるはずである。

複数の手法を組み合わせるアンサンブルモデルにより、より予測性能が高いモデルを実現する提案モデルは、異なる分析手法を追加できる拡張性を持っており、さらに予測性能が高いモデルを実現できる可能性を持っている。例えば今回、ファンダメンタル分析として主にファンダ

メンタル指標の数値情報を特徴量としているが、実際の株式分析においては、決算短信の文字情報などを参考にすることが普通である。提案モデルは、事業内容や将来の方針などの文字情報から予測する分析を加えることが可能であり、より予測性能を上げられる可能性を持っている。

## 6. ま と め

本研究では、既存のテクニカル分析の手法を用いるだけでなく、市場における価値に着目したファンダメンタル分析を機械学習を用いて行い、アンサンブル学習を用いた複合的な株主価値推定モデルを提案した。

XBRL ファイルを利用し、全ての上場企業の企業情報を取得するシステムを用いて企業情報を一元化した。推定対象を標準化された株主価値にすることで、機械学習によるファンダメンタル分析を可能にした。機械学習によって、約 60000 サンプルのデータセットから帰納的な推定を行ったこと、そして表3のように重要な特徴量を1000項目ほどの企業情報の特徴量から抽出することによって、人間の処理できるデータサンプル数の限界及び人間の認知限界の問題を解消し、より精度の高い株主価値推定が行えることを示した。

そして、アンサンブルモデルによって異なる分析を融合させた提案モデルが、単一分析手法より予測性能が高いモデルとなることを示した。また、提案モデルによって今まで独立で研究されていた複数の既存手法を予測期間・対象に応じて組み合わせることが可能となり、さらに優れた予測を行えるようになる可能性について述べた。

本研究は、株式市場のデータ化、機械学習の発展など、多分野に渡る様々な成果によって初めて可能になったものである。本研究が、日本の金融の発展に貢献することを願っている。

## 謝 辞

本研究は JSPS 科研費 JP25700032, JP15H05327, JP16H06562 の助成を受けたものです。

## ◇ 参 考 文 献 ◇

- [Bergstra 13] Bergstra, J., Yamins, D., and Cox, D. D.: Hyperopt: A python library for optimizing the hyperparameters of machine learning algorithms, in *Proceedings of the 12th Python in Science Conference*, pp. 13–20 Citeseer (2013)
- [Brock 92] Brock, W., Lakonishok, J., and LeBaron, B.: Simple technical trading rules and the stochastic properties of stock returns, *The Journal of finance*, Vol. 47, No. 5, pp. 1731–1764 (1992)
- [Cao 01] Cao, L. and Tay, F. E.: Financial forecasting using support vector machines, *Neural Computing & Applications*, Vol. 10, No. 2, pp. 184–192 (2001)
- [Chen 15] Chen, K., Zhou, Y., and Dai, F.: A LSTM-based method for stock returns prediction: A case study of China stock market, in *Big Data (Big Data), 2015 IEEE International Conference on*, pp. 2823–2824 IEEE (2015)

- [Chen 16] Chen, T. and Guestrin, C.: Xgboost: A scalable tree boosting system, *arXiv preprint arXiv:1603.02754* (2016)
- [Choudhry 08] Choudhry, R. and Garg, K.: A hybrid machine learning system for stock market forecasting, *World Academy of Science, Engineering and Technology*, Vol. 39, No. 3, pp. 315–318 (2008)
- [Dornbusch 76] Dornbusch, R.: Expectations and exchange rate dynamics, *Journal of political Economy*, Vol. 84, No. 6, pp. 1161–1176 (1976)
- [Elton 09] Elton, E. J., Gruber, M. J., Brown, S. J., and Goetzmann, W. N.: *Modern portfolio theory and investment analysis*, John Wiley & Sons (2009)
- [Frankel 85] Frankel, J. A. and Froot, K. A.: Using survey data to test some standard propositions regarding exchange rate expectations (1985)
- [Frankel 90] Frankel, J. A. and Froot, K.: Chartists, fundamentalists, and trading in the foreign exchange market (1990)
- [Hochreiter 97] Hochreiter, S. and Schmidhuber, J.: Long short-term memory, *Neural computation*, Vol. 9, No. 8, pp. 1735–1780 (1997)
- [Kim 07] Kim, H.-j. and Shin, K.-s.: A hybrid approach based on neural networks and genetic algorithms for detecting temporal patterns in stock markets, *Applied Soft Computing*, Vol. 7, No. 2, pp. 569–576 (2007)
- [Kreesuradej 94] Kreesuradej, W., Wunsch, D. C., and Lane, M.: Time delay neural network for small time series data sets (1994)
- [Lam 04] Lam, M.: Neural network techniques for financial performance prediction: integrating fundamental and technical analysis, *Decision support systems*, Vol. 37, No. 4, pp. 567–581 (2004)
- [Lev 93] Lev, B. and Thiagarajan, S. R.: Fundamental information analysis, *Journal of Accounting research*, pp. 190–215 (1993)
- [Murphy 86] Murphy, J. J.: *Technical Analysis of the Financial Markets*, p. 5, New York Institute of Finance (1986), “日本興業銀行国際資金部 (訳). 先物市場のテクニカル分析, 一般財団法人金融財政事情研究会, 1990”
- [Saad 96] Saad, E. W., Prokhorov, D. V., and Wunsch, D. C.: Advanced neural network training methods for low false alarm stock trend prediction (1996)
- [Sharpe 64] Sharpe, W. F.: Capital asset prices: A theory of market equilibrium under conditions of risk, *The journal of finance*, Vol. 19, No. 3, pp. 425–442 (1964)
- [Tieleman 12] Tieleman, T. and Hinton, G.: Lecture 6.5-rmsprop: Divide the gradient by a running average of its recent magnitude, *COURSERA: Neural Networks for Machine Learning*, Vol. 4, No. 2 (2012)
- [川崎 16] 川崎健: アナリスト不在の不幸 強まる規制、荒れる株価, 日本経済新聞 電子版 (2016), <http://www.nikkei.com/article/DGXLZO10041570Y6A121C1EN1000/>

[担当委員: 川村 秀憲]

2017 年 5 月 1 日 受理

## ◇ 付 録 ◇

### A. テクニカル指標一覧

以下, 時刻  $t$  における終値を  $c_t$ , 始値を  $s_t$ , 高値を  $h_t$ , 安値を  $l_t$ , 出来高を  $v_t$  とする.

- (1) 終値に対する始値, 高値, 安値の割合

$$\frac{x_t}{c_t} \quad x_t = [s_t, h_t, l_t]$$

- (2)  $k$  ステップ前からの終値変化率

$$\frac{c_t}{c_{t-k}} \quad k = 1, 5, 20, 60, 120, 240, 360, 720$$

- (3)  $k$  ステップ前からの出来高変化率

$$\frac{v_t}{v_{t-k}} \quad k = 5, 20, 60, 120, 360$$

- (4) 終値の  $k$  ステップ移動平均乖離率

$$\frac{c_t}{\frac{1}{k} \sum_{i=t-k+1}^t c_i} \quad k = 5, 25, 75$$

- (5) RSI( $k$  ステップで値上がりしたステップの割合)

$$1 - \frac{1}{1 + \left( \sum_{i=t-k+1}^t U_{t-i} \right) / \left( \sum_{i=t-k+1}^t D_{t-i} \right)}$$

$$\text{where } U_t = \begin{cases} 1, & c_t > c_{t-1} \\ 0, & c_t \leq c_{t-1} \end{cases} \quad D_t = \begin{cases} 1, & c_t < c_{t-1} \\ 0, & c_t \geq c_{t-1} \end{cases}$$

$$k = 14, 20, 60$$

- (6) ゴールデンクロス (短期の移動平均線が、長期の移動平均線を下から上に抜ける現象) の有無

$$\begin{cases} 1, & a_t(k) - a_t(l) > 0 \quad \& \quad a_{t-1}(k) - a_{t-1}(l) \geq 0 \\ 0, & \text{otherwise} \end{cases}$$

$$\text{where } k < l, \quad a_t(k) = \frac{1}{k} \sum_{i=t-k+1}^t c_i$$

- (7) デットクロス (短期の移動平均線が、長期の移動平均線を上から下に抜ける現象) の有無

$$\begin{cases} 1, & a_t(k) - a_t(l) < 0 \quad \& \quad a_{t-1}(k) - a_{t-1}(l) \leq 0 \\ 0, & \text{otherwise} \end{cases}$$

$$\text{where } k < l, \quad a_t(k) = \frac{1}{k} \sum_{i=t-k+1}^t c_i$$

### B. 追加するファンダメンタル指標一覧

- (1)  $PER$ (株価収益率) =  $\frac{\text{時価総額}}{\text{当期純利益}}$
- (2)  $EPS$ (一株あたりの利益) =  $\frac{\text{純利益}}{\text{発行済株式総数}}$
- (3)  $BPS$ (一株あたりの株主資本) =  $\frac{\text{株主資本}}{\text{発行済株式総数}}$
- (4)  $PBR$ (株価純資産倍率) =  $\frac{\text{現在株価}}{BPS}$
- (5) 配当利回り =  $\frac{\text{一株あたりの配当}}{\text{株価}} \times 100$
- (6)  $ROE$ (自己資本利益率) =  $\frac{EPS}{BPS}$
- (7)  $ROA$ (総資産利益率) =  $\frac{\text{純利益}}{\text{総資産}}$
- (8) 自己資本比率 =  $\frac{\text{総資産} - \text{負債}}{\text{総資産}} \times 100$
- (9) 有利子負債自己資本比率 =  $\frac{\text{有利子負債}}{\text{自己資本}} \times 100$
- (10)  $EV$ (貸貸借表から導かれる企業価値) = 時価総額 + 有利子負債 - 貯金
- (11)  $EBITDA$ (利払い前・税引き前・減価償却前・その他償却前利益) = 営業利益 + 減価償却費
- (12)  $EV/EBITDA$  =  $\frac{EV}{EBITDA} \times 100$
- (13) 流動比率 =  $\frac{\text{流動資産}}{\text{流動負債}} \times 100$
- (14) 当座比率 =  $\frac{\text{当座資産}}{\text{流動負債}} \times 100$

## 著者紹介



田村 浩一郎

東京大学工学系研究科 技術経営戦略学専攻 修士 1 年



上野山 勝也

2004 年東京大学工学部卒業。2006 年同大学院修士課程修了。博士（工学）。外資系大手コンサルティングファームの東京/ソウルオフィスにてビジネスインテリジェンス業務に従事後、大手ネット企業の米国シリコンバレーオフィス立上げに参画し、ウェブプロダクトの大規模ログ解析業務に従事。松尾研究室にて博士（工学）取得後、2013 年より東京大学大学院工学系研究科技術経営戦略学専攻。専門は Web Mining, 機械学習/深層学習技術の産業応用



飯塚 修平

1997 年東京大学工学部卒業。2002 年同大学院博士課程修了。博士（工学）。産業技術総合研究所，スタンフォード大学を経て，2007 年より，東京大学大学院工学系研究科技術経営戦略学専攻 准教授。2012 年より人工知能学会理事・編集委員長，2014 年より倫理委員長。人工知能学会論文賞，情報処理学会会長尾真記念特別賞，ドコモモバイルサイエンス賞など受賞。専門は，Web 工学，Deep Learning，人工知能。



松尾 豊(正会員)

1997 年東京大学工学部卒業。2002 年同大学院博士課程修了。博士（工学）。産業技術総合研究所，スタンフォード大学を経て，2007 年より，東京大学大学院工学系研究科技術経営戦略学専攻 准教授。2012 年より人工知能学会理事・編集委員長，2014 年より倫理委員長。人工知能学会論文賞，情報処理学会会長尾真記念特別賞，ドコモモバイルサイエンス賞など受賞。専門は，Web 工学，Deep Learning，人工知能。