

平成 28 年度

学位論文

深層学習を用いたアンサンブルモデルによる
企業価値推定モデルの提案

平成 29 年 3 月

指導教員 松尾豊 特任准教授

東京大学工学部システム創成学科

知能社会システムコース

03-150981 田村浩一郎

概要

近年、金融庁は、中長期的な投資を推奨することを目的に、企業が未公表の重要情報を選択的に伝えることを禁じる「フェアディスクロージャー（FD）規制」の導入を進めている [1]。決算前の企業に対する証券アナリストの取材活動が規制され始めると、証券アナリストの予測が当たらなくなってしまった。その結果、金融庁の思惑に反して、決算発表後の短期的な売買が増えている。 [1]。

証券アナリストが用いている既存の企業価値推定モデルは、調査対象となる単一業界や単一企業へのインタビュー調査から、演繹的に価値推定を行う手法 [2] が主流であったが、多くの企業情報が Web 上に公開されている現在、多数の企業を対象に横断的・解析的に企業価値を推定することが可能となっている。本研究では特に、近年飛躍的に技術が向上している機械学習技術に注目し、帰納的に企業価値を推定する手法に関して研究する。

機械学習技術を用いた株価予測モデルには、主に株式市場の指数に着目したテクニカル分析 [3-5] に基づくモデルが大半 [6-12] であり、企業活動に関連するファンダメンタルな因子に着目したモデルは数少ない [13]。また、株式市場の指数と企業活動に関連する因子の両方を説明変数として横断的に用いた機械学習モデルは、筆者が知りうる限り提案されていない。

そこで本研究は、証券アナリストの予測が当たらなくなっている社会的問題を解決するために、「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」という機械学習技術を用いた企業価値推定モデルを提案する。

検証実験の結果、提案モデルは、データサンプル数を増やした帰納的推論による予測を可能にし、また、学習過程で市場の価格決定要因を抽出することによって、既存手法よりも優れた予測を行えることが示された。

そして、アンサンブルモデル [14] によって異なるアプローチを融合させた提案モデルが、より汎化性能の高いモデルとなることを示し、特に回帰予測において実用的な予測精度であることを示した。この結果は、提案モデルによって、今まで独立に提案されていた複数の既存手法を予測問題に応じて組み合わせることが可能であり、さらに優れた予測を行えるようになる可能性を示唆している。

目次

第1章 序論	1
1.1 背景	1
1.1.1 証券アナリストの現状と潜在的な問題	1
1.1.2 機械学習の発展と株式分析への適用	6
1.1.3 学術的な見地	8
1.2 研究目的	9
1.3 本論文の構成	10
第2章 関連研究	12
2.1 企業価値	12
2.1.1 企業価値と株主価値	12
2.1.2 証券アナリストの企業価値推定の目的	13
2.2 株式評価における既存の経済学ファンダメンタルアプローチ	14
2.2.1 アセットアプローチ	14
2.2.2 マーケットアプローチ	15
2.2.3 インカムアプローチ	16
2.2.4 経済学的ファンダメンタルアプローチの問題点	17
2.3 機械学習を用いた株価予測	19
2.3.1 効率的市場仮説	19
2.3.2 既存の機械学習による株価予測研究	20
2.4 各機械学習手法の基本概念	22
2.4.1 ロジスティック回帰	22
2.4.2 決定木	23
2.4.3 サポートベクターマシン	24
2.4.4 アンサンブル学習	26
2.4.5 広義のアンサンブル学習	27
2.4.6 狭義のアンサンブル学習	27

2.4.7	深層学習	31
2.4.8	多層パーセプトロンネットワーク	32
2.4.9	Recurrent Neural Networks	35
2.5	既存手法と提案手法の位置づけ	39
第 3 章	提案手法	41
3.1	モデル概要	41
3.1.1	提案モデルの目的	41
3.1.2	モデルの全体像	42
3.2	「提案モデルのテクニカルアプローチ」のモデル	44
3.2.1	予測対象	44
3.2.2	入力データ	44
3.2.3	学習器	45
3.3	「提案モデルのファンダメンタルアプローチ」のモデル	46
3.3.1	モデル概要	46
3.3.2	予測対象	47
3.3.3	財務情報を取得・データベース化するシステム	47
3.3.4	特徴量選択	48
3.3.5	学習器	49
3.4	提案モデル最終層	49
第 4 章	検証実験	51
4.1	検証実験の設定	52
4.1.1	予測対象	52
4.1.2	検証期間	53
4.1.3	評価基準	53
4.1.4	対象企業	53
4.1.5	ハイパーパラメタの取り扱い方	54
4.2	既存の経済学的ファンダメンタルアプローチの評価	55
4.3	既存の機械学習を用いたテクニカルアプローチの評価	59
4.3.1	データの性質と前処理	59
4.3.2	ハイパーパラメタの調整	63
4.4	「提案モデルのテクニカルアプローチ」のモデルの評価	64

4.5	「提案モデルのファンダメンタルアプローチ」のモデルの検証	65
4.5.1	データセットの前処理	65
4.5.2	ハイパーパラメタの調整	69
4.5.3	モデルの作成	71
4.6	ファンダメンタル分析とテクニカル分析の優位性の検証	72
4.7	提案モデルの検証	73
第 5 章	検証実験結果	75
5.1	既存の経済学的ファンダメンタルアプローチの評価結果	75
5.2	既存の経済学的ファンダメンタルアプローチの評価と「提案モデルのファンダメンタルアプローチ」のモデルの評価の比較結果	83
5.3	既存の機械学習を用いたテクニカルアプローチの評価と、「提案モデルのテクニカルアプローチ」のモデルの評価の比較結果	94
5.4	ファンダメンタル分析とテクニカル分析の優位性の検証結果	96
5.5	提案モデルの評価結果	98
第 6 章	考察	106
6.1	本研究の株式分析に対する貢献	106
6.2	今後の展望	107
6.2.1	検証実験の課題	107
6.2.2	提案モデルの拡張性	108
第 7 章	結論	109
	参考文献	110
	謝辞	116

図 目 次

1.1 証券アナリストの予測に基づく投資による累積リターン	2
1.2 TOPIX500 銘柄における 2015 年 3 月期における決算発表前後の累積売買 回転率	3
2.1 日本の 10 年国債の利回りの推移	18
2.2 多層パーセプトロンの構造	32
2.3 RNN の構造のイメージ	36
2.4 LSTM block	38
3.1 提案モデル概要	43
3.2 テクニカルアプローチのデータセット	45
3.3 「提案モデルのファンダメンタルアプローチ」のモデル概要	46

表 目 次

2.1 既存手法と提案手法の分類	40
4.1 採用するテクニカル指標一覧	61
4.2 採用するファンダメンタル指標一覧	67
5.1 アセットアプローチの評価結果	76
5.2 マーケットアプローチの評価結果	77
5.3 インカムアプローチの評価結果 1	78
5.4 インカムアプローチの評価結果 2	79
5.5 既存の経済学的ファンダメンタルアプローチの分類予測の評価結果 (正例) .	81
5.6 既存の経済学的ファンダメンタルアプローチの分類予測の評価結果 (負例) .	82
5.7 既存の経済学的ファンダメンタルアプローチの回帰予測の評価結果	83
5.8 提案モデルの「ファンダメンタルアプローチのモデル」の分類予測の評価 結果 (正例)	84
5.9 提案モデルの「ファンダメンタルアプローチのモデル」の分類予測の評価 結果 (負例)	85
5.10 提案モデルの「ファンダメンタルアプローチのモデル」の回帰予測の評価 結果	86
5.11 2014 年第 4 四半期・営業 60 日平均の分類予測におけるファンダメンタル 指標重要度	87
5.12 2014 年第 4 四半期・営業 60 日平均の回帰予測におけるファンダメンタル 指標重要度	88
5.13 2014 年第 4 四半期・営業 240 日平均の分類予測におけるファンダメンタル 指標重要度	89
5.14 2014 年第 4 四半期・営業 240 日平均の回帰予測におけるファンダメンタル 指標重要度	90

5.15 経済学的ファンダメンタルアプローチと提案モデルの「ファンダメンタル アプローチのモデル」の分類予測の正解率の比較	92
5.16 経済学的ファンダメンタルアプローチと提案モデルの「ファンダメンタル アプローチのモデル」の回帰予測の平均誤差 (%) の比較	93
5.17 予測対象が営業 60 日平均における既存の機械学習を用いたテクニカルアプ ローチと提案モデルの「テクニカルアプローチのモデル」の評価比較 (分類 予測:正解率, 回帰予測:平均誤差率)	95
5.18 ファンダメンタルアプローチの重要性が全体に占める割合	97
5.19 提案モデルの分類予測の精度結果 (正例)	99
5.20 提案モデルの分類予測の精度結果 (負例)	100
5.21 提案モデルの回帰予測の平均誤差 (%)	101
5.22 提案モデルの分類予測の正解率比較	102
5.23 提案モデルの回帰予測の平均誤差 (%) 比較	103

第1章 序論

本章では，本研究の背景，研究目的および本論文の構成について述べる．

1.1 背景

1.1.1 証券アナリストの現状と潜在的な問題

株価は多様な因子が相互に影響しあう複雑な現象の結果であり，予測の可能性やモデリングの手法に関して，多様な分野で学問的関心を集めてきた．株式分析の手法は，ファンダメンタル分析 [15, 16](以下ファンダメンタル分析に関する手法をファンダメンタルアプローチとする) とテクニカル分析 [3–5](以下テクニカル分析に関する手法をテクニカルアプローチとする) に大分され，[17] では、「テクニカル分析は市場の動きの研究に専念するのに対し，ファンダメンタル分析は価格を上下させたり，あるいは同じレベルにとどめさせたりする原因となる，需要と供給関係に焦点をあてる」としている．

証券アナリストと呼ばれる人たちは，株式市場を説明し，未来を予測しようと試みている．証券アナリストの多くは，既存の企業価値推定モデルとして，資産の価値から分析するコストアプローチ [2]，他社との比較に観点を置いたマーケットアプローチ [2]，収益から分析するインカムアプローチ [2] といったファンダメンタルアプローチ (以下経済学的ファンダメンタルアプローチと呼ぶ) を用いて企業価値推定及び投資価値評価を行なっている．しかし，2016 年 11 月 29 日の日経新聞の記事 [1] によれば，2015 年に欧州系証券 2 社のアナリストが企業決算の未公表情報を一部の顧客に知らせていた問題が発覚すると，それを契機に証券アナリストによる決算前の企業への取材活動が規制され始めた．その結果，図 1.1¹のように，証券アナリストの予測に基づく投資のリターンは低下し，2016 年 11 月では-10%以下であるという．

¹引用元: http://www.nikkei.com/news/image-article/?R_FLG=0&ad=DSXMZ01002382028112016EN1000&dc=1&ng=DGXLZ010041570Y6A121C1EN1000&z=20161129



図 1.1: 証券アナリストの予測に基づく投資による累積リターン

図 1.1 から、株式市場において、証券アナリストが決算前の事前情報なしには有意な予測を行えていないということが言える。[1]によれば、金融庁は「早耳情報に基づく短期的なトーディングではなく、中長期的な視点に立って投資を行うという投資家の意識変革を促す」という目的で、企業が未公表の重要情報を選択的に伝えることを禁じる「フェアディスクロージャー（FD）規制」の導入を進めているが、実際は、証券アナリストの予測の正確性が薄れると、図 1.2²のように決算発表後の株の変動率が上昇し、決算発表後の数日間だけ売買が膨らむ短期化が顕著になってしまった。

²引用元: http://www.nikkei.com/news/image-article/?R_FLG=0&ad=DSXMZ01002380028112016EN1000&dc=1&ng=DGXLZ010041570Y6A121C1EN1000&z=20161129




図 1.2: TOPIX500 銘柄における 2015 年 3 月期における決算発表前後の累積売買回転率

本来、株式市場の公平性という観点から、決算前の事前情報なしに予測を行うことが要求される。決算前の企業に対する証券アナリストの取材活動が規制され始めた結果、証券アナリストの予測が当たらなくなってしまった事実から、証券アナリストの用いてきた既存の企業価値推定モデルは、今まで決算前の事前情報を所与とすることで機能していたに過ぎず、既存の企業価値推定モデルそのものに潜在的な問題があるため、決算前の事前情報なしには適切な予測を行うことができないと仮定できる。

既存の企業価値推定モデルは将来キャッシュフローを始めとした入力変数や、手法の組み合わせ方に大きく依存しており、その入力変数の値や手法の組み合わせ方は、既存概念や経験に基づき演繹と帰納の繰り返りで属人的に決定されている。証券アナリストは、インタビューなどを通して対象企業や業界を「深く」分析し、解像度の高い情報を元に企業価値推定を行っていたが、証券アナリストの事前調査の規制の動きにより、事前情報の入手が難しくなり、予測が当たらなくなってしまったと考えられる。

既存の企業価値推定モデルの潜在的な問題として、主に以下の2つの問題が挙げられる。

1. 帰納的推論による予測の最適化が効果的に行われていない
2. 複数の手法が孤立している

1. 帰納的推論による予測の最適化が効果的に行われていない

現在、既存の企業価値推定モデルとして最も一般的に用いられている分析手法の経済学的ファンダメンタルアプローチは、いずれも演繹的な推論による予測手法である。

演繹的推論は、様々な仮定を導入し、論理的な推論により導き出された命題を真とする。しかし、演繹的推論による予測は、いくつかの問題を抱えている。

1つ目は、導入する仮定が正しいことは証明できず、仮定が誤りである場合は正しい推論が行えないことである。たとえば、既存の経済学的ファンダメンタルアプローチの一つであるインカムアプローチでは、企業価値は将来のキャッシュフローによって決定するという仮定を行うが、その仮定を証明する手段はないし、もし仮定が誤りであれば、予測結果は適切でないことになる。

2つ目は、導入する仮定の選択が適切であることを証明できないことである。先ほどの例を取れば、企業価値は将来のキャッシュフローによって決定するという仮定をそもそも導入すること自体が適切であることを証明できない。たとえ将来のキャッシュフローが企業価値の決定要因であったとしても、他の要因も存在する可能性があり、またそれがより重大な決定要因である可能性も否定できない。

3つ目は、仮定や推論の段階で恣意性を排除できないことである。インカムアプローチでは特に、将来の業績・フリーキャッシュフロー及び成長率 [18] を導出する際にそれらの値が恣意的であることは避けられず、同じモデルを使用しても人によって予測が異なる。

確かに、経済学的ファンダメンタルアプローチのような演繹的な手法は、非上場企業の場合など株価のような正解データが所与でない場合にも適用できる利点がある。しかし、以上のような問題を踏まえ、正解データが存在する株式市場においては、最適な予測を行うという目的を最大化する帰納的推論によって、画一的でより優れた予測を行うべきである。

実際、証券アナリストも、演繹的な手法の中にも経験則に基づく帰納的な分析を行っており、分析手法も帰納的な分析によって改善されてきた。例えば、経済学的ファンダメンタルアプローチの代表的な手法である Discount Cash Flow 法 (以下 DCF 法) [19] の割引率として用いられることの多い加重平均資本コスト WACC [20] の株式資本コスト [20] は、株のリスクを市場の動きから予測しようとする CAPM 理論 [21] を用いて導入されることが多い。この CAPM 理論は様々な仮定を必要としており、モデルとしての当てはまりの悪さが指摘され、ファマ-フレンチの 3ファクターモデル [22] がより当てはまりの良

いモデルであることを実際のデータを用いて検証し、提案者の一人である Fama はノーベル賞を受賞した。

しかし、人間による帰納的推論による予測手法には

1. 帰納的推論に使われるデータサンプル数の限界
2. 人間の認知限界

という2つの限界が存在する。

帰納的推論に使われるデータサンプル数の限界

帰納的推論を行うには、十分な数のデータサンプルが必要である。特に株式分析においては、時間軸と空間軸の2つの軸におけるデータサンプルが必要だ。企業価値の推定では、過去、現在、未来という時間軸を通して考えることが必要であるし、企業全体における位置づけや比較が欠かせない。しかし、日本の上場企業は現在約3000企業あり、決算情報は年に4回、さらには株価は常時更新されていて、膨大な量のデータがある。人間は、すべての企業の時系列データを取り扱うことはできないため、証券アナリストは専門のセクターに別れて分析を行っており、時空間的に限定的な範囲での分析にとどまっている。

人間の認知限界

膨大であるのは企業数や期間だけではない。各企業にも、固有の情報が数多くある。例えば、財務諸表から取得できる数値情報だけでも1000を超える項目がある。人間の認知できる範囲には限界があるので、証券アナリストはこの数値情報の中から重要だと思われる項目を経験的に選択し、また指標を計算・追加することで予測を行っているが、項目の取捨選択が適切である保証はない。予測に必要な項目を抽出している可能性もあるし、選択されていない項目の中に予測に重要な項目が存在している可能性もある。例えば、経済学的ファンダメンタルアプローチでは、企業の内在的な情報を用いて企業評価を行うが、市場の価格決定要因をきちんと抽出できていない可能性もあるし、日本の市場以外の動向、ニュースの報道、テクニカル指標、最近ではツイッターや株式掲示板の発言などといった外部の市場の価格決定要因を考慮できていない。

これらの限界の存在によって、既存の企業価値推定モデルは効果的に帰納的推論が行われておらず、予測結果を最適化することができていない。

2. 複数の手法が孤立している

経済学的ファンダメンタルアプローチは、アセットアプローチ、マーケットアプローチ、インカムアプローチの3つの手法が主流であり、2.2節で後述するように、それぞれのアプローチもさらに細かく様々な手法に分類される。また、先に述べたように、ファンダメンタル分析の対となる概念として、テクニカル指標を用いたテクニカル分析も古くから知られている。ファンダメンタルアプローチとテクニカルアプローチのどちらが有効であるかという議論や研究 [17, 23] が長い間行われているように、手法ごとの比較や改善が行われている。また、ニュースを分析することで株価予測を行う研究 [12] など、新たな切り口で予測を試みる手法も提案されてもいる。

しかし、筆者が知りうる限り複数の異なる手法を組み合わせるモデルが体系立てられておらず、複数の既存の企業価値推定モデルが孤立してしまっている。証券アナリストたちは、複数の孤立したアプローチを経験則に基づいて組み合わせてきたが、人間が非線形にアプローチを組み合わせることは難しく、汎化性能を効率的に上げることができていないと推測できる。

1.1.2 機械学習の発展と株式分析への適用

機械学習は現代において最も重要な技術の一つである。機械学習とは、データから学習した結果や知見をもとに、新しいデータに対して認識、判定、予測などを人間が自然に行なっているようにコンピューターが行う技術のことである。

機械学習の研究は古くから行われており、例えば深層学習の前身である Neural Networks [24] が考案されたのは1958年のことである。しかし、当時のハードの技術では計算時間の問題などから多くの手法が現実的な実用性を持っていなかった。しかし、コンピューターの性能が向上し、さらにはインターネットが普及したことによって、機械学習の重要な要素である「データが取得できること」と「計算力」が担保される形となり、実用性が飛躍的に向上した。実用性が向上したことにより、多くの研究がなされ、そして様々な分野に応用されるようになっていった。

2006年ニューラルネットワークの研究において、AutoEncoder [25] および deep belief network [26] が提案され、これが、深層学習いわゆる deep learning へと発展した。深層

学習の活用により画像認識 [27, 28], 機械翻訳 [29, 30], 音声認識 [31, 32] 等さまざまな研究領域で飛躍的な進展が報告がされた上に, 人間より高い精度で人の顔を見分けられたという研究 [27] が報告され深層学習は話題になった. 現在, 深層学習は AI, 機械学習研究におけるブレイクスルーであるとされ, 深層学習に関わる研究が盛んに行われており, 自動運転, 疾患を発見する人工知能医師など機械学習のさらなる可能性が期待されている.

近年, Finance と Technology を融合させた FinTech [33] という新たな概念が生まれ, 株式市場分析の研究にも機械学習の手法が用いられるようになってきた [6–13]. また, 企業そのものに注目してファンダメンタル分析を行う証券アナリストに対して, 数式やコンピューターを駆使するクオンツと呼ばれる人たちは, 機械学習を用いてテクニカル分析を行い, 市場を理解, 利益を得ようと試みている. 近年こうしたアプローチが取られるようになってきたのは, 機械学習の手法が発展しただけでなく, インターネットの普及やファイナンス分野におけるデータの整備が進み, 株価データが誰でも簡単に入手できるようになったことが背景としてある.

機械学習は, 膨大な時空間的なデータから帰納的にパターンを見つけ出し予測や判断を行えるだけでなく, 深層学習などのアルゴリズムは帰納的に重要な素性を抽出することができる. よって, 1.1.1 項で述べた既存の企業価値推定モデルの「帰納的推論による目的の最適化に限界がある」という問題を, 機械学習を用いることで解決することが期待される.

さらに, 機械学習の手法であり, 2.4.4 項で後述するアンサンブル学習を用いて, 複数のアプローチを融合させたモデルを構築し, 「複数の手法が孤立している」という問題を解決することも期待される.

また, 企業活動が間接的にインターネット場に露出することが増えており, 財務情報などの企業情報を取得することも可能になった.

機械学習が飛躍的な発展を遂げ, 企業情報を取得することが可能になった今, 既存の企業価値推定モデルを機械学習技術を用いて見直し, データのサンプル数を増加させた形で帰納的推論による横断的な分析を行う価値は相対的に高まっており, 今後も高まり続けると考えることができる.

1.1.3 学術的な見地

株式市場分析に機械学習を用いることを提唱している先行研究は数多くある [6–13]。その大半を占めるのは指数予測系の研究であり、Time Delay Neural Networks を用いて株価のトレンド予測をおこなった研究 [6]、Recurrent Neural Networks を用いて翌日の株価指数を予測する研究 [7] などが2000年以前に行われている。2000年以後、Neural Networks と他の予測モデルを組み合わせるハイブリッド型のモデルが提案され始め、Neural Networks と遺伝子アルゴリズムと組み合わせた研究 [8] などがその一つである。また、サポートベクターマシンを利用した株価予測 [9] が精度をあげたことで話題を呼んだ。その後、遺伝子アルゴリズムにより特徴量選択を行い、サポートベクターマシンを利用して株価を予測するハイブリッド型のモデル [13] が提唱され、精度向上を実現した。これらの研究は、一般的な機械学習の研究において、異なる予測器を組み合わせることで精度を向上させるアンサンブルモデル [14] が株式市場分析においても有効であることを示唆している。最近では、深層学習の手法の一つである Recurrent Neural Networks の拡張として提唱された Long Short-Term Memory [10] を用いて株価指数予測をする研究 [11] や、新聞記事の情報を用いた Long Short-Term Memory と株価情報を用いた Long Short-Term Memory を併用する研究 [12] が行われている。

多くの研究がなされているが、ほとんどの研究 [6–13] が株式市場の指数に着目したテクニカル分析 [3–5] に基づき指数のトレンド予測を行う研究である。機械学習技術を用いて、データサンプル数を増加させた形での帰納的推論による、横断的な企業価値推定分析の価値が相対的に高まっているにも関わらず、財務情報など企業活動に関連するファンダメンタルな因子に着目したモデルは数少なく [13]、横断的な分析を行っているモデルは筆者の知る限り提案されていない。

これには、2つの要因があると考えられる。

1つ目は、機械学習による株価予測を行う場合、指数予測を行う方が比較的容易であるということだ。固有企業の株価は、株式市場の指数以外の固有の業績やニュース情報といったファンダメンタルな要素の影響を受けやすい。企業に固有なファンダメンタル要素による株価の変動は、テクニカル指標のみでは説明が難しく、テクニカル指標を用いた機械学習の妨げとなる。また、ファンダメンタル指標を加えた機械学習を行う場合でも、十分な数の企業に対して検証を行わない限り、構成されるモデルが特定企業のみ当てはまるモデルであることを否定することができない。一方、平均化された指数予測であれば、そうした問題が存在しないために、機械学習による株価予測が比較的容易に行える。

2つ目の要因は、企業分析において企業間の関係性を計測することは不可欠であるが、それは対象範囲の全ての企業の情報を取得しなければ実現することができないということである。日本において、財務諸表などのビジネスレポートをXMLの規格をベースにした電子書籍XBRL(eXtensible Business Reporting Language)が普及したのは2005年以降のことであり、それ以前は企業の財務情報を始めとした固有の情報を一括して取得、処理することは事実上不可能であった。XBRLが普及したのちも、全ての企業についての情報を取得し取り扱うことは、XBRLの規格の複雑さやデータ量の規模の大きさ故に、困難が伴うものである。

また、[Akita, 2016] [12] らによっても指摘されていることとして、テクニカル指標のみを用いた予測、テキストマイニングのみを用いた予測といったような、単一的な研究がほとんどであり、異なるアプローチごとの関係性を考慮した研究がなされておらず、各提案手法が孤立している。この問題は、1.1.1項で述べた証券アナリストが用いている既存の企業価値推定モデルの問題と同じ問題である。

そして、[Akita, 2016] [12] ら及び[Choudhry, 2008] [13] らによっても指摘されていることとして、ほとんどの研究で提案されているモデルは、予測対象が指数であることもあり、企業間の時系列の相関を考慮している研究が少ない。ファイナンスの分野では、特定企業と市場の株価相関を、株式市場が1%変化したときに、任意の株式のリターンが何%変化するかを表す係数 β によって表現しているが、この数値は時系列性を反映できていないことや、企業と企業の相関を捉えることができていない。

以上、本研究の背景について述べた。次に、研究目的について述べる。

1.2 研究目的

本研究の目的は、証券アナリストの予測が当たらなくなってしまった「証券アナリスト不在」という社会的問題の解決のために、既存の企業価値推定モデルの潜在的問題として挙げられる

1. 帰納的推論による予測の最適化が効果的に行われていないこと
2. 複数の手法が孤立していること

を「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」の提案を行うことで解決し、より優れた投資価値評価を行うことである。

「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」は、

- 機械学習によるファンダメンタルアプローチ (以下、「提案モデルのファンダメンタルアプローチ」と呼ぶ)
- Long Short-Term Memory(以下 LSTM) を用いて企業間の時系列相関を学習したテクニカルアプローチ (以下、「提案モデルのテクニカルアプローチ」と呼ぶ)

を試み、それらの複数アプローチをアンサンブルモデル [14] によって融合させたモデルである。

そして本論文では、提案モデルの既存手法に対する優位性と有用性を示すため、下記の4つを検証する。

検証1 機械学習によってファンダメンタルアプローチを実現することで、既存の経済学的ファンダメンタルアプローチの抱える問題を解決し、より優れた時価総額の予測を行えるということ

検証2 LSTM を用いることで、市場との時系列相関を学習しより高い精度を実現できるということ

検証3 機械学習によるファンダメンタルアプローチとテクニカルアプローチの優位性は予測期間・問題によって異なること

検証4 アンサンブルモデルによって複数のアプローチを融合させたより汎化性能が高くかつ拡張性のあるモデルが実現できること

以上、本研究の目的について述べた。次に、本論文の構成について述べる。

1.3 本論文の構成

2章では、株式評価、予測の関連研究を俯瞰し、機械学習の手法を含めた周辺概念、知識を整理することで本研究の学術的見地を明確にする。

3章では、本論文で提案する「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」について説明する。まず、分析手法全体の流れを概説し、モデルが大きく3つ

の概念から構成されていることを示す。次に、用いるデータの属性・性質を説明し、データの取得方法を本研究で構築したシステムを元に説明する。その後、用いている機械学習的手法を整理しながら、用いているモデルを各要素に分解しながら説明していく。

4章では、検証実験について述べる。まず、実験に使用したデータの期間、範囲など検証実験の設定について述べ、次に検証実験の方法について説明する。

5章では、検証実験の結果を述べる。評価や比較を行う過程で、経済学的ファンダメンタルアプローチが機能しなくなっている原因や、有用なファンダメンタル指標などについても考察する。

6章で検証実験結果に基づいて提案モデルの有用性及び今後の展望を考察する。

最後に、7章で結論を述べる。

第2章 関連研究

本章では、株式評価、予測の関連研究を俯瞰し、機械学習の手法を含めた周辺概念、知識を整理することで本研究の学術的見地を明確にする。まず、企業価値推定とは何かについて整理し、本研究における企業価値推定が、証券アナリストの行なっている投資価値推定であることを明確にする。そして、証券アナリストの多くが企業価値推定モデルとして使用している経済学的ファンダメンタルアプローチについてまとめたのち、それらの問題点を言及する。次に、既存の機械学習を用いた株式分析の研究について述べ、その研究が抱える課題を考察しながら本研究との違いを述べる。そうして、本研究で提案する「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」に対する理解を深めるために、用いている機械学習の手法を整理し、詳細に述べる。最後に、既存手法と提案手法の位置関係を整理する。

2.1 企業価値

2.1.1 企業価値と株主価値

ファイナンスの分野において、「企業価値」は

$$\text{企業価値} = \text{負債} + \text{株主価値}$$

と定義される。

株価は、

$$\text{株価} = \text{株主価値} / \text{発行株式数}$$

で定義される。企業価値とは、上場企業だけに当てはまる概念ではなく、上場していない中小企業についても有効な概念である。一口に企業価値といっても、

1. 金融機関から見た企業価値
2. 組織再編性及び相続時などにおける事業関係者にとっての企業価値

3. 企業買収、売却の関係者にとっての企業価値

4. 投資家にとっての金融商品としての企業価値

といった様々な視点から捉えることができる。(1) 金融機関から見た企業価値については、多くの企業は金融機関から資金調達を行なっているが、金融機関はその企業が投資先としてどのようなリスクがあり、どれほどの価値があるのかを見定める必要がある。(2) 組織再編性及び相続時などにおける事業関係者にとっての企業価値については、企業関係者は自社の価値を知ることなしに組織再編性や相続を行うことは不可能であるし、また自社の価値を正しく推定することで競合他社との比較や自社の経営改善などを行うことも可能になる。(3) 企業買収、売却の関係者にとっての企業価値については、企業を買収もしくは売却するかの判断には、買収もしくは売却による定性的なメリット・デメリットだけでなく、企業価値を定量的に推定することが欠かせない。また、(4) 投資家にとっての金融商品としての企業価値については、投資家にとって、金融商品の価値を推定することは極めて重要なことであり、特に将来どのような価値として評価されるか、つまり価値が上がるか下がるかは利益に関わる本質的な問題である。

2.1.2 証券アナリストの企業価値推定の目的

2.1.1 項で企業価値を異なる視点から捉えたが、企業価値を推定する目的もその性質によって異なる。(1) 金融機関から見た企業価値及び(2) 組織再編性及び相続時などにおける事業関係者にとっての企業価値においては、主として「企業価値」を知ることが最終目的であるのに対し、(3) 企業買収、売却の関係者にとっての企業価値及び(4) 投資家にとっての金融商品としての企業価値において企業価値を推定することの最終目的は「将来の株主価値」または「将来株価」を推定することである。

そして、推定された企業価値は、推定対象企業が上場企業か非上場企業かによってその性質を異にする。対象企業が非上場企業であった場合、推定価値を検証する手段がなく、他に参考になる値が存在していないので、推定値そのものに価値がある。一方で対象企業が上場企業であった場合、株価という形で常に市場の評価値が出ているために、市場の評価との比較が常に重要であり、推定価格が「将来の市場の評価値」であることが求められる。

証券アナリストは上場企業を取り扱っているため、将来の市場の評価値を推定することが目的である。将来の市場の評価値を推定し、現在の評価値と比較することによって、以下の投資価値評価を行う。

- 投資判断 (買いか売るか, または中立か)
- 目標株価

本研究の最終的な目的は、証券アナリストの予測が当たらなくなってしまった「証券アナリスト不在」という社会的問題を解決することである。

よって、本稿では企業価値を (3) 企業買収, 売却の関係者にとっての企業価値及び (4) 投資家にとっての金融商品としての企業価値として捉え、本研究の予測推定対象を日本の上場企業の投資判断と、将来の株主価値及び将来の株価とする。

2.2 株式評価における既存の経済学ファンダメンタルアプローチ

この節では、既存の企業価値推定モデルとして用いられている経済学ファンダメンタルアプローチについて整理し、それらの抱えている問題を考察する。経済学的ファンダメンタルアプローチには、アセットアプローチ、マーケットアプローチ、インカムアプローチと主に3つの手法が存在する。それぞれの手法は、[2]によって以下の2.2.1項、2.2.2項、2.2.3項のようにまとめられている。

2.2.1 アセットアプローチ

アセットアプローチは、対象企業の貸借対照表に記載されている資産と負債の差額として計算される純資産をもとに企業価値を推定する方法である。アセットアプローチはさらに下記のような手法に分類される。

簿価純資産法

貸借対照表に計上されている資産・負債に粉飾・誤謬（例えば、減価償却の不足分など）等の修正を加え、資産から負債を控除した純資産額をもって株式評価するもの

修正簿価純資産法

簿価純資産に一部の資産・負債の含み損益を取り込んで評価する方法。有価証券や土地などで大きな含み損益が認められるものについて時価の取り込みを行う。

時価純資産法

資産・負債の各項目について時価評価し、時価純資産を算出し株式評価する。売上債権の滞留債権や棚卸資産の滞留在庫を評価減したり、退職給付債務や損害賠償等

の簿外処理されている可能性のある負債をオンバランスするなどして、時価純資産を算定する。時価純資産法は、個別項目ごとに時価評価し、それらを積み上げて時価純資産を求める。

アセットアプローチは、単純化されたアプローチで客観的であるという利点があるが、企業価値は将来キャッシュフローによって決まるという古典的なファイナンス分野の概念と合致していないことや、将来の予測になっていないことなどが問題点としてあげられる。

2.2.2 マーケットアプローチ

マーケットアプローチは、市場価格を基礎にして対象評価会社の株式の評価を行う方法である。第三者間取引が最も公正な価格であるという前提にたち、市場において実際に取引されている価額を用いるものである。マーケットアプローチはさらに下記のような手法に分類される。

類似公開企業比準 (比較) 法

上場（公開）している類似企業の各種指標の株価に対する倍率を参照して、評価対象会社の株式評価を行う方法。評価対象企業が非上場企業であるときに DCF 法と合わせて頻繁に用いる方法で、マーケット・アプローチの代表的な評価方法である。

市場株価法

評価対象企業が上場企業である場合に用いる方法。採用する株価は、前日終値、終値1カ月平均値、終値3カ月平均値、終値6カ月平均値などがあり、評価目的に合わせて単一もしくは併用して評価額を求める。

類似取引法

類似した取引を参照し、参照した取引における倍率等を用いて評価する方法。欧米等では M&A 取引などで用いられているが、日本では詳細に公表されている取引実績がないため類似取引のデータベース化がすすんでおらず、評価実務ではあまり一般的に採用されていない。

過去取引事例法

評価対象企業の株式が過去に頻繁に売買されている場合、過去に取引された際の価格を参照する方法。

マーケットアプローチの最大の利点はじっさに取引価格を参照している点である。しかし、市場の価格形成の特性を十分に理解し、評価目的に照らして選択しなければ、誤った評価額を導く可能性がある。

2.2.3 インカムアプローチ

インカム・アプローチは、将来期待される一連の経済的利益ないしキャッシュ・フローを、その実現のために想定されるリスク等を反映した割引率で現在価値に割り引いて企業価値を算定する方法。インカム・アプローチは、M&A等における評価額をはじめ、様々な場面で利用される最も基本的な評価方法であり、最も代表的な評価方法であるDCF(ディスカунテッドキャッシュフロー)法は、将来にわたって得られるキャッシュフローを現在価値に割引いた額となるため、ファイナンス理論に最も忠実な方法とも考えられている。インカムアプローチはさらに下記のような手法に分類される。

DCF(ディスカунテッドキャッシュフロー)法

将来キャッシュフローを、リスク等を勘案した割引率によって現在価値に割り引いた金額を評価額とする評価方法。ファイナンス理論に最も忠実な評価方法といえ、実務的に様々な場面で利用されている。ただし、将来キャッシュフローや割引率の設定に主観的な判断が介在する可能性も高く、評価額の妥当性を十分に吟味する必要がある。

収益還元法

会計上の予想利益を資本還元率によって割り引くことで企業価値を算定する方法。収益還元法は一定の成長率をもって評価する方法であるためDCF法に比べて評価額が硬直的となりやすく、予想利益が変動することが想定される場合には効果的な評価方法とは言えず、株式評価報告書ではあまり採用されない。ただし、一定の成長率であることがある場合には合理的な評価方法であり、またコストをあまりかけずに評価する場合にはDCF法の簡便的な評価方法として採用することができる。

配当還元法

配当金を株主資本コストで割り引くことで株主価値を直接評価する方法。DCF法や収益還元法が企業価値を評価し、そこから株主価値（すなわち株価）を評価する方法であるのに対し、配当還元法は株主価値を直接求めることができる。ただし、配当

金が見込めない企業（多額の繰越欠損金を抱えている、ベンチャー企業である）や日本企業のように低配当政策を採用する企業の場合、低い評価額となる可能性がある。

2.2.4 経済学的ファンダメンタルアプローチの問題点

以上のような既存の経済学ファンダメンタルアプローチの特徴として、インカムアプローチの DCF 法などは上場企業にも非上場企業にも適応できるということがある。それはファイナンス理論に従って演繹的なアプローチによって導出しているからである。しかし、1.1.1 項でも述べた通り、現状として、既存の企業価値推定モデルによる上場企業の株価予測が当たっていない。その原因は、1.1.1 項でも考察しているが、もう少し細かく整理すると、

- 市場価格が取得できる上場企業においても、非上場企業と同じ演繹的手法をとっているということ
- 時空間的な分析が効率的に行われていないということ
- 市場の価格決定要因を効果的に反映していない
- 適用しているモデルが時代の変化に対応できていない

となる。

上場企業の企業価値を推定することの目的は、将来の市場評価を推定することである。上場企業の市場評価額は常に株価として所与であるため、理論的には現在の株価と過去の情報を解析することで帰納的に予測することができるが、1.1.1 項で述べた帰納的推論に用いるデータサンプル数の限界や、ヒトの認知限界などによって帰納的推論による推定が効果的に行われていない。なお、市場株価法などのマーケットアプローチは、経済学的ファンダメンタルアプローチの中でも現在株価を参照する帰納的な方法と言えるが、この手法は現在価値を算出しているだけであって、将来予測をしているわけではなく、上場企業の企業価値推定をする目的にそぐわない。

いずれのアプローチも、過去、現在、未来という時間軸に従った分析になっておらず、現在の状態を基準にして現在値の推定及び将来予測を行なっているにすぎない。また、マーケットアプローチのように他企業との比較を行う手法もあるが、比較企業の選択が同業界内であったりと範囲が限定されかつ恣意的であることが多い。経済学的ファンダメンタルアプローチは、長い時間軸、及び企業間の関係を考慮するアプローチではない。

既存の経済学的ファンダメンタルアプローチは、市場の価格決定要因を属人的に決定しており、市場の価格決定要因を適切に抽出できていない可能性がある。また、市場の価格決定要因は、企業及びマクロなファンダメンタル指標だけではない。例えば海外情勢、ニュース報道、テクニカル手法、近年ではツイッターや株式掲示板の発言なども価格決定要因である。それにもかかわらず、企業の財務情報のみから将来の市場価格を推定することは理にかなっていない。また、たとえ多面的に異なるアプローチを試みたとしても、異なるアプローチによって導かれた予測結果を組み合わせる手法が体系立てられていない。

さらに、既存の企業価値推定モデルとして用いられている数式モデルが、時代の変化に対応できていない可能性がある。例えば、DCF法の割引率として用いられることの多いWACC [20] の株式資本コスト [20] は、株のリスクを市場の動きから予測しようとするCAPM理論 [21] を用いて導入されることが多い。しかし、CAPM理論が提案されたのは1960年代であるが、日本の10年国債の利回りの推移(図2.1¹)などからもわかるように、日本の株式市場の状態は大きく変化している。日本の株式市場の現状が過去に提案された数式モデルに適していない可能性がある。



図 2.1: 日本の10年国債の利回りの推移

¹引用元: <http://efficient-world.jp/wp-content/uploads/2015/07/cd690e89a46e6daafa35c1c1ce728428.png>

2.3 機械学習を用いた株価予測

この節では、機械学習を用いて株価を予測する研究の学術的見地を説明する。まず、本論文の効率的市場仮説に対する立場を明らかにする。その後、既存の機械学習を用いた株価予測に関する研究をあげ、それらの未解決問題や領域について明らかにしながら、本研究の新規性と学術的見地を明確にしていく。

2.3.1 効率的市場仮説

効率的市場仮説 [34] とは、「全ての情報がすでに株価に織り込まれている」という仮説であり、ファイナンスの分野において支持を集めている。効率的市場仮説には程度で分類された以下の3つの説がある。

ウィーク型効率性

市場において現在価格は過去の情報を全て反映したものである

セミストロング型効率性

ウィーク型の仮説に加えて、新たに公開される情報が瞬時に価格に反映される

ストロング型効率性

インサイダーなどの一般的でない情報でさえ瞬時に価格に反映される

しかし、もしこの仮説がいかなる場合にも正しければ、事実上市場の平均以上のリターンを求めることが不可能というだけでなく、現在価格が常に適正価格であるため、証券アナリストの予測も、過去のパターンから将来予測を行う機械学習のアプローチも、意味をなさないということになる。実際には、ファイナンスの分野において、株価が割高になるバブルの発生や暴落が説明できないとする批判や、投資家は必ずしも合理的でないとする行動経済学的な立場からの批判も多く、また値上がりした銘柄がさらに上昇したり、値下がりした銘柄がさらに下落するといった市場が一方向に進みやすいというモメンタム効果は、代表的な効率的市場仮説のアノマリーであるとされている。また RJ Shiller は、過去の株式市場のデータから株価は常に合理的な価格ではないことを検証することで効率的市場仮説を否定 [35] している。

先にも述べた通り、効率的市場仮説の「全ての情報がすでに現在株価に織り込まれており、現在価格が常に適正価格である」という命題を偽と仮定することで、株価の将来予測を行うことの意義が発生する (もし命題が真であれば、上場企業のように株価が与えられ

ている状況で、その株価が常に正しく、過去の情報から予測される結果は常に現在値と等しいということになり、予測の意義はない)。しかし、効率的市場仮説を全面的に否定し、市場が全く効率的でないと仮定してしまうと、機械学習による帰納的な予測手法に矛盾が生じることに留意する必要がある。つまり、教師あり機械学習は、正解データをもとに学習したモデルを用いて将来の予測を出力するが、「全ての情報がすでに現在株価に織り込まれており、現在価格が常に適正価格である」という命題を偽と仮定した場合、正解データにおいても「正解データは全ての情報を織り込んでおり、常に適正価格である」という命題が偽であることになる。機械学習は、正解データが正しいことを要求するため、機械学習の手法自体が不適切であることになる。

この矛盾を解決するには、効率的市場仮説の「瞬時」に「全て」の情報が価格に反映されるというセミストロング型効率性仮説を否定し、ある一定以上の時間幅においては効率的市場仮説は正しいが、瞬間瞬間においては、市場が反映できていない情報や誤って反映してしまっている情報が存在しているという捉え方をする必要がある。つまり、市場は常に正しいという訳ではないが、常に正しくなろうとする力が働くということである。

未来が現在より正しいという立場をとることで、機械学習のような帰納的推論による株価の将来予測の正当性が確保される。

本研究では、「市場は常に正しいという訳ではないが、常に正しくなろうとする力が働く」という、効率的市場仮説の議論に対して中立的な立場をとる。

2.3.2 既存の機械学習による株価予測研究

株式市場分析に機械学習を用いることを提案している先行研究は数多くある [6–13]。

それらの大半の研究の予測対象は S&P500(Standard and Poor's 500)、TOPIX(Tokyo Stock Exchange Prices Indexes) や日経平均株価などの指数であり、Time Delay Neural Networks を用いて株価のトレンド予測をおこなった研究 [6]、Recurrent Neural Networks を用いて翌日の株価指数を予測する研究 [7] などが 2000 年以前に行われている。2000 年以後、Neural Networks と他の予測モデルを組み合わせるハイブリッド型のモデルが提案され始め、Neural Networks と遺伝子アルゴリズムと組み合わせた研究 [8] などがその一つである。これらの研究は、一般的な機械学習の研究において、異なる予測器を組み合わせることで精度を向上させるアンサンブルモデル [14] が株式市場分析においても有効であることを示唆している。また、サポートベクターマシンを利用した株価予測 [9] が精度

をあげたことで話題を呼んだ。最近では、深層学習の手法の一つである Recurrent Neural Network の拡張として提唱された Long Short-Term Memory(LSTM) [10] を用いて株価指数予測をする研究 [11] がなされている。

本研究は、予測対象を企業の株価としており、企業の固有な情報や特性なども株価に反映されることから、こうした平均化された指数予測の研究とは性質が異なる。

企業一つ一つの株価を予測しているような研究は、遺伝子アルゴリズムにより特徴量選択を行い、サポートベクターマシンを利用して株価を予測するハイブリッド型のモデル [13] や、新聞記事の情報を用いた LSTM モデルと株価情報を用いた LSTM を併用する研究 [12] などがある。しかしこれらの研究はいずれもテクニカルアプローチをそれぞれの企業に独立に試みた研究であり、本質的には先の指数予測の研究と同じであると言える。

また、[12] でなされている重要な問題提起の一つに、既存研究の多くはテクニカル指標のみを用いた研究であり、企業活動に関連するファンダメンタルな因子にを入力データとして用いることの有用性や、異なるアプローチを組み合わせる最終予測を出力する手法の考察が行われていない、ということがある。

本研究は、他の株価予測研究と同じように、企業一つ一つに独立のテクニカルアプローチのモデルを使用するだけでなく、上場企業全体において横断的にファンダメンタルアプローチを試みることで、横断的・解析的に企業価値を推定する。予測対象を株主価値とすることで、企業ごとの株式発行数の違いに縛られず、すべての企業を並列で評価することができる。そして、テクニカルアプローチとファンダメンタルアプローチの両方を試み、それらの異なる複数のアプローチを融合することができるモデルを提案する。

[13] において、株価は独立で変動するというわけではなく [36]、企業間相関を考慮したモデルの必要性について提案している。企業 A と企業 B の相関を、[13] では

$$Cor(A, B) = \frac{\frac{1}{n} \sum_{t=1}^T (CloseA_t - \mu_{CloseA})(CloseB_t - \mu_{CloseB})}{\sigma_{CloseA} \sigma_{CloseB}}$$

と計算している。 $CloseA_t, CloseB_t$ は時点 t における終値、 $\mu_{CloseA}, \mu_{CloseB}$ は $t = 1 \sim T$ における平均値、 $\sigma_{CloseA}, \sigma_{CloseB}$ は $t = 1 \sim T$ における標準偏差である。

また、ファイナンスの分野においては、企業のマーケットとの相関を表す時に、個別株

式がマーケットのリスクにどの程度影響されるかを表す指標 β を用いる．企業 A と指数 Index との β は,

$$\beta(A, Index) = \frac{\frac{1}{n} \sum_{t=1}^T (\Delta A_t - \mu_{\Delta A})(\Delta Index_t - \mu_{\Delta Index})}{\sigma_{\Delta Index}}$$

と定義されている． $\Delta A_t, \Delta Index_t$ は時点 t における変化率， $\mu_{\Delta A}, \mu_{\Delta Index}$ は $t = 1 \sim T$ における平均値， $\sigma_{\Delta Index}$ は $t = 1 \sim T$ における標準偏差である．

両者の違いは終値の分布を考慮しているか，変化率の分布を考慮しているかの違いである．いずれの場合も市場との相関を表現することを試みた数式モデルであるが，いずれもすべてのタイムステップを同等に扱っており，時系列相関を表現できていない．

本研究では，既存の研究では指数予測に使われていた機械学習によるテクニカルアプローチを企業価値推定にも導入し，その際，再帰的深層学習 Recurrent neural network の一つである LSTM を用いることで，より効果的に時系列相関を抽出し，学習することを試みる．

2.4 各機械学習手法の基本概念

次に，本論文で提案するモデルで使用されている一般的な機械学習手法の基本概念について説明する．

2.4.1 ロジスティック回帰

ロジスティック回帰 [37] は分類モデルであり，線形分離可能なクラスに対して効果を発揮する．正事象の起こる確率を p とすると，事象の起こりやすさを表現するオッズ比は $\frac{p}{1-p}$ と定義される．そして，ロジット関数を次のように定義する．

$$\text{logit}(p) = \log \frac{p}{1-p}$$

ロジット関数は，0 ～ 1 の値を入力として実数全体に写像する関数である．正事象のクラスラベルを $y = 1$ とした時，ロジット関数を用いて，特徴量 \mathbf{x} の値を対数オッズ間の線形関係を以下のように表現できる．

$$\text{logit}(p(y = 1|\mathbf{x})) = \sum_{i=0}^m w_i x_i = \mathbf{w}^T \mathbf{x}$$

ここで、ロジット関数の逆関数であるロジスティック関数を用いることで、サンプルが特定のクラスに属している確率を予測することが可能になる。

$$z = \mathbf{w}^T \mathbf{x}$$

$$\phi(z) = \frac{1}{1 + e^{-z}}$$

モデルのパラメタ \mathbf{w} は尤度 L

$$L(\mathbf{w}) = P(\mathbf{y}|\mathbf{x}; \mathbf{w}) = \prod_{i=1}^n (\phi(z^{(i)}))^{y^{(i)}} (1 - \phi(z^{(i)}))^{1-y^{(i)}}$$

を最大化することで求められる。一般的には、対数尤度の負の値をコスト関数に設定し、

$$J(\mathbf{w}) = \sum_{i=1}^n [-y^{(i)} \log(\phi(z^{(i)})) - (1 - y^{(i)}) \log(1 - \phi(z^{(i)}))]$$

を勾配降下法を用いて最小化する。

2.4.2 決定木

決定木 [38] は、分類、回帰予測問題を扱うことのできるアルゴリズムであり、意味解釈 (得られた結果から意味の解釈や知見を取得すること) 可能性を持っているアルゴリズムである。

決定木のアルゴリズムは、特徴量 x_i に対して閾値を設定し、決定木の根から特徴量ごとに2分類を繰り返し、情報利得が最大となる特徴量でデータを分割していくというものだ。分類問題におけるの情報利得目的関数は、2分決定木の場合以下のように定義される。

$$IG(D_p, f) = I(D_p) - \frac{N_{left}}{N_p} I(D_{left}) - \frac{N_{right}}{N_p} I(D_{right})$$

ただし、 f は分割を行う特徴量であり、 I は不純度を表す関数、 D_p は親のデータセット、 D_{left} 及び D_{right} は子ノードのデータセットである。この目的関数を最大化するような特徴量でデータを分割していく。なお、過学習を避けるために、木の深さに制限をかけて学習することが一般的である。

不純度としての関数はいくつかあり、最も一般的であるのは誤分類の確率を最小化する

条件である，ジニ不純度であり，以下のように定義される．

$$I_G(t) = \sum_{i=1}^c p(i|t)(1 - p(i|t)) = 1 - \sum_{i=1}^c p(i|t)^2$$

$p(i|t)$ は特定のノード t においてクラス i に属する割合を表す．

また，回帰問題である場合，不純度関数は，

$$I(t) = MSE(t) = \frac{1}{N_p} \sum_{i \in D_t} (y^{(i)} - \hat{y}_t)^2$$

$$\hat{y}_t = \frac{1}{N} \sum_{i \in D_t} y^{(i)}$$

と定義され，分割後の分散を最小化するような条件となっている．なお， N_t はノード t のトレーニングサンプルの個数， D_t はノード t のトレーニングセットを表す．

2.4.3 サポートベクターマシン

サポートベクターマシン (SVM: Support Vector Machine) [39, 40] は，最適化の目的としてマージン最大化をする分類，回帰アルゴリズムである．線形判別関数を用いた手法 [39] に加えて，線形分離不可能な場合においても利用可能な手法 [40] に拡張された．

ハードマージンサポートベクターマシン

ハードマージンサポートベクターマシンは，線形判別式を用いたアルゴリズムである．

回帰問題である場合，判別関数は

$$f(x) = \text{sign}(\mathbf{w}^t \mathbf{x} + b)$$

$$\text{sign}(x) = \begin{cases} 1, & x > 0 \\ -1, & x \leq 0 \end{cases}$$

と表される．一方回帰問題である場合，出力関数を

$$f(x) = \mathbf{w}^t \mathbf{x} + b$$

とすれば良い．

ここで \mathbf{x} は入力データ， \mathbf{w} 及び b は今回最適化したいパラメタである．

正の超平面を $\mathbf{w}^t \mathbf{x}_{\text{pos}} + b = 1$ 負の超平面を $\mathbf{w}^t \mathbf{x}_{\text{neg}} + b = -1$

とした時, 超平面の距離すなわちマージンは,

$$\frac{\mathbf{w}^t (\mathbf{x}_{\text{pos}} - \mathbf{x}_{\text{neg}})}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}$$

で定義される.

線形判別の超平面が存在するための条件は,

$$y_{(i)}(\mathbf{w}^t \mathbf{x}_{(i)} + b) \geq 1$$

であるから, 結局, マージン最大化は

$$\begin{cases} \min & \phi(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s. t.} & y_{(i)}(\mathbf{w}^t \mathbf{x}_{(i)} + b) \geq 1 \end{cases} \quad (2.1)$$

の最適化問題を解くことによって実現され, パラメタを求めることができる.

ソフトマージンサポートベクターマシン

ハードマージンサポートベクターマシンの欠点として, 線形分離不可能な場合に適応できないということがあった. ソフトマージンサポートベクターマシンは, ハードマージンサポートベクターマシンの制約条件を緩め, 代わりにペナルティー関数を導入することでその問題の解決を図ったアルゴリズムである. スラック変数 $\xi \geq 0$ とペナルティー項 C を用いると, 2.1 の最適化問題は

$$\begin{cases} \min & \phi(\mathbf{w}, \xi) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_{(i)} \\ \text{s. t.} & y_{(i)}(\mathbf{w}^t \mathbf{x}_{(i)} + b) \geq 1 - \xi_{(i)} \end{cases} \quad (2.2)$$

となる.

非線形サポートベクターマシン

ソフトマージンサポートベクターマシンによって非線形問題についてもサポートベクターマシンを適応することが可能になったが, 最終的な境界面は線形であるため, 境界面が非線形である場合に適切なモデルにはならない. そこで, 非線形サポートベクターマシンは, 特徴量 \mathbf{x} を非線形写像関数 $\varphi: R^n \rightarrow R^m$ を用いて高次元空間に写像することによって線形分離を可能にするという発想に基づくアルゴリズムで

ある。

2.1 の最適化問題をラグランジュ未定乗数法によって解く際、ラグランジュ関数は

$$L(\mathbf{w}, b, \lambda) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \lambda_i y_i ((\mathbf{w}^t \mathbf{x} + b) - 1) \quad (2.3)$$

と定義できる。 $\frac{\partial L}{\partial b} = 0$ 及び $\frac{\partial L}{\partial \mathbf{w}} = 0$ を計算することによって 2.3 から

$$L(\mathbf{w}, b, \lambda) = \sum_{i=1}^n \lambda_i - \sum_{i, j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \quad (2.4)$$

が導かれる。非線形サポートベクターマシンでは、2.4 の式は、

$$L(\mathbf{w}, b, \lambda) = \sum_{i=1}^n \lambda_i - \sum_{i, j=1}^n \lambda_i \lambda_j y_i y_j \varphi_i(\mathbf{x}) \varphi_j(\mathbf{x}) \quad (2.5)$$

しかし、写像関数 $\varphi(\mathbf{x})$ の計算コストが高いという現実的な問題があるため、実際にはカーネルトリックと呼ばれる手法を用いる必要がある。2.5 の式では結局、 $\varphi_i(\mathbf{x}) \varphi_j(\mathbf{x})$ は高次元空間での内積であるから、直接高次元空間の内積 $k(\mathbf{x}_i, \mathbf{x}_j)$ を定義すればよく、これをカーネル関数という。一般的にカーネル関数には動径基底関数カーネル (RBF: Radical Basic Function kernel)

$$k(\mathbf{x}_i, \mathbf{x}_j) = \exp \left(-\gamma \|\mathbf{x}_{(i)} - \mathbf{x}_{(j)}\|^2 \right)$$

を用いる。なお、 γ は最適化するハイパーパラメタである。

2.4.4 アンサンブル学習

アンサンブル学習 [14] とは、個々に学習した複数の学習きを何らかの形で組み合わせて汎化性能を向上させる手法のことを言う。アンサンブル学習は

1. 異なる学習器で学習した結果をアンサンブルするもの
2. 同じ学習器で学習した結果をアンサンブルするもの

の2つに大別することができる。本稿では、必要に応じて (1) のアンサンブル学習を「広義のアンサンブル学習」とし、(2) のアンサンブル学習を「狭義のアンサンブル学習」と区別する。

2.4.5 広義のアンサンブル学習

「広義のアンサンブル学習」は、異なる学習器を組み合わせで行うので、汎化性能の向上が期待されるだけでなく、異なる性質の特徴量を異なるモデルによって扱えるため、本研究のようにファンダメンタルアプローチとテクニカルアプローチの双方のアプローチを組み合わせるといったような異なる複数のアプローチを組み合わせることが可能になるという点で、重要な手法である。多くの場合、「広義のアンサンブル学習」は2層もしくはそれ以上の層によって形成されるモデルである。2層目以降で採用されるモデルとして、

分類問題であれば

1. 単純な多数決
2. 一層目のモデルの精度に応じて重み付けをした上での多数決
3. 2層目に非線形機械学習モデルを使用する

回帰問題であれば

1. 単純平均
2. 一層目のモデルの精度に応じて加重平均
3. 2層目に非線形機械学習モデルを使用する

ようなモデルがある。(3)のモデルは、ハイパーパラメタ探索用のデータセット、学習のためのデータセット、検証のためのデータセットと複数のデータセットを全体のデータセットから分割して確保する必要があるが、複雑であるのに対し、(1)、(2)の場合は学習と検証に必要なデータセット数を確保しやすく、また単純であるという利点がある。しかし、多くの問題は非線形問題であるので、可能であるならば(3)のモデルが好まれる。

2.4.6 狭義のアンサンブル学習

狭義のアンサンブルモデルは、さらに以下の2つに分類することができる。

1. 同種の学習器を独立に学習し、それらをアンサンブルするもの
2. 単純な学習器を逐次的に学習し、それらをアンサンブルするもの

(1)のパターンはバギング、(2)のパターンはブースティングと呼ばれている。

バギング

バギング [41] は，ブートストラップ法 [42] を用いて弱学習器を作成し，その出力から最終的な学習器を作成する方法．アルゴリズムは以下のとおり．

1. 以下の手順を N 回繰り返す．
 - 入力データセット D から重複抽出を行い，データセット D_n を作成する
 - データセット D_n を用いて弱学習器 h_n を作成する
2. (1) で作成した学習器 h_n を用いて，最終的な学習器を作成する．出力を $H(x)$ とすると，
 - 分類問題の場合: $H(x) = \operatorname{argmax} \{n | h_n = y\}$
 - 回帰問題の場合: $H(x) = \frac{1}{N} \sum_{n=1}^N h_n$

ランダムフォレスト

ランダムフォレスト [43] は，バギングに決定木 2.4.2 を用いて，さらに特徴量選択を行っているアルゴリズムである．アルゴリズムは以下のとおり．

1. 以下の手順を N 回繰り返す．
 - 入力データセット D から重複抽出を行い，データセット D_n を作成する
 - データセット D_n を用いて，以下の手順をノード数の上限に達するまで繰り返し，決定木 T_n を作成する
 - － p 個の特徴量の説明変数から m 個の変数をランダムに選択する
 - － 選択された m 個で決定木を作成する
2. (1) で作成した決定木 T_n を用いて，最終的な学習器を作成する．出力を $T(x)$ とすると，
 - 分類問題の場合: $T(x) = \operatorname{argmax} \{n | T_n = y\}$
 - 回帰問題の場合: $T(x) = \frac{1}{N} \sum_{n=1}^N T_n$

また，ランダムフォレストの派生として，決定木を作成する際に枝分かれ位置をランダムで決定することで計算速度を上げる Extra Trees アルゴリズムなどもある．

ブースティング

ブースティング [44] は確率的近傍学習 (PAC learning) に基づいたものであり, 逐次的に弱学習器を作成するアルゴリズムである. ブースティングには,

- Adaboost
- Gradient boosting
- Xgboost(eXtreme Gradient Boosting)

が代表的なアルゴリズムとしてある.

Adaboost

Adaboost のアルゴリズムは以下のとおり.

1. m 個に分割されたデータセット D_i に対する重み $W(i)$ の確率分布 \mathbf{W} の初期値 \mathbf{W}_1 を生成する
2. 以下の手順を T 回繰り返す.

- \mathbf{W}_t に従って弱学習器 h_t を作成する
- 弱学習器 h_t の誤り率を計算

分類問題の場合: $\epsilon_t = \sum_{i: h_t(\mathbf{x}_i) \neq y_i} W_t(i)$

回帰問題の場合: $S = \sup |\hat{y}_i(\mathbf{x}_i) - y_i| \quad i = 1, 2, \dots, m$ としたとき,

$$\epsilon_t = \frac{1}{mS} \sum_{i=1}^m |\hat{y}_i(\mathbf{x}_i) - y_i| W_t(i)$$

- 弱学習器 h_t の重要度 α_t を計算

分類問題の場合: $\alpha_t = \frac{1}{2} \log\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$

回帰問題の場合: $\alpha_t = \frac{1-\epsilon_t}{\epsilon_t}$

- 重みを更新する

$$\text{分類問題の場合: } W_{t+1}(i) = W_t(i) \times \begin{cases} e^{-\alpha_t} & \text{if } h_t(x_i) = y_i \\ e^{\alpha_t} & \text{if } h_t(x_i) \neq y_i \end{cases}$$

回帰問題の場合: $W_{t+1}(i) = W_t(i) \times \alpha_t \exp(1 - \epsilon_t)$

3. 2 で作成した弱学習器 h_t を用いて, 最終的な学習器を作成する. 出力を $H(\mathbf{x})$ とすると,

- 分類問題の場合: $H(\mathbf{x}) = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x})\right)$

- 回帰問題の場合: $H(\mathbf{x}) = \sum_{t=1}^T \alpha_t h_t(\mathbf{x})$

Gradient boosting

Gradient boosting [45] は勾配ブースティングとも呼ばれ, Adaboost の派生アルゴリズムである. Adaboost で重みを更新するところを, Gradient boosting では損失関数をパラメタ行列で微分する勾配降下法を用いて重みの更新を行うアルゴリズムである.

XGBoost

XGBoost(eXtreme Gradient Boosting) [46] はランダムフォレストと Gradient boosting の双方の概念を取り入れたアルゴリズムである. アルゴリズムは以下のとおり.

1. I 個に分割されたデータセット D_i に対する決定木 $f_0(\mathbf{x}_i)$ を生成する.

$$f_t \in F$$

$$\text{where } F = \{f(\mathbf{x}) = w_{q(x)}\}, \quad q: R^m \rightarrow N, \quad w \in R^N$$

なお \mathbf{x}_i は入力データ, w は葉の重み, m は入力データの次元, N は葉の数である. 普通の決定木とは葉に重みが定義されることが異なる.

2. 以下の手順を $t = 1, 2, \dots, k, \dots, T$ と繰り返す.

- 予測値 $\hat{y}_i = \sum_{t=1}^k f_t(\mathbf{x}_i)$ を計算
- モデルの評価式を定義する

$$L(\phi)^{(t)} = \sum_i l(y_i, \hat{y}_i^{(t-1)}) + f_t(\mathbf{x}_i) + \Omega(f_t)$$

$$\text{where } \Omega(f_t) = \gamma N + \frac{1}{2} \lambda \|w\|^2$$

ただし, y_i は正解データ, l は損失関数, Ω は正則化項, γ, λ はパラメタである.

- 評価式を Taylor 展開して 2 次の項まで求め, 定数項を除く.

$$\tilde{L}(\phi)^{(t)} = \sum_i g_i f_t \left[\mathbf{x}_i + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \Omega(f_t)$$

$$\text{where } g_i = \partial_{\hat{y}_i^{(t-1)}} l(y_i, \hat{y}_i^{(t-1)}), \quad h_i = \partial_{\hat{y}_i^{(t-1)}}^2 l(y_i, \hat{y}_i^{(t-1)})$$

- 上記の手法により g_i と h_i を変数とする最適化問題に置き換えられたので、最適化をすることで w を更新する。
3. 2で作成した決定木 f_t を用いて、最終的な学習器を作成する。出力を $F(\mathbf{x})$ とすると、

- 分類問題の場合: $F(\mathbf{x}) = \text{sign}(\sum_{t=1}^T f_t(\mathbf{x}))$
- 回帰問題の場合: $F(\mathbf{x}) = \sum_{t=1}^T f_t(\mathbf{x})$

決定木による特徴量重要度抽出

決定木アルゴリズムは 2.4.2 項でも述べた通り、意味解釈可能性を持ったアルゴリズムである。特徴量ごとに計算される情報利得は、その特徴量が予測問題においてどれだけの意味をなしているかという指標に他ならない。ランダムフォレスト及び XGBoost は、決定木のアンサンブルモデルであり、これらのアルゴリズムによって特徴量の重要度を抽出することが可能である。具体的には、弱学習器として使用されている決定木の情報利得の特徴量ごとの平均を計算することで、特徴量の重要度を求めることができる。

本研究では、XGBoost を用いて各特徴量の重要度を計算し、特徴量選択するだけでなく、「広義のアンサンブルモデル」における 2 層目に XGBoost を用いることで、各アプローチの重要度を抽出することを試みる。

2.4.7 深層学習

深層学習は多層のニューラルネットワークによる機械学習のことで、従来の機械学習の手法では難しかった対象データの特徴量抽出を最適化の過程で行うことができる。深層学習の活用により画像認識 [27, 28]、機械翻訳 [29, 30]、音声認識 [31, 32] 等さまざまな研究領域で飛躍的な進展が報告がされている。

深層学習は、画像処理に利用される Convolutional Neural Networks [47](CNN) というネットワークや、系列データの処理に利用される Recurrent Neural Networks [48](RNN) というネットワークがあるが、どのネットワークも多層パーセプトロンネットワークの手法を基本としている。ここでは、まず多重パーセプトロンの説明をしたのち、本研究で用いている Recurrent Neural Networks 及びその派生ネットワーク Long Short Term Memory Recurrent Networks [10](LSTM) について説明する。

2.4.8 多層パーセプトロンネットワーク

順伝播型ネットワークの構造




図 2.2: 多層パーセプトロンの構造

多層ネットワークは，図 2.2 のように，入力層 (input layer)，隠れ層 (hidden layer)，出力層 (output layer) によって構成される．

入力データを \mathbf{x} とした時，入力層から隠れ層へ下記のように情報を伝播させる．

$$\mathbf{u}^{(i)} = \mathbf{W}^{(i)}\mathbf{x} + \mathbf{b}^{(i)}$$

$$\mathbf{z}^{(i)} = \mathbf{f}(\mathbf{u}^{(i)})$$

なお， $\mathbf{W}^{(i)}$ は入力層から隠れ層への重み行列， $\mathbf{b}^{(i)}$ はバイアス， \mathbf{f} は活性化関数である．

1 番目の隠れ層では同様にして，

$$\mathbf{u}_l^{(h)} = \mathbf{W}_l^{(h)}\mathbf{z}_{l-1}^{(h)} + \mathbf{b}_l^{(h)}$$

$$\mathbf{z}_l^{(h)} = \mathbf{f}(\mathbf{u}_l^{(h)})$$

最後の出力層では

$$\mathbf{u}^{(o)} = \mathbf{W}^{(o)} \mathbf{z}_L^{(h)} + \mathbf{b}^{(o)}$$

$$\mathbf{z}^{(o)} = \mathbf{f}(\mathbf{u}^{(o)})$$

となっている。

ネットワークによる予測 $\hat{y} = \mathbf{z}^{(o)}$ とラベルデータ y を用いて、誤差関数 $E(\hat{y}, y)$ を設定し、誤差関数の最適化問題を解くことで重み $\mathbf{W}^{(i)}$, $\mathbf{W}_l^{(h)}$, $\mathbf{W}^{(o)}$ および、バイアス $\mathbf{b}^{(i)}$, $\mathbf{b}_l^{(h)}$, $\mathbf{b}^{(o)}$ を求める。

勾配降下法と誤差逆伝播法

多層パーセプトロンの学習方法について説明する。重みの更新は、負の勾配方向に行なっていく。

$$\nabla E = \frac{\partial E}{\partial \mathbf{w}} = \left[\frac{\partial E}{\partial w_1}, \frac{\partial E}{\partial w_2}, \dots, \frac{\partial E}{\partial w_M} \right]$$

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \epsilon \nabla E$$

なお、 ϵ は学習率である。ここで採用する勾配降下法は、基本的なものとして

バッチ勾配降下法 データセット全体に対して勾配を計算する方法

確率的勾配降下法 サンプルの一部または一つに対して勾配を計算しパラメタを更新する方法

ミニバッチ勾配降下法 重みの更新を少数のサンプルの集合ごとに行う方法。

がある。特にミニバッチを利用した確率的勾配降下法は、計算効率を向上させるだけでなく、局所解に陥るリスクを低減することができるため、より一般的である。また、この他にも、Adagrad [49], Adadelta [50], RMSprop [51], Adam [52], Nadam [53] など多くの最適化アルゴリズムが提案されており、適切な最適化アルゴリズムを採用することが求められる。

過学習の抑制

過学習は、与えられた学習データに対して過度な適合をしてしまい、汎化性能が落ちてしまうことをいう。過学習は、勾配降下法で局所解に陥っている状態とも理解できる。過学習を避ける手法はいくつか提案されており、以下のようなものがある。

早期終了 (early stopping) 学習を進める上で、validation 誤差が増加するようであればその時点で学習を終了する手法

正則化 学習時の重みの自由度を制約関数を設けることで制限する手法

ドロップアウト 多層ネットワークにおけるユニットを確率的に重みの更新対象から外す手法。この手法はドロップアウトにより局所的に複数の学習器が存在することになり、アンサンブル学習と同じ原理で汎化性能の向上を期待するものであるとされている。

次に、誤差逆伝播法について説明する。

誤差逆伝播法

先にも述べたように、重みの更新は、誤差関数の勾配を計算する必要がある。

$$\nabla E = \frac{\partial E}{\partial \mathbf{w}}$$

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \epsilon \nabla E$$

しかし、多層パーセプトロンの場合、出力層から入力層に向かって何層にも渡って微分の連鎖規則を繰り返す必要が出てくる。これは非常に計算コストが高く、現実的でない。そこで、用いられる手法が誤差逆伝播法である。

隠れ層の第 l 層において、 $l-1$ 層のノード i から l 層のノード j に対する重みを w_{ji} 、 n 番目バッチ学習の誤差関数を E_n とすると、勾配降下法において、

$$\frac{\partial E_n}{\partial w_{ji}^{(l)}} = \frac{\partial E_n}{\partial u_j^{(l)}} \frac{\partial u_j^{(l)}}{\partial w_{ji}^{(l)}} \quad (2.6)$$

となる。第 l 層のノードの集合を N_l とすると、 u_j^l の変化は $l+1$ 層の入力 u_k^{l+1} の線形和の変化によってのみ生じるので、微分連鎖より

$$\frac{\partial E_n}{\partial u_j^{(l)}} = \sum_{k \in N_{l+1}} \frac{\partial E_n}{\partial u_k^{(l+1)}} \frac{\partial u_k^{(l+1)}}{\partial u_j^{(l)}} \quad (2.7)$$

2.7 の式は，両辺に $\frac{\partial E_n}{\partial u_j^{(l)}}$ が存在している．ここで，

$$\delta_j^{(l)} = \frac{\partial E_n}{\partial u_j^{(l)}} \quad (2.8)$$

とおくと，

$$\begin{aligned} u_k^{(l+1)} &= \sum_j w_{kj}^{(l+1)} z_j^{(l)} = \sum_j w_{kj}^{(l+1)} f(u_j^{(l)}) \\ \frac{\partial u_k^{(l+1)}}{\partial u_j^{(l)}} &= w_{kj}^{(l+1)} f'(u_j^{(l)}) \end{aligned}$$

より，

式 2.7 は

$$\delta_j^{(l)} = \sum_k \delta_k^{(l+1)} (w_{kj}^{(l+1)} f'(u_j^{(l)})) \quad (2.9)$$

と変形することができる．

式 2.9 から， $\delta_j^{(l)}$ が $\delta_k^{(l+1)}$ から直接導出できることがわかる．よって，数学的帰納法のように $\delta_j^{(l)}$ を出力層から計算することができ，これが誤差逆伝播の名前の由来である．

また， $u_j^{(l)} = \sum_i w_{ji}^{(l+1)} z_i^{(l-1)}$ より，

$$\frac{\partial u_j^{(l)}}{\partial w_{ji}^{(l)}} = z_i^{(l-1)} \quad (2.10)$$

式 2.6 は，式 2.9 および式 2.10 より

$$\frac{\partial E_n}{\partial w_{ji}^{(l)}} = \delta_j^{(l)} z_i^{(l-1)} \quad (2.11)$$

と表せる．結局， $w_{ji}^{(l)}$ による微分は，ユニット j の $\delta_j^{(l)}$ とユニット i からの出力 $z_i^{(l-1)}$ の積で簡単に計算することができる．

以上の誤差逆伝播の原理によって勾配降下法が可能になり，重み及びバイアスといったパラメタ最適化を行うことができる．

2.4.9 Recurrent Neural Networks

Recurrent Neural Networks(RNN) は深層ニューラルネットワークの一種で主に，系列データの解析に利用される再帰的ネットワークである．具体的には，機械翻訳 [29, 30]，手

書き文字認識 [54, 55], 音声認識 [31, 32], ユーザログ解析 [56], 画像説明文生成 [57, 58], 医療診断 [59, 60] 等の領域で高い性能を発揮することが報告されている。

以下では, RNN の構造の概略及び本研究で用いている RNN の派生ネットワーク Long Short Term Memory Recurrent Networks(LSTM) について説明する。

RNN の構造

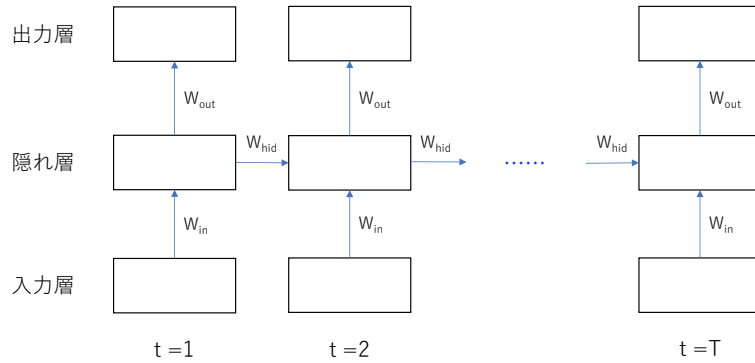


図 2.3: RNN の構造のイメージ

RNN も多層パーセプトロンと基本的な仕組みは同じであり, 図 2.3 のように, 入力層, 隠れ層, 出力層の 3 層から構成されている. 多層パーセプトロンの違いは系列データに対して出力を次のステップの入力に加えるといった再帰的アルゴリズムであるという点である。

系列方向を時刻とすれば, 時刻 t の隠れ層 \mathbf{h}_t の計算に時刻 $t-1$ の隠れ層の情報を入力する $\mathbf{h}_t = f(\mathbf{x}_t, \mathbf{h}_{t-1})$ の式のように, 一つ前の情報を再帰的に入力するという構造である。

$$\mathbf{z}^t = \mathbf{f}(\mathbf{W}^{\text{in}}\mathbf{x}^t + \mathbf{W}\mathbf{z}^{t-1}) \quad (2.12)$$

なお, 関数 f は活性化関数であり, シグモイド関数や \tanh (Hyperbolic Tangent 関数), Relu [61], ELUs [62] など多く提案されており, 通常, 非線形関数である。

活性化関数はシグモイド関数や \tanh (Hyperbolic Tangent 関数), Relu [61], ELUs [62] など多く提案されており, 通常, 非線形関数である.

RNN の 1 つの課題として, 効果的に長期的な表現を学習させることが難しいということが挙げられている [63]. RNN の学習は 2.4.8 項で挙げたような様々な勾配法を用いることができるが, 勾配が発散して学習モデルが壊機能しなくなる勾配爆発 [63, 64] という問題や, 勾配が消滅して対象データの長期的な特徴量を捉えることができないという勾配消滅 [64, 65] という問題がしばしば発生する. こうした問題は通常が多層パーセプトロンでも起こりうることであるが, 特に RNN で問題となるのは, 2.12 式のように再帰的計算を行うことに由来している. 特に, 長い系列データを RNN で学習する場合, 多層パーセプトロンにおいて隠れ層が多層になることと同義であり, 効果的に長期的な表現を学習させることが難しい.

LSTM

こうした問題を解決もしくは緩和するため, ゲート付き活性化関数の利用や学習時の勾配に制約を加える方法が提案されている. その手法の一つとして代表的なものが本論文で提案する手法にも用いられている LSTM である.

なお, 勾配爆発の緩和に対しては, 学習時の勾配に制約を加える方法が有効であり, 具体的には学習させるパラメタの勾配の絶対値に上限閾値を設定することで勾配爆発の影響を緩和する方法 [66] などが提案されている.

以下で, LSTM の原理について説明する.

LSTM は, RNN の中間層の各ユニットをメモリユニットと呼ばれる要素で置き換えたものであり, それ以外の基本的な外部構造は RNN と同じである.




図 2.4: LSTM block

メモリユニットの内部構造は図 2.4²の通りで、下記の式で定義される。

$$\mathbf{i}_t = \sigma(\mathbf{W}_{xi}\mathbf{x}_t + \mathbf{W}_{hi}\mathbf{h}_{t-1} + \mathbf{b}_i) \quad (2.13)$$

$$\mathbf{g}_t = \sigma(\mathbf{W}_{xg}\mathbf{x}_t + \mathbf{W}_{hg}\mathbf{h}_{t-1} + \mathbf{b}_g) \quad (2.14)$$

$$\mathbf{f}_t = \sigma(\mathbf{W}_{xf}\mathbf{x}_t + \mathbf{W}_{hf}\mathbf{h}_{t-1} + \mathbf{b}_f) \quad (2.15)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_{xo}\mathbf{x}_t + \mathbf{W}_{ho}\mathbf{h}_{t-1} + \mathbf{b}_o) \quad (2.16)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \mathbf{g}_t \quad (2.17)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \mathbf{c}_t \quad (2.18)$$

$$\mathbf{y}_t = \sigma(\mathbf{W}_{cy}\mathbf{c}_t + \mathbf{b}_y) \quad (2.19)$$

ここでは、 \mathbf{i}_t は入力ゲートを指し、 \mathbf{f}_t は忘却ゲートを指し、 \mathbf{g}_t はメモリセルへの入力を指し、 \mathbf{o}_t は出力ゲートを指し、 \mathbf{c}_t はメモリセルを指し、 \mathbf{W}_{xi} , \mathbf{W}_{hi} , \mathbf{W}_{xg} , \mathbf{W}_{hg} , \mathbf{W}_{xf} , \mathbf{W}_{hf} , \mathbf{W}_{xo} , \mathbf{W}_{ho} , \mathbf{W}_{cy} はそれぞれ重み行列、 \mathbf{b}_i , \mathbf{b}_g , \mathbf{b}_f , \mathbf{b}_o , \mathbf{b}_y はそれぞれバイアス項を表し、 \odot は要素積を表す。

式 2.17 にあるように、メモリセルへの入力は 1 つ前のメモリセルの状態 \mathbf{c}_{t-1} と入力 \mathbf{g}_t

²引用元: http://wba-initiative.org/wiki/_media/%E6%A9%9F%E6%A2%B0%E5%AD%A6%E7%BF%92/2015greff_lstm_ja.png?cache=

であり、一つ前のメモリの状態を自身に帰還することによって記憶保持を実現している。それぞれの入力に対して、過去のメモリセルからの情報を捨てる忘却ゲートと現在からの情報を調整する入力ゲートを作用させ、 \mathbf{c}_t をえる。新しい隠れ層 \mathbf{h}_t は式 2.18 のようにメモリセルからの出力を出力ゲートで調整したものを入力として受け取る。以上のように、複数のゲートを用いて情報の伝播を調整することによって、短期間の記憶しか実現できないという RNN の短所を補っている。

以上、深層学習について述べた。

2.5 既存手法と提案手法の位置づけ

この節では、以上で述べた関連研究における既存手法と、本研究の提案手法の位置づけを整理することで確認し、明らかにする。既存手法と提案手法の概念関係は以下のとおり。

- 既存手法
 - － 既存の企業価値推定モデル＝経済学的ファンダメンタルアプローチ
 - * アセットアプローチ
 - * マーケットアプローチ
 - * インカムアプローチ
 - － 既存の機械学習によるテクニカルアプローチ
- 提案手法
 - － 複数のアプローチを融合させたアンサンブルモデル
 - * 提案モデルのファンダメンタルアプローチ
 - * 提案モデルのテクニカルアプローチ

これらの手法を、

1. 対象としている現象
2. 入力素性
3. 推定モデル
4. 出力変数

という観点から整理する。なお、

A' = 経済学的ファンダメンタルアプローチ

B' = 既存の機械学習によるテクニカルアプローチ

A = 提案モデルのファンダメンタルアプローチ

B = 提案モデルのテクニカルアプローチ

C = 複数のアプローチ (A, B) を融合させたアンサンブルモデル

と表記すると、以下の表 2.1 ように整理される。

表 2.1: 既存手法と提案手法の分類

手法		対象としている現象			入力素性		推定モデル			出力変数	
		指数	企業の株価		テクニカル	ファンダメンタル	演繹	帰納		トレンド	株価
			上場	非上場				相関あり	相関なし		
既存手法	A'	×	○	○	×	○	○	×	×	×	○
	B'	○	×	×	○	×	×	×	○	○	×
提案手法	A	×	○	×	×	○	×	○	×	○	○
	B	×	○	×	○	×	×	○	×	○	○
	C	×	○	×	○	○	×	○	×	○	○

次の章では、本研究が提案する「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」について述べる。

第3章 提案手法

本章では、「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」について説明する。まず、モデル全体の概要を述べる。その後、提案モデルを構成している各要素のデータとモデルの詳細について説明していく。

3.1 モデル概要

3.1.1 提案モデルの目的

本研究の目的は、証券アナリストの予測が当たらなくなってしまった「証券アナリスト不在」という社会的問題の解決のために、既存の企業価値推定モデルの問題として挙げられる

1. 帰納的推論による目的の最適化に限界があること
2. 複数の手法が孤立していること

を「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」の提案を行うことで解決し、より優れた投資価値評価を行うことである。

1つ目の、帰納的推論による目的の最適化に限界があるという問題は、全企業の時系列データを用いて教師あり機械学習を行うことで、1.1.1項で述べた「帰納的推論に使われるデータサンプル数の限界」及び「ヒトの認知限界」を取り払い解決することができると期待する。具体的には、

- 財務情報を入力素性とした機械学習によるファンダメンタルアプローチ（「提案モデルのファンダメンタルアプローチ」）
- LSTMを用いて企業間の時系列相関を学習したテクニカルアプローチ（「提案モデルのテクニカルアプローチ」）

を全企業の時系列データに適用することで、時間軸・空間軸において十分なデータサンプル数による帰納的推論による予測を行い、また、木構造を用いた情報利得による特徴量

選択や深層学習における重みの更新によって、重要な特徴量を学習の過程で抽出し、「ヒトの認知限界」を解消する。

2つ目の複数の手法が孤立しているという問題に関しては、2.4.4項で述べた「広義のアンサンブルモデル」学習を用いて、複数の異なるアプローチを融合させることによって解決を試みる。

また、2.1.2項で述べたように、証券アナリストの予測としては、今後対象企業の株は買いなのか売りなのか(もしくは中立か)とう分類予測と、株価の適正価格や目標価格はいくらなのかという回帰予測の2種類ある。よって本研究も、分類モデルと回帰モデルの2つを提案し、

分類モデルの場合 将来、対象企業の株価が上がるのか下がるのか

回帰モデルの場合 将来、対象企業の株価はいくらになるのか

を予測する。

3.1.2 モデルの全体像

提案する「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」の概要は図3.1の通り。「提案モデルのテクニカルアプローチ」による分類モデル、「提案モデルのテクニカルアプローチ」による回帰モデル、「提案モデルのファンダメンタルアプローチ」による分類モデル、「提案モデルのファンダメンタルアプローチ」による回帰モデルの4つのモデル(以下ではまとめて「提案モデルの1層目」と呼ぶ)と、それらを融合する最終層の非線形モデル(以下では「提案モデルの最終層」と呼ぶ)によって構成される。提案モデルの最終層は、最終予測が分類問題である場合は分類モデル、回帰問題である場合は回帰モデルを採用する。

「提案モデルのテクニカルアプローチ」の分類モデルによる分類予測、「提案モデルのテクニカルアプローチ」の回帰モデルによる回帰予測、「提案モデルのファンダメンタルアプローチ」の分類モデルによる分類予測、「提案モデルのファンダメンタルアプローチ」の回帰モデルによる回帰予測を、提案モデル最終層の入力素性とし、最終層の分類モデルで分類予測、回帰モデルで回帰予測を行う。通常のアンサンブルモデルであれば、回帰問題であれば構成されるモデルは回帰モデルのみ、分類問題であれば分類モデルのみであることが一般的であるが、

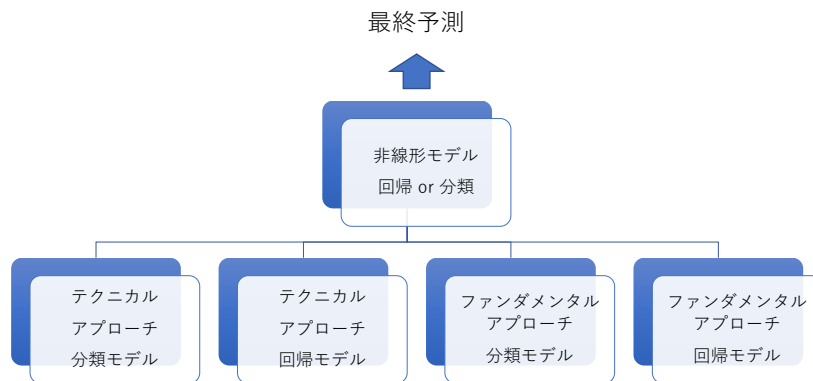


図 3.1: 提案モデル概要

- 本研究は分類・回帰問題双方を扱うので、提案モデルの最終層のモデルを入れ替えるだけで、どちらの予測問題にも簡単に対応できるようにする
- 分類問題においても (変化率の) 回帰予測は有効な特徴量となることが期待される。逆の場合も同じ

といった理由から、分類・回帰モデル双方を提案モデルの1層目に導入した。

さらに、広義のアンサンブルモデルを用いることによって、新たな異なるアプローチを提案モデルの1層目に追加することでモデルの拡張が可能になり、モデルの汎化性能を向上させることが期待できる。例えば、今回の提案モデルはファンダメンタルアプローチとテクニカルアプローチの2つのアプローチを「提案モデルの1層目」に導入しているが、新聞記事の情報を用いて株価予測をする研究 [12] などで提案されているテキストマイニングを行うアプローチによるモデルを、提案モデルの1層目に追加することも可能であり、汎化性能を向上させることが期待できる。

以上、モデルの概要について述べた。次に、モデルを構成している各要素について述べ

ていく.

3.2 「提案モデルのテクニカルアプローチ」のモデル

以下では, 提案モデルを構成している「提案モデルのテクニカルアプローチ」のモデルについて述べる.

3.2.1 予測対象

テクニカルアプローチによる予測対象は,

分類モデル 将来対象株価が上昇するか下降するか

回帰モデル 将来株価の現在株価比の変化率

である. 回帰モデルにおいて, 将来株価でなく変化率を求めるのは, 予測対象を全企業にする際に, 企業ごとに株式発行数が違うことによる株価のスケールの違いを均一にするためである. 機械学習においてスケールの違う値を並列に扱うことは学習の妨げ及び評価の不公平を招くことになる.

3.2.2 入力データ

今回, 予測対象企業に対する市場の時系列相関を学習したいため, 採用するテクニカル指標をすべての企業, 指数に対して計算し, すべての企業, 指数のデータを合算したものを1タイムステップにおける入力データとする. また, 正解データは予測対象企業 M の単一の株価変化率とする. データセットの概要は図 3.2 の通り.

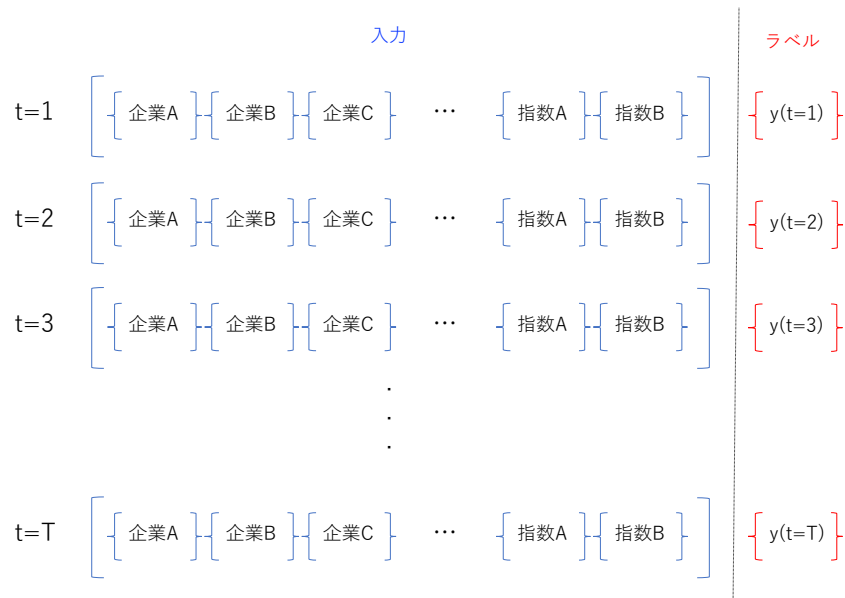


図 3.2: テクニカルアプローチのデータセット

3.2.3 学習器

テクニカル指標の最大の特徴は時系列データであるということである。本研究の効率的市場仮説に対する立場は 2.3.1 項で明らかにした通りであり、将来の株価が現在の情報だけでなく過去から現在における一連の流れで決定しているのであれば、過去の情報を考慮したモデルが必要である。そこで今回、2.4.9 項で説明したように、長期的な時系列データを扱うことが可能である LSTM を学習器として用いる。

また、重要なこととして、時系列データを扱える LSTM を使用することによって、学習の過程で時系列相関を獲得できることが期待される。2.3 節で述べた通り、株価の相関を表すモデルとして β が採用されてきたが、この数式モデルは時系列性を無視した単純な変化率の相関を導き出しているに過ぎない。一方で、LSTM の学習の過程によって獲得された重みは、「対象企業の株価に過去から現在の各情報がどれだけの影響を与えるか」という指標と捉えることができる。

3.3 「提案モデルのファンダメンタルアプローチ」のモデル

以下では、提案モデルを構成している「提案モデルのファンダメンタルアプローチ」のモデルについて述べる。2.3節で述べたように、既存の株価予測研究のモデルはファンダメンタルアプローチを取り入れたモデルではなかった。今回、全企業のファンダメンタル情報を所得したこと及び予測対象を株主価値にすることによって、企業固有の素性から株価を予測することが可能になる。

3.3.1 モデル概要

提案モデルのファンダメンタルアプローチ」のモデルの概要は以下の図3.3通り。「財務情報を取得・データベース化するシステム」を構築し、企業活動情報をXBRLファイル取得、解析することでデータベース化する。そして、取得したデータセットに対してXGBoostを用いて特徴量ごとの重要度を計算し、それに基づいて特徴量抽出を行う。特徴量抽出によって次元削減された特徴量を用いて複数の学習器を学習させ、各学習器の予測を用いてXGBoostを学習・予測をする「広義のアンサンブルモデル」を構築する。

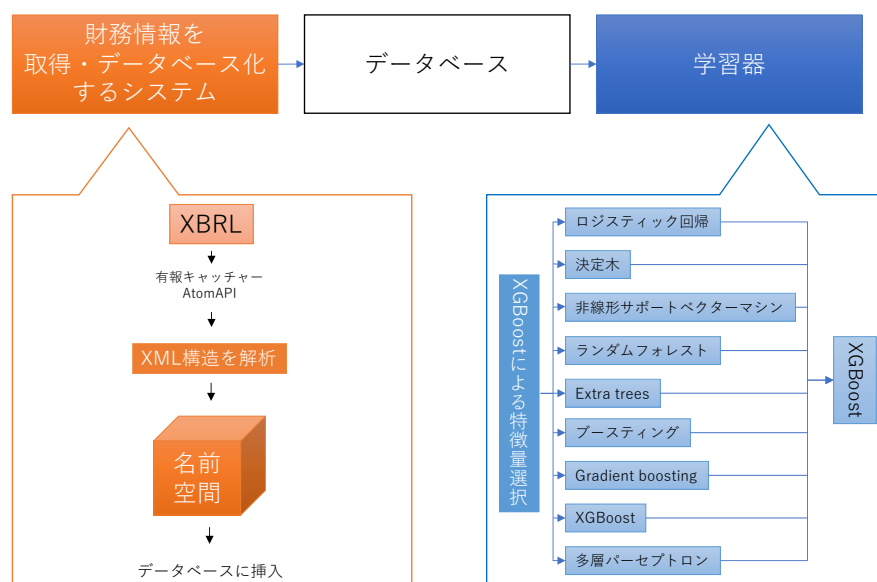


図 3.3: 「提案モデルのファンダメンタルアプローチ」のモデル概要

以下、「提案モデルのファンダメンタルアプローチ」のモデルの各要素について説明する。

3.3.2 予測対象

「提案モデルのファンダメンタルアプローチ」のモデルによる予測対象は、

分類モデル 将来対象企業の株主価値が上昇するか下降するか

回帰モデル 将来の対象企業の株価の株主価値

である。回帰モデルにおいて、将来株価でなく株主価値を予測対象とするのは、

- 企業ごとに株式発行数が違うことによる株価のスケールの違いを均一にする
- 企業ごとの財務情報の比較を可能にし、並列予測を可能にする

という意味があり、このモデルにおいて重要である。

また、回帰予測の場合、モデルは平均誤差率で評価するため、最適化問題としては株価の絶対値ではなく平均誤差率を最小化するようなモデルを構築する必要がある。よって、「提案モデルのファンダメンタルアプローチ」のモデルは損失関数に誤差率を用いる。今回、「提案モデルのファンダメンタルアプローチ」のモデルでは、計算コストを抑えるため、誤差率の代わりに対数差分を用いる。テーラー展開の1次近似より

$$\log(\hat{y}_i) - \log(y_i) = \log\left(\frac{\hat{y}_i}{y_i}\right) = \log\left(1 + \frac{\hat{y}_i - y_i}{y_i}\right) \approx \frac{\hat{y}_i - y_i}{y_i}$$

が成立するので、株価・株主価値の対数差分を損失関数に用いることは、実質的に誤差率を最小化していることになる。

3.3.3 財務情報を取得・データベース化するシステム

企業ごとの株価などのテクニカル指標は、多くの場合データベース化されており、インターネットからも簡単に取得できる。一方で、企業のファンダメンタル情報は、情報を一括したデータベースが一般的に公開されておらず、自らデータベース化するシステムを構築する必要がある。

XBRL(eXtensible Business Reporting Language) ファイルとは、財務諸表などのビジネスレポートをXMLの企画をベースとして電子書籍化されたものである。本研究では、

XBRL ファイルを利用することによってすべての企業のビジネスレポートをデータベース化するシステムを構築した。

システム概要は以下の通り。

1. 有報キャッチャー AtomAPI¹ を利用して過去の企業の XBRL ファイルをダウンロード
2. 金融庁が公開しているタクソノミ要素リスト²を元に、各要素の名前空間を作成する
3. 作成した名前空間を元に、XML ファイルを解析し、データベースにデータを挿入する

なお、名前空間を定義、作成する際に、

- 連結情報か非連結情報か
- XBRL ファイルの規格がか旧規格か新規格か
- 対象期間が通期か、特定事業会社第二四半期/中間期か、四半期か

といった場合分けが必要となることに注意しなければならない。

本研究で提案するモデルは、タクソノミ要素リストで定義されている要素のうち、決算短信、損益決算書、貸借対照表、キャッシュフロー表に含まれるものをすべてを入力素性の対象とする。

本研究は、企業を横断的に分析するために全ての企業のデータを取得する必要がある。決算短信に含まれる財務情報をデータベース化する本システムは不可欠である。また、本研究以外にも利用可能であり、汎用性の高いものでもある。

3.3.4 特徴量選択

前年度比の特徴量データなどを加えると、特徴量の次元が 3000 以上になる。このままの特徴量を、例えばロジスティック回帰のような学習器の入力にすると、学習器が複雑さ故に過学習を起こしやすくなってしまう。「提案モデルのファンダメンタルアプローチ」のモデルでは、特徴量選択による次元削減を行う。2.4 節で述べたように、決定木による重要度抽出を XGBoost を用いて行い、重要度が高いものの特徴量を選択することで次元削減を試み、ファンダメンタル指標の中から市場価格決定要因を抽出する。

¹有報キャッチャー AtomAPI: <http://resource.ufocatch.com/>

²タクソノミ要素リスト: <http://www.fsa.go.jp/search/20160314.html>

3.3.5 学習器

四半期ごとに公開されるファンダメンタル情報も、長期的な期間において時系列データである。よって、LSTMのような時系列性を考慮したモデルを扱うことが望ましい。しかし、四半期ごとのデータであるため、系列長が短く、LSTMのようなモデルではうまく学習できない。そこで、LSTMのような再帰的モデルでなく、前年比を特徴量に加えることで時系列的特徴を保ちながら、静的な学習器を用いて予測を行うことで予測を行う。

具体的には、2.4節で述べたロジスティック回帰、決定木、非線形サポートベクターマシン、バギング、ランダムフォレスト、Extra Trees、ブースティング、Gradient boosting, XGBoost, 多層パーセプトロンを用いる。

まず、整形、選択が行われた特徴量を、ロジスティック回帰、決定木、非線形サポートベクターマシン、バギング、ランダムフォレスト、Extra Trees、ブースティング、Gradient boosting, XGBoost, 多層パーセプトロンに入力し、学習及び予測を行う。

そして、各学習器の予測を新たなXGBoostの入力とすることによって、広義のアンサンブルモデルを構築する。そうして構築された広義のアンサンブルモデルによってなされた予測を、「提案モデルのファンダメンタルアプローチ」のモデルによる予測とする。

2.4節でも述べたように、「提案モデルのファンダメンタルアプローチ」のモデルとしても広義のアンサンブルモデルを使用することによって、汎化性能を高めることが期待される。汎化性能を向上させるだけでなく、モデルの選択の恣意性の排除や拡張性の確保も広義のアンサンブルモデルを使用する狙いである。

以上、「提案モデルのファンダメンタルアプローチ」のモデルについて述べた。

3.4 提案モデル最終層

提案モデル最終層は、複数のアプローチを融合することを可能にする重要な層であり、今まで独立していた既存研究の異なるアプローチを結びつけ体系立てられる可能性を持つ。

例えば、株式評価における経済学的従来手法はアセットアプローチ、マーケットアプローチ、インカムアプローチと主に3つのファンダメンタルアプローチがあることをすでに2.2節で述べたが、これらのような複数のアプローチを組み合わせる具体的な方法は整理されておらず、恣意的で経験を頼りにした手法である場合が多い。

しかし、複数のアプローチによる予測を入力データとする非線形学習器を用いた広義のアンサンブルモデルによって、これらのアプローチを融合したモデルを構築することがで

きる。今まで独立していた提案手法を、関連づけ、汎化性能が高いモデルを構築できる可能性がある。

本研究では、提案モデルの最終層に XGBoost を使用する。XGBoost を使用する理由は、

- 非線形モデルを使用することによって、アプローチ間における非線形関係を表現できる
- 決定木を用いたアルゴリズムであるため、特徴量の重要度を情報利得から計算することができ、最終的にどのアプローチがどれだけ予測値に寄与しているかということが指標化できる

といったことがある。

具体的な最終層の学習器の入力データは、

分類問題の場合

1. 「提案モデルのテクニカルアプローチ」の分類モデルによる分類予測
2. 「提案モデルのテクニカルアプローチ」の回帰モデルによる変化率の回帰予測
3. 「提案モデルのファンダメンタルアプローチ」の分類モデルによる分類予測
4. 「提案モデルのファンダメンタルアプローチ」の回帰モデルによる回帰予測と予測時点での時価総額から計算される変化率

回帰問題の場合

1. 「提案モデルのテクニカルアプローチ」の分類モデルによる分類予測
2. 「提案モデルのテクニカルアプローチ」の回帰モデルによる変化率の回帰予測
3. 「提案モデルのファンダメンタルアプローチ」の分類モデルによる分類予測
4. 「提案モデルのファンダメンタルアプローチ」の回帰モデルによる回帰予測
5. 予測時点での時価総額

とする。

以上、「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」について述べた。

次章では、検証実験について述べる。

第4章 検証実験

本章では、検証実験について述べる。

検証実験の主たる目的は、本論文で提案する「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」が既存の企業価値推定モデルの潜在的問題を解決し、既存手法より有用性のあるモデルであるということを示すことである。またその過程で、新たな知見を獲得することを期待する。

そこで、本研究では、1.2 節でも述べた通り、以下の4つを検証する。

検証 1 機械学習によってファンダメンタルアプローチを実現することで、既存の経済学的なファンダメンタルアプローチの抱える問題を解決し、より優れた予測を行えるということ

検証 2 LSTM を用いることで、市場との時系列相関を学習しより高い精度を実現できるということ

検証 3 機械学習によるファンダメンタルアプローチとテクニカルアプローチの優位性は予測期間・問題によって異なること

検証 4 アンサンブルモデルによって複数のアプローチを融合させたより汎化性能が高くかつ拡張性のあるモデルが実現できること

まず、経済学的ファンダメンタルアプローチを全企業に対して行い、評価を行う。またその過程で、インカムアプローチの一つである DCF 法をいくつかのパターンを試すことで、DCF 法が機能しなくなっている原因を探る。

次に、既存の機械学習的株価予測手法を行い、精度評価を行う。そうして、

1. 経済学的ファンダメンタルアプローチ
2. 既存の機械学習を用いたテクニカルアプローチの株価予測手法

の2つをベースラインに設定する。

そして、本研究の提案モデルを構成する「提案モデルのファンダメンタルアプローチ」のモデルを評価し、経済学的ファンダメンタルアプローチによるベースラインと比較することで、「機械学習によってファンダメンタルアプローチを実現することで、既存の経済学的なファンダメンタルアプローチの抱える問題を解決し、より優れた予測を行えるということ」を検証する。

次に、本研究の提案モデルを構成する「提案モデルのテクニカルアプローチ」のモデルを検証し、既存の機械学習を用いたテクニカルアプローチの株価予測手法によるベースラインと比較することで「LSTMを用いることで、市場との時系列相関を学習しより高い精度を実現できるということ」を検証する。

そうして、本研究の最終的な提案モデルを用いて、「機械学習の手法においてもファンダメンタル分析とテクニカル分析の優位性が予測期間によって異なることということ」を検証し、複数のアプローチを柔軟に融合させるモデルが必要であることを確認する。

最後に、提案モデルを評価し、「アンサンブルモデルによって複数のアプローチを融合させたより汎化性能が高くかつ拡張性のあるモデルが実現できること」を検証する。

以下でその検証方法を詳細に述べる。

4.1 検証実験の設定

4.1.1 予測対象

まず、予測対象について議論する。

本研究では、3.3節で述べたようにファンダメンタル情報として決算短信情報を用いている。株価などのテクニカル指標は毎時更新される情報であるのに対し、決算短信情報は最大でも年4回しか更新されない。(今回の検証実験では決算短信修正などは考慮しない) によって、ファンダメンタルアプローチによるモデルの検証において、ファンダメンタル情報がどれだけ株価予測に寄与するかということを正確に評価するため、各企業の決算短信が発表された翌日からの株価を予測する必要がある。さらに、検証において、できるだけ市場のランダム要素を排除するため、予測対象を「将来の平均株価」とする。

また、「機械学習の手法においてもファンダメンタル分析とテクニカル分析の優位性が予測期間によって異なることということ」を検証するため、異なる予測期間に対して検証を行う。証券アナリストの予測においても、3ヶ月後、半年後、1年後の投資価値評価を行うことは一般的であり、特に、決算短信が出てから次の決算短信が出るまで約60営業日(約3ヶ月)あること、また1年が約240営業日であることを踏まえて、予測対象期間を60営業日、240営業日の2つについて検証する。

まとめると、以下の2つを予測対象として検証実験を行う。

1. 各企業の決算短信発表翌日から営業日時60日間の日足の終値の平均
2. 各企業の決算短信発表翌日から営業日時240日間の日足の終値の平均

4.1.2 検証期間

検証実験としての公平性を保ちつつ、かつ学習のための十分なデータセットを確保するために、検証する期間は、2013年第1四半期から2014年第4四半期までの8四半期とする。

4.1.3 評価基準

本研究の提案モデル及びそのベースラインなどの複数の手法を、以下の評価指標で評価する。

分類予測の場合

対象企業における正解率 (Accuracy)、正の適合率 (Precision)、正の再現率 (Recall)、正の F-measure(F 値)、負の適合率、負の再現率、負の F-measure

回帰予測の場合

対象企業における平均誤差率、誤差率の標準偏差

そして、各手法を以上の指数のうち分類予測ならば正解率で、回帰予測ならば平均誤差率で比較を行い、モデルの性能の優劣を検証する。

4.1.4 対象企業

検証の対象となる企業は、基本的に検証期間に上場している日本企業全てである。しかし、計算時間の制約から、全期間において全企業の検証をすることは難しい場合もあるこ

とを考慮し、検証事項によっては日経平均株価を構成する 225 銘柄 (2016 年 4 月時点) を対象として評価、比較を行う。

4.1.5 ハイパーパラメタの取り扱い方

ハイパーパラメタとは、機械学習の手法の内部で最適化することのできないパラメタであり、外部で指定する必要がある変数のことを言う。例えばサポートベクターマシンのペナルティー項、決定木の深さ、狭義のアンサンブルモデルにおける弱学習器の数、深層学習における隠れ層のノードの数などであり、様々である。さらに言えば、広義のアンサンブルモデルにおいて、一層目に採用する学習器の選択も外部で最適化すべき事項であり、ハイパーパラメタと同概念であるとも言えるかもしれない。

機械学習におけるハイパーパラメタは、データセットを

train dataset 学習に用いるデータセット

validation dataset 学習経過の観察やパラメタ調整などを行い、学習機をより優れたモデルにするための仮検証用データセット

test dataset 最終的に作成した学習器を評価するデータセット

の 3 つに分けた時、train dataset で学習したモデルを validation dataset を用いて最適化することが一般的である。

ハイパーパラメタの基本的な最適化方法 (ハイパーパラメタサーチと呼ぶ) は以下のとおり。

1. 学習用データセットを、ランダムに N 分割し、 i 番目のデータセットを validation dataset、残りの $n - 1$ 個のデータセットを train dataset とする。
2. 学習器のハイパーパラメタの組み合わせを用意する。(例: SVM のとき $\{[C = 1, \gamma = 0.01], [C = 10, \gamma = 0.1] \dots\}$)
3. ハイパーパラメタのすべての組み合わせ対して、以下を実行する。
 - (a) 以下を $i=1, 2, 3 \dots N$ で繰り返す。
 - i. train dataset で学習器を学習させる

ii. validation dataset を用いて評価する

(b) N 個の評価を平均し，与えたれたハイパーパラメタの評価とする．

4. ハイパーパラメタの組み合わせごとに得られた評価に基づき，最も良い評価のハイパーパラメタの組み合わせを学習器の最終的なハイパーパラメタと設定する．

ハイパーパラメタを最適化することによって，モデルの精度を向上させることが期待できる．

しかし，ハイパーパラメタの最適化には多大な計算コストがかかる．検証実験の場合は特に，多くのパターンのハイパーパラメタの最適化を行う必要があり，全てのパターンを最適化することは現実的に難しい．結局，ハイパーパラメタの最適化と検証実験の妥当性は計算時間という制約の中ではトレードオフの関係にある．

そこで本研究では，計算コストが低い場合はハイパーパラメタの最適化を行うが，計算コストが高い場合は，検証実験の妥当性を著しく損なわない範囲で恣意的なハイパーパラメタを選択することとする．

4.2 既存の経済学的ファンダメンタルアプローチの評価

経済学的ファンダメンタルアプローチは，2.2節で述べた通り，アセットアプローチ，マーケットアプローチ，インカムアプローチの3つがある．今回，それぞれのアプローチとして，具体的に

アセットアプローチ = 簿価純資産法

マーケットアプローチ = 市場株価法

インカムアプローチ = DCF 法

を用いて検証する．

なお，経済学的ファンダメンタルアプローチの予測としては，これら3つの単純平均を用いることとする．

アセットアプローチ

アセットアプローチでは、簿価純資産法を用いて検証する。簿価純資産法は、2.2 節で述べた通り、貸借対照表に計上されている資産・負債に粉飾・誤謬 (例えば、減価償却の不足分など) 等の修正を加え、資産から負債を控除した純資産額をもって株式評価する方法であり、今回は簡単のため、

$$\text{純資産額} = \text{株主価値}$$

として評価する。

マーケットアプローチ

マーケットアプローチでは 2.2 節で述べた市場株価法を用いて検証する。今回の検証実験においては、直近営業日 60 日間の終値平均を用いる。なお、2.2.4 項で述べた通り、このアプローチは予測というよりもむしろ現在評価を行なっているにすぎないということに留意する必要がある。

インカムアプローチ

インカムアプローチでは、DCF 法を用いて検証する。DCF は、2.2 節で述べたように、将来キャッシュフローをリスク等を勘案した割引率によって現在価値に割り引いた金額を評価額とする評価方法で、ファイナンス理論に最も忠実であり実務的に様々な場面で利用されているものである。今回の検証実験では、四半期ごとのフリーキャッシュフローに対して割引率を適応することで評価を行う。なお、割引率には最も一般的である WACC(資本コスト)を採用し、WACC の算出は CAPM [21] に基づいて導出する。

DCF 法の具体的な計算は以下の通り。

1. WACC の計算

(a) 負債コスト R_d を計算する

$$R_d = \frac{\text{支払利息}}{[(\text{期首有利子負債} + \text{期末有利子負債})/2]}$$

(b) 株主資本コスト R_e を CAPM に基づいて計算する

$$R_e = R_f + \beta_{A, Index}(R_m - R_f)$$

where R_f = リスクフリーレート (日本国債の10年利回り), R_m = 市場全体の投資利回り

$$\beta(A, Index) = \frac{\frac{1}{n} \sum_{t=1}^T (\Delta A_t - \mu_{\Delta A})(\Delta Index_t - \mu_{\Delta Index})}{\sigma_{\Delta Index}}$$

ただし, $\Delta A_t, \Delta Index_t$ は時点 t における変化率, $\mu_{\Delta A}, \mu_{\Delta Index}$ は $t = 1 \sim T$ における平均値, $\sigma_{\Delta Index}$ は $t = 1 \sim T$ における標準偏差である.

(c) WACC を計算する

$$WACC = R_e \times \frac{E}{D + E} + R_d \times (1 - T) \times \frac{D}{D + E}$$

where D = 有利子負債, E = 株主資本, T = 実効税率 (0.3)

2. フリーキャッシュフロー (FCF) の計算

$$FCF = \text{営業キャッシュフロー} - \text{投資キャッシュフロー}$$

3. FCF を WACC を用いて現在価値に割りもどし, 総和を「企業価値」とする. 将来フリーキャッシュフローに関しては, 未来のフリーキャッシュフローは現在のフリーキャッシュフローと同じであるという定額モデルの場合

$$\text{企業価値} = \lim_{n \rightarrow \infty} \sum_{k=1}^n FCF \times \left(\frac{1}{1 + WACC} \right)^{\frac{k}{4}}$$

4. 「企業価値」に非事業用資産を足したのち, 有利子負債を差し引いたものを株主価値とする

$$\text{株主価値} = \text{企業価値} + \text{非事業用資産} - \text{有利子負債}$$

今回の検証実験において, DCF 法を以下の3パターンに分けて検証する.

$R_m = 0.00044$ とするパターン

2010-01-01 2016-01-01 に置ける TOPIX の変化率の平均から定義どうりの計算によって導かれる市場期待収益率を採用する

$R_d = 0.05$, $R_m = 0.1$ と変更したパターン

近年のマイナス金利や市場期待収益率の低下といった時代による市場の変化を考慮せず, 過去の金利や市場期待収益率を用いたパターン

$R_d = 0.05$, $R_m = 0.1$ とした上, 未来の FCF を既知として計算するパターン

FCF 予測は非常に難しく恣意的である．本来ならば未知である未来の FCF の値を 4 期分参照し，FCF の未来予測として用いて計算するパターン．企業価値の計算の式を以下に変更する．

$$\text{企業価値} = \sum_{t=1}^4 FCF_t \left(\frac{1}{1+WACC} \right)^{\frac{t}{4}} + \lim_{n \rightarrow \infty} \sum_{t=5}^n FCF_4 \times \left(\frac{1}{1+WACC} \right)^{\frac{t}{4}}$$

一つ目のパターンは，一般的な DCF 法の定義式である．2 つ目のパターンは，昨今マイナス金利など特殊な市場に DCF 法が対応していない可能性を考慮し，以前の金利及び市場期待収益率を用いた場合を検証する．3 つ目のパターンは，DCF 法の難点として

- 未来の FCF 予測が難しくかつ恣意的であるということ
- 成長率を企業ごとに定義することがむずがしくかつ恣意的であること

が挙げられるが，将来 FCF を既知として DCF 法を実行することによって，その問題点を仮想的に解決する．そうして得られた予測というのは，FCF の予測困難性を排除したという点において，成長率を考慮しない定額モデル DCF 法の理論限界予測といえることができる．それぞれ，上から順番にパターン 1，パターン 2，パターン 3 と呼ぶことにする．

以上のような 3 つのパターンを検証することによって，DCF 法が株式市場において機能していないとされる原因を考察する．

最終予測

経済学的ファンダメンタルアプローチの最終的な予測は，

回帰問題の場合

3 つのアプローチの単純平均を計算し，現在の株主価値との比較において単純平均が上であれば上昇予測，下であれば下降予測

運動の第二法則

3 つのアプローチの単純平均

とし，予測値が現在値から $\pm 100\%$ 以上離れている場合は，予測値を $\pm 100\%$ に制限したものとする．これは，特にインカムアプローチの DCF 法では，無限等比数列を計算するため，割引率の計算や将来フリーキャッシュフローの予測値によって大きく値が変動してしまい，評価することが困難になってしまうことを懸念するためである．

そうして，4.1.3 項に基づいて評価する．

4.3 既存の機械学習を用いたテクニカルアプローチの評価

既存の機械学習を用いたテクニカルアプローチの評価を行う目的は、「LSTMを用いることで、市場との時系列相関を学習しより高い精度を実現できるということ」を検証するためのベースラインを知ることである。

既存の機械学習を用いたテクニカルアプローチは2.3節で述べた通り様々な手法が提案されているが、検証実験における正当性を確保するため、既存の機械学習を用いたテクニカルアプローチとしてLSTMを採用する。そして、提案モデルを構成する「テクニカルアプローチのモデル」との違いは、入力データが全企業のテクニカル指標ではなく、単一企業のテクニカル指標のみとすることである。

検証対象は計算時間の制限から日経平均構成銘柄 225 企業の営業 60 日間平均の予測とし、それぞれの企業に対して LSTM 学習器を作成し、予測を出力する。

検証方法の概要は以下のとおり。

1. データセットの作成
2. ハイパーパラメタの調整
3. 日経平均構成銘柄 225 企業の学習器をそれぞれ作成
4. 日経平均構成銘柄 225 企業の予測を学習器を用いて出力
5. 日経平均構成銘柄 225 企業で評価

具体的な検証方法は以下で述べる。

4.3.1 データの性質と前処理

検証実験では企業ごとの始値、高値、安値、終値、出来高はロイターのデータを使用する。

テクニカル指標

テクニカルアプローチは、株価や出来高などのテクニカル分析指標を元に株価やそのトレンドを予測するアプローチであり、多くの指標が提案されている。指標の選択には多く

の議論の余地が残るが，本研究における検証実験という観点から，テクニカル指標の選択は意味を持たないため，提案モデルは表 4.1 に記載されている基本的な指標を使用する．

表 4.1: 採用するテクニカル指標一覧

テクニカル指標	式	概要
$ROC_0(c, x)$	$\frac{x_t}{ct} \quad x_t = [s_t, h_t, l_t]$	終値に対する始値, 高値, 安値の割合
$ROC_k(c)$	$\frac{c_t}{c_{t-k}} \quad k = 1, 5, 20, 60, 120, 240, 360, 720$	k ステップ前からの 終値変化率
$ROC_k(v)$	$\frac{v_t}{v_{t-k}} \quad k = 5, 20, 60, 120, 360$	k ステップ前からの 出来高変化率
$Disparity_k(c)$	$\frac{c_t}{\frac{1}{k} \sum_{i=t-k+1}^t c_i} \quad k = 5, 25, 75$	終値の k ステップ 移動平均乖離率
$RSI_k(c)$	$1 - \frac{1}{1 + \left(\frac{\sum_{i=t-k+1}^t U_{t-i}}{\sum_{i=t-k+1}^t D_{t-i}} \right)}$ $\text{where } U_t = \begin{cases} 1, & c_t - c_{t-1} > 0 \\ 0, & c_t - c_{t-1} \leq 0 \end{cases}$ $\text{where } D_t = \begin{cases} 1, & c_t - c_{t-1} < 0 \\ 0, & c_t - c_{t-1} \geq 0 \end{cases}$	k ステップで値上が りしたステップの 割合 $k = 14, 20, 60$
$GC_{k,l}(c)$	$\begin{cases} 1, & a_t(k) - a_t(l) > 0 \text{ \& } a_{t-1}(k) - a_{t-1}(l) \geq 0 \\ 0, & \text{otherwise} \end{cases}$ $\text{where } k < l, \quad a_t(k) = \frac{1}{k} \sum_{i=t-k+1}^t c_i$	ゴールデนคร ス $(k, l) = (5, 25), (25, 75)$
$DC_{k,l}(c)$	$\begin{cases} 1, & a_t(k) - a_t(l) < 0 \text{ \& } a_{t-1}(k) - a_{t-1}(l) \leq 0 \\ 0, & \text{otherwise} \end{cases}$ $\text{where } k < l, \quad a_t(k) = \frac{1}{k} \sum_{i=t-k+1}^t c_i$	デットクロス $(k, l) = (5, 25), (25, 75)$

データセット作成

学習及び検証に用いるデータ区間は、予測対象期間における対象企業の決算短信開示日から前5年間とする。

そして今回、週足データをデータセットの1タイムステップとし、LSTMの入力データを30ステップとする。

データセットは、

train dataset

学習に用いるデータセット

validation dataset

学習経過の観察やパラメタ調整などを行い、学習機をより優れたモデルにするための仮検証用データセット

test dataset

最終的に作成した学習器を評価するデータセット

の3つに分ける。

ここで注意しなければならないのは、4.1節で述べたように予測対象が

1. 各企業の決算短信発表翌日から営業日時60日間の日足の終値の平均
2. 各企業の決算短信発表翌日から営業日時240日間の日足の終値の平均

であるため、正解データは入力データより60営業日または240営業日先の情報を含んでいるということである。機械学習に限ったことではないが、通常予測を立てるモデルを構築する際に未来情報を与えてはいけない。よって、train dataset と validation dataset はデータ区間5年間のうち、60営業日または240営業日を後ろから取り除いたものとする必要がある。なお、本来であればtrain dataset と validation dataset の関係も以上の注意点を考慮した関係であることが望ましいが、本研究の検証の場合予測対象の期間が60営業日または240営業日と長いことから学習に十分なデータセットが用意しにくいこと、及びvalidation dataset の割合が5% ありかつ1タイプステップが週足(約5営業日)であり、パラメタ最適化に十分な未来情報が含まれていないデータセットが存在していることなどから、train dataset は60営業日または240営業日を後ろから取り除いたもののうち前95%、

validation dataset は後ろ 5% としても, validation dataset の役割を果たせると判断しそのようにデータを分割した.

なお, test dataset は, データセットの最後の 30 ステップとする.

データセットの正規化

データセットを作成したのち, 特徴量ごとに次元やスケールが異なることは機械学習の妨げになるため, 各特徴量ごとに正規化を行う. 本研究の提案モデルにおいては以下の正規化方法を用いた.

$$f(x_i) = \frac{x_i - \bar{x}}{\sigma_x}$$

なお, \bar{x} は x 全体の平均, σ_x は x の標準偏差である.

以上の正規化によって, すべての特徴量が平均 0, 分散 1 になり, 特徴量ごとの次元やスケールが一律になり, 学習がうまく行えるようになる.

4.3.2 ハイパーパラメタの調整

LSTM の学習は計算コストが高く, ハイパーパラメタの扱いは 4.1.5 で述べた通りとする. 本研究で, LSTM を用いる際の主なハイパーパラメタは以下のとおり.

- 隠れ層のノード数:200
- 入力層のドロップアウト率:0.05
- 隠れ層のドロップアウト率:0.15
- 出力層の活性化関数:[分類問題:softmax, 回帰問題:linear]
- 学習率:0.00001
- 最適化法:RMSprop
- 損失関数:[分類問題:categorical cross entropy, 回帰問題:mean squared error]
- early stopping:[対象:validation loss, patience:15]

日経平均構成銘柄 225 企業の学習器をそれぞれ作成, 予測を出力

日経平均構成銘柄 225 企業において, 企業ごとに LSTM 学習器を定義し, train dataset, validation dataset を用いて学習, test dataset を用いて予測を行う.

日経平均構成銘柄 225 企業で評価

日経平均構成銘柄 225 企業において、予測対象期間が営業 60 日間平均のものについて 4.1.3 項に基づき評価を行う。

4.4 「提案モデルのテクニカルアプローチ」のモデルの評価

3.2 節で述べた「提案モデルのテクニカルアプローチ」のモデルの検証を行う。基本的な検証方法は 4.3 節で述べた既存の機械学習を用いたテクニカルアプローチの評価と同じである。唯一の違いは、対象企業と市場との相関を学習するために、入力データに他企業のテクニカル指標を追加している点である。

「提案モデルのテクニカルアプローチ」のモデルの評価をしたのち、4.3 節で述べた既存の機械学習によるテクニカルアプローチのモデルと比較することで、「LSTM を用いることで、市場との時系列相関を学習しより高い精度を実現できるということ」を検証する。

なお、以後 4.7 説で述べる「提案モデルの検証」においても、この「提案モデルのテクニカルアプローチ」のモデルによる予測結果を用いることが望ましい。しかし、「提案モデルのテクニカルアプローチ」のモデルは全企業のテクニカル指標を入力データとする LSTM ネットワークであり、計算コストが非常に大きい上、提案モデルでは全企業の LSTM モデルが必要となるため、様々な検証を行うのは非現実的である。そこで今回、「提案モデルのテクニカルアプローチ」のモデルの代替モデルとして、全企業のテクニカル指標の代わりに指数 [TOPIX, 日経平均 225, マザーズ, JSD] のテクニカル指標と予測対象企業 A との $\beta_{A, Index}$ を入力データとし、さらに 100 企業をランダムサンプリングした上で重ねて学習したモデルを用意する。こうしてできたモデルを「提案モデルのテクニカルアプローチ」の代替モデルと呼ぶ。

具体的な「提案モデルのテクニカルアプローチ」の代替モデル作成方法は以下の通り。

1. LSTM ネットワークを定義する
2. 全企業の中から、ランダムに 100 企業選ぶ
3. $i=1,2,3,\dots,100$ として、以下を繰り返す
 - (a) LSTM のネットワークの重みを更新せずに、以前の重みを用いる。
 - (b) 企業 i と、TOPIX, 日経平均 225, マザーズ, JSD 指数の β を求める。

(c) 企業 i , TOPIX, 日経平均 225, マザーズ, JSD 指数のテクニカル指標及び計算した β を入力データとする

(d) 入力データを用いて LSTM ネットワークに学習させる

「提案モデルのテクニカルアプローチ」の代替モデルは、すべての企業の株価が同様のモデルによって表現されるという仮定を本来必要としているが、検証実験の妥当性の確保のため、検証実験においてはこの仮定が成り立つものとして議論を進める。

4.5 「提案モデルのファンダメンタルアプローチ」のモデルの検証

3.3 節で述べた「提案モデルのファンダメンタルアプローチ」のモデルの検証を行う。検証方法の概要は以下のとおり。

1. データセットの前処理
2. ハイパーパラメタの調整
3. モデルを作成
4. 上場企業全体及び日経平均 225 構成銘柄企業で評価

4.5.1 データセットの前処理

特徴量追加

取得したデータのうち、損益決算書、キャッシュフロー表、及び決算短信の一部に含まれるデータは、四半期ごとの独立したデータでなく、年度内の累計データである。そこで、四半期ごとのデータを並列して対等に扱うため、累計値から四半期ごとの値を逆算する形で求め、修正する。

一般的に、ファンダメンタル情報は前年比を計算し比較する。そこで今回も、同様に前年比を計算し、特徴量として追加する。

さらに、yahoo finance¹から、業種分類、設立年月日、市場名、上場年月日、従業員数(単独)、従業員数(連結)、単元株数、平均年齢、平均年収といった企業情報を取得、特徴量として追加する。なお、上場年月日、設立記念日などは現在時刻との差分を計算することによって経過時間を割り出し、特徴量として追加する。

¹<http://finance.yahoo.co.jp/>

また、表 4.2 に記されているファンダメンタル指標を、取得したデータから計算し、特徴量として追加する。なお、以下のファンダメンタル指標は、四半期ごとに計算されるものであり、証券会社などによって一般に公開されている年間における指標とは異なることに注意する必要がある。

表 4.2: 採用するファンダメンタル指標一覧

ファンダメンタル指標	式	概要
<i>PER</i>	$\frac{\text{時価総額}}{\text{当期純利益}}$	株価収益率
<i>EPS</i>	$\frac{\text{純利益}}{\text{発行済株式総数}}$	一株あたりの利益
<i>BPS</i>	$\frac{\text{株主資本}}{\text{発行済株式総数}}$	一株あたりの株主資本
<i>PBR</i>	$\frac{\text{現在株価}}{BPS}$	株価純資産倍率
配当利回り	$\frac{\text{一株あたりの配当}}{\text{株価}} \times 100$	株価に対する年間配当金の割合を示す指標
<i>ROE</i>	$\frac{EPS}{BPS}$	自己資本利益率
<i>ROA</i>	$\frac{\text{純利益}}{\text{総資産}}$	総資産利益率
自己資本比率	$\frac{\text{総資産} - \text{負債}}{\text{総資産}} \times 100$	自己資本が総資産を占める割合
有利子負債自己資本比率	$\frac{\text{有利子負債}}{\text{自己資本}} \times 100$	有利子負債が自己資本を占める割合
<i>EV</i>	時価総額 + 有利子負債 - 貯金	貸貸貸借表から導かれる企業価値
<i>EBITDA</i>	営業利益 + 減価償却費	利払い前・税引き前・減価償却前・その他償却前利益
<i>EV/EBITDA</i>	$\frac{EV}{EBITDA} \times 100$	簡易買収倍率、企業の割安性を測る指標
流動比率	$\frac{\text{流動資産}}{\text{流動負債}} \times 100$	企業の短期的な支払能力を判断する指標
当座比率	$\frac{\text{当座資産}}{\text{流動負債}} \times 100$	企業の短期の負債に対する支払い能力を判断する指標

以上の作業によって、最終的な特徴量は、

- 業界などの基本的な企業情報
- 財務諸表から得られたデータ
- 財務指標から計算される前年度比
- ファンダメンタル指標

によって構成される。

データセットの整形

財務諸表から得られたファンダメンタル指標のデータの性質として、欠損値が多いこと、またデータに外れ値が多いことが挙げられる。欠損値及び外れ値は、統計的な計算をする機械学習にとって学習及び評価の妨げになる。そこで検証実験では、以下のような処理を行う。

欠損値の補完

全企業の財務諸表を扱う都合上、期間によっては財務諸表が取得できない場合や、取得できない要素が存在している場合もある。そうした欠損値を補うために、本モデルでは、欠損値が発見された場合、以前の値を現在から近い順に参照するという補完方法をとる。もし以前に参照できる値がなければ、0で補完する。

外れ値の置換

外れ値は、特にニューラルネットワークのような学習器の学習の妨げになる。そこで、本モデルでは、特徴量ごとの標準偏差を計算し、値が $\mu \pm 5\sigma$ (*where* μ = 平均, σ = 標準偏差) の範囲に値が収まるよう以下のような置換をする。

$$x_i = \begin{cases} \mu + 5\sigma & \text{if } \mu + 5\sigma \leq x_i \\ \mu - 5\sigma & \text{if } x_i \leq \mu - 5\sigma \\ x_i & \text{otherwise} \end{cases}$$

正規化

特徴量ごとの次元及びスケールを揃える。

$$f(x_i) = \frac{x_i - \bar{x}}{\sigma_x}$$

データセットの分割

本項では3.3節で述べた「提案モデルのファンダメンタルアプローチ」のモデルの学習及びハイパーパラメタの最適化、及び2層目の学習、予測に用いるためのデータセットの分割方法について述べる。

まず、以下のデータセットを用意する。

- 予測対象期間の1期前から5年分(20期)のデータセット
- 予測対象期間の1期分のデータセット

前者を「提案モデルのファンダメンタルアプローチ」のモデルの作成に用いる train dataset, 後者を提案モデルの「ファンダメンタルアプローチのモデル」の評価に用いる test dataset とする。

そして、train dataset をさらに以下のようにランダムサンプリングによって2等分割する。

- 1層目の学習器(ロジスティック回帰, 決定木, 非線形サポートベクターマシン, バギング, ランダムフォレスト, Extra Trees, ブースティング, Gradient boosting, XGBoost, 多層パーセプトロン)の学習及びハイパーパラメタの最適化に用いるデータセット
- 2層目の学習器(XGBoost)の学習及びハイパーパラメタの最適化に用いるデータセット

前者を train first dataset, 後者を train second dataset とする。

なお、今回、ファンダメンタル情報のデータセットの時系列性を考慮しないモデルであるため、ハイパーパラメタの最適化において train dataset の時系列性を保持する必要がないと仮定できる。よって、train dataset のデータセットから時系列性を排除するようにランダムサンプリングによって train first dataset, train second dataset を作成する。なお、train dataset と test dataset の関係は、未来情報が train dataset に入り込まないように注意しなければならないことは「提案モデルのテクニカルアプローチ」のモデルの検証と同じである。

4.5.2 ハイパーパラメタの調整

「提案モデルのファンダメンタルアプローチ」のモデルにおいて、用いる学習器のハイパーパラメタの最適化を行う。最適化方法は4.1.5項で述べた基本的な手法に加えて、勾

配降下法を用いて評価の高いハイパーパラメタの値の周辺を重点的に調べる hyperopt²というアルゴリズムを用いて最適化を行う。なお、本研究においては、多層パーセプトロンは計算コストが高いため、LSTM 同様ハイパーパラメタの最適化は行わない。また、ハイパーパラメタ名は、python パッケージである scikit-learn³に基づくものとし、以下で記載されていないハイパーパラメタは scikit-learn のデフォルト値とする。

探索する学習器とハイパーパラメタの範囲は以下のとおり。

- ロジスティック回帰
 - $C : [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]$
 - $penalty : [“l1”, “l2”]$
- 決定木
 - $max_depth : [2, 3, 4, 5, 6, 7, 8, 9, 10]$
- 非線形サポートベクターマシン
 - $kernel : [“rbf”]$
 - $C : [1, 10, 100]$
 - $gamma : [0.001, 0.005, 0.01]$
- バギング
 - $n_estimators : [100, 110, 120, 130, 140, 150, 160, 170, 180, 190, 200]$
- ランダムフォレスト
 - $n_estimators : [100, 110, 120, 130, 140, 150, 160, 170, 180, 190, 200]$
- Extra trees
 - $n_estimators : [100, 110, 120, 130, 140, 150, 160, 170, 180, 190, 200]$
- Adaboost
 - $n_estimators : [100, 110, 120, 130, 140, 150, 160, 170, 180, 190, 200]$

²url: <https://github.com/hyperopt/hyperopt>

³url: <http://scikit-learn.org/stable/>

- Gradient boosting
 - *n_estimators* : [100, 110, 120, 130, 140, 150, 160, 170, 180, 190, 200]
- XGBoost
 - *max_depth* : [2, 3, 4, 5, 6, 7, 8, 9, 10]
 - *sub_samples* : [0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0]
 - *n_estimators* : [100, 110, 120, 130, 140, 150, 160, 170, 180, 190, 200]
 - *colsample_bytree* : [0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0]

また、多層パーセプトロンのハイパーパラメタの設定は以下の通り。

- 多層パーセプトロン
 - 入力層のノード数:100
 - 隠れ層のノード数:200
 - ドロップアウト率:0.2
 - 入力及び隠れ層の活性化関数:relu
 - 出力層の活性化関数: [分類問題:softmax, 回帰問題:relu]
 - 学習率:0.002
 - 最適化法:Nadam
 - 損失関数:分類問題:categorical cross entropy, 回帰問題:mean squared error
 - early stopping:対象:validation loss, patience:10

4.5.3 モデルの作成

以下の手順で「提案モデルのファンダメンタルアプローチ」のモデルを作成する。

1. train first dataset を用いてハイパーパラメタの調整を行う。
2. train first dataset と調整したハイパーパラメタを用いて1層目の学習器層目の学習器(ロジスティック回帰, 決定木, 非線形サポートベクターマシン, バギング, ランダムフォレスト, Extra Trees, Adaboost, Gradient boosting, XGBoost, 多層パーセプトロン)を作成する

3. 作成した一層目の学習器を用いて、train second dataset による予測をそれぞれの学習器ごとに出力する。これらの出力を予測データセットとする。
4. 出力した予測データセットを用いて2層目の XGBoost のハイパーパラメタの調整を行う。
5. 調整したハイパーパラメタと予測データセットを用いて2層目の XGBoost を学習させる。

上場企業全体及び日経平均 225 構成銘柄企業で評価

作成したモデルを用いて、test dataset によって予測の出力、評価を行う。

そして、既存の経済学的ファンダメンタルアプローチの評価と比較することによって、「機械学習の手法をとることによって既存の経済学的なファンダメンタルアプローチの抱える問題を解決し、提案モデルがより優れた予測を行えるということ」を検証する。

4.6 ファンダメンタル分析とテクニカル分析の優位性の検証

3.4 節で述べた提案モデルの検証において、2.4 節や 3.4 節で述べたように、学習した XGBoost から各特徴量の重要度を抽出することができる。

- 「提案モデルのテクニカルアプローチ」の代替分類モデルによる分類予測
- 「提案モデルのテクニカルアプローチ」の代替回帰モデルによる回帰予測
- 「提案モデルのファンダメンタルアプローチ」の分類モデルによる分類予測
- 「提案モデルのファンダメンタルアプローチ」の回帰モデルによる回帰予測

の重要度を予測対象期間ごとに抽出し、テクニカルアプローチの重要度の和とファンダメンタルアプローチの重要度の和を計算することで、「機械学習によるファンダメンタルアプローチとテクニカルアプローチの優位性は予測期間・問題によって異なること」を検証する。

4.7 提案モデルの検証

提案モデルの精度検証

3.4 節で述べた提案モデルの精度検証を行う。「提案モデルのテクニカルアプローチ」のモデルと、「提案モデルのファンダメンタルアプローチ」のモデルの予測結果を用いて、提案モデルの最終層の XGBoost のパラメタ最適化及び学習、評価を行う。なお、4.4 節で述べたように、計算時間の制約から、「提案モデルのテクニカルアプローチ」のモデルの代わりに「提案モデルのテクニカルアプローチ」代替モデルを用いる。

評価方法は以下のとおり。

1. 4.1.2 項で述べた検証期間における、2013 年第 1 四半期から 2014 年第 4 四半期の「提案モデルのテクニカルアプローチ」の代替モデル及び「提案モデルのファンダメンタルアプローチ」のモデルの分類、回帰予測をそれぞれ行い、3.4 節で述べたように入力用の予測データセットを作成する。
2. 予測データセットのうち、予測対象期間のものを test dataset、残りを train dataset とする
3. train dataset をシャッフルし、データセットを 5 分割する 4.1.5 項で述べたハイパーパラメタサーチを行い、最終層の XGBoost のハイパーパラメタを最適化する
4. 最適化されたハイパーパラメタと test dataset を用いて最終層の XGBoost を学習する
5. 学習した最終層の XGBoost を用いて test dataset で予測・評価を行う。この評価を提案モデルの上場企業全体の評価とする。

こうして得られた評価と、「提案モデルのファンダメンタルアプローチ」のモデル、「提案モデルのテクニカルアプローチ」の代替モデルの評価を比較することによって、「アンサンブルモデルによって複数のアプローチを融合させたより汎化性能が高くかつ拡張性のあるモデルが実現できること」を検証する。

実用性の評価

機械学習を用いた株価予測に関する既存研究の多くは、ベースラインとして既存の株価予測手法を採用し、比較することでモデルの優位性を示すものである。しかし、予測手法

の真の評価は、常に市場との比較によってなされるべきである。

例えば分類問題であれば、提案手法の正解率が7割であったとしても、それは真に優れたモデルであるかは保証できない。というのも、正解データの分布が偏っており、8割が上昇するという分布である場合、全て上昇するという予測を出力するモデルの方がより優れているという結果になってしまうからだ。また、回帰問題であれば、例えば予測平均誤差が3%でも、予測対象と現在値の平均変化率が1%であれば、現在値を予測結果とする極めて単純なモデルの方が優れているということになる。

真に市場を表現し予測することができるモデルであるか否かは、実用面において重要であり、また2.3.1項で述べたように、真に市場を表現し予測することができるモデルの存在は、効率的市場仮説の反例を示していることになる。

よって今回、

分類予測の場合

予測対象企業全体において、実際に株価が上昇する企業数と下降する企業数の全体に占める割合の高い方

回帰予測の場合

予測対象企業において、予測時点での時価総額からの変化率の平均

を「真のベースライン」とする。例えば先ほどの例であれば、分類問題であればベースラインは0.7、回帰問題であれば0.01ということになる。

そうして、「真のベースライン」と提案モデルの精度を比較し、提案モデルがどれだけの実用的な予測精度があるのか、また真に市場を表現し予測することができるモデルであるかどうかを検証する。

以上、検証実験について述べた。

次章では、結果について述べる。

第5章 検証実験結果

本章では，検証実験の結果について述べる．示す結果は以下のとおり．

1. 既存の経済学的ファンダメンタルアプローチの評価結果
2. 「提案モデルのファンダメンタルアプローチ」のモデルの評価及び既存の経済学的ファンダメンタルアプローチの評価との比較結果
3. 「提案モデルのテクニカルアプローチ」のモデルの評価及び既存の機械学習を用いたテクニカルアプローチの評価との比較結果
4. ファンダメンタル分析とテクニカル分析の優位性の検証結果
5. 提案モデルの評価結果

5.1 既存の経済学的ファンダメンタルアプローチの評価結果

アセットアプローチ，マーケットアプローチ，インカムアプローチの予測精度は以下の5.1 項，5.1 項，5.1 項とおり．

アセットアプローチの評価結果

表 5.1: アセットアプローチの評価結果

検証期間	予測対象	平均誤差 (%)	誤差の標準偏差 (%)
2013_1	営業 60 日間平均	53.50	34.17
	営業 240 日間平均	51.43	33.35
2013_2	営業 60 日間平均	50.86	33.20
	営業 240 日間平均	50.20	33.10
2013_3	営業 60 日間平均	50.64	33.16
	営業 240 日間平均	49.79	32.81
2013_4	営業 60 日間平均	50.76	32.91
	営業 240 日間平均	49.22	31.77
2014_1	営業 60 日間平均	49.20	31.87
	営業 240 日間平均	47.44	30.74
2014_2	営業 60 日間平均	48.87	31.93
	営業 240 日間平均	47.89	31.39
2014_3	営業 60 日間平均	47.65	31.03
	営業 240 日間平均	47.91	30.99
2014_4	営業 60 日間平均	47.54	30.67
	営業 240 日間平均	49.09	31.08

マーケットアプローチの評価結果

表 5.2: マーケットアプローチの評価結果

検証期間	予測対象	平均誤差 (%)	誤差の標準偏差 (%)
2013_1	営業 60 日間平均	12.17	19.59
	営業 240 日間平均	19.20	24.70
2013_2	営業 60 日間平均	14.29	21.69
	営業 240 日間平均	19.17	24.23
2013_3	営業 60 日間平均	11.01	16.37
	営業 240 日間平均	15.84	19.26
2013_4	営業 60 日間平均	10.39	15.53
	営業 240 日間平均	17.34	19.18
2014_1	営業 60 日間平均	9.44	11.38
	営業 240 日間平均	16.99	14.94
2014_2	営業 60 日間平均	9.27	10.23
	営業 240 日間平均	15.50	13.33
2014_3	営業 60 日間平均	10.39	15.53
	営業 240 日間平均	14.53	14.27
2014_4	営業 60 日間平均	9.60	11.43
	営業 240 日間平均	16.10	16.64

インカムアプローチの評価結果

4.2 で述べた通り、インカムアプローチでは DCF 法を採用し、そして

1. $R_m = 0.00044$ とするパターン 1
2. $R_d = 0.05$, $R_m = 0.1$ と変更したしたパターン 2
3. $R_d = 0.05$, $R_m = 0.1$ とした上、未来の FCF を既知として計算するパターン 3

の 3 パターンにおいて検証した。結果は表 5.3 と表 5.4 のとおり。

表 5.3: インカムアプローチの評価結果 1

検証期間	予測対象	パターン	平均誤差 (%)	誤差の標準偏差 (%)
2013_1	営業 60 日間平均	1	99.09	6.57
		2	92.25	20.92
		3	92.91	20.10
	営業 240 日間平均	1	99.28	6.56
		2	92.47	20.84
		3	95.32	16.29
2013_2	営業 60 日間平均	1	99.28	7.49
		2	89.80	24.45
		3	84.01	26.15
	営業 240 日間平均	1	99.31	7.23
		2	91.31	22.79
		3	83.68	29.45
2013_3	営業 60 日間平均	1	99.44	5.74
		2	91.85	21.73
		3	83.04	26.18
	営業 240 日間平均	1	99.32	6.50
		2	90.87	22.84
		3	81.77	30.66
2013_4	営業 60 日間平均	1	96.60	14.39
		2	90.55	23.12
		3	82.65	23.92
	営業 240 日間平均	1	99.18	6.95
		2	90.18	23.92
		3	73.79	33.25

表 5.4: インカムアプローチの評価結果 2

検証期間	予測対象	パターン	平均誤差 (%)	誤差の標準偏差 (%)
2014_1	営業 60 日間平均	1	96.57	15.25
		2	90.25	23.66
		3	83.73	23.99
	営業 240 日間平均	1	99.74	4.13
		2	90.61	23.63
		3	74.87	32.72
2014_2	営業 60 日間平均	1	96.46	14.97
		2	89.72	24.09
		3	86.46	21.52
	営業 240 日間平均	1	99.64	4.88
		2	90.27	23.59
		3	74.41	32.58
2014_3	営業 60 日間平均	1	95.86	16.25
		2	88.12	25.85
		3	91.09	16.37
	営業 240 日間平均	1	99.40	6.31
		2	89.73	24.22
		3	75.11	32.01
2014_4	営業 60 日間平均	1	96.79	14.43
		2	96.10	15.49
		3	74.24	32.05
	営業 240 日間平均	1	99.40	6.15
		2	89.56	24.36
		3	73.79	32.33

なおインカムアプローチでは、4.2 節で述べた通り、予測範囲を現在値の $\pm 100\%$ に制限していることに留意する必要がある。

以上の結果から、インカムアプローチではほとんどの予測が現在値から $\pm 100\%$ 以上異なる予測を行い、そして結果として大きく予測が外れていることがわかる。また、パター

ン1, パターン2, パターン3の比較によって, ほとんどの検証期間の平均誤差において

$$\text{パターン1} > \text{パターン2} > \text{パターン3}$$

となっていることがわかる.

パターン1とパターン2の比較から, 近年の特異な市場期待収益率及び金利が原因で, DCF法における割引率が低くなってしまい, 予測精度が下がっており, DCF法のモデルが時代の変化に対応できていないと推測することができる.

パターン2とパターン3の比較から, やはりDCF法において将来キャッシュフローを予測することが難しく, DCF法における欠点となっていることが確認された.

既存の経済学的ファンダメンタルアプローチの評価結果

以上3つのアプローチの予測の単純平均を求めることで, 既存の経済学的ファンダメンタルアプローチの評価結果とし, また提案モデルを構成する「ファンダメンタルアプローチのモデル」と比較するベースラインとする.

既存の経済学的ファンダメンタルアプローチの分類予測の評価結果は表5.5と表5.6のとおり.

表 5.5: 既存の経済学的ファンダメンタルアプローチの分類予測の評価結果 (正例)

検証期間	予測対象	正解率 (%)	適合率 (%)	再現率 (%)	F 値 (%)
2013.1	営業 60 日間平均	50.46	67.71	23.91	35.35
	営業 240 日間平均	46.57	77.07	29.01	42.15
2013.2	営業 60 日間平均	45.51	73.60	26.34	38.79
	営業 240 日間平均	54.43	69.13	47.57	56.36
2013.3	営業 60 日間平均	56.43	44.13	23.97	31.06
	営業 240 日間平均	52.37	67.54	47.96	56.09
2013.4	営業 60 日間平均	42.92	75.43	26.33	39.04
	営業 240 日間平均	60.58	82.75	61.79	70.75
2014.1	営業 60 日間平均	52.23	58.50	21.73	31.69
	営業 240 日間平均	53.88	74.67	53.97	62.66
2014.2	営業 60 日間平均	40.51	70.38	17.47	27.99
	営業 240 日間平均	53.04	77.81	52.28	62.54
2014.3	営業 60 日間平均	34.97	84.15	15.12	25.63
	営業 240 日間平均	52.61	67.42	48.16	56.19
2014.4	営業 60 日間平均	52.28	64.17	47.72	54.74
	営業 240 日間平均	54.23	43.57	46.87	45.16

表 5.6: 既存の経済学的ファンダメンタルアプローチの分類予測の評価結果 (負例)

検証期間	予測対象	正解率 (%)	適合率 (%)	再現率 (%)	F 値 (%)
2013.1	営業 60 日間平均	50.46	46.14	85.11	59.84
	営業 240 日間平均	46.57	36.26	82.40	50.36
2013.2	営業 60 日間平均	45.51	36.90	82.01	50.90
	営業 240 日間平均	54.43	43.53	65.55	52.32
2013.3	営業 60 日間平均	56.43	59.95	78.95	68.15
	営業 240 日間平均	52.37	39.95	60.03	47.97
2013.4	営業 60 日間平均	42.92	32.53	80.54	46.34
	営業 240 日間平均	60.58	30.44	56.48	39.56
2014.1	営業 60 日間平均	52.23	50.76	83.96	63.27
	営業 240 日間平均	53.88	31.53	53.66	39.72
2014.2	営業 60 日間平均	40.51	34.64	85.61	49.32
	営業 240 日間平均	53.04	27.88	55.31	37.07
2014.3	営業 60 日間平均	34.97	27.42	91.85	42.23
	営業 240 日間平均	52.61	40.46	60.21	48.40
2014.4	営業 60 日間平均	52.28	42.57	59.25	49.54
	営業 240 日間平均	54.23	62.36	59.19	60.73

既存の経済学的ファンダメンタルアプローチの回帰予測の評価結果は表 5.7 とおり.

表 5.7: 既存の経済学的ファンダメンタルアプローチの回帰予測の評価結果

検証期間	予測対象	平均誤差 (%)	誤差の標準偏差 (%)
2013_1	営業 60 日間平均	29.96	23.85
	営業 240 日間平均	32.39	26.29
2013_2	営業 60 日間平均	30.32	25.58
	営業 240 日間平均	31.64	27.15
2013_3	営業 60 日間平均	26.92	23.41
	営業 240 日間平均	30.30	26.37
2013_4	営業 60 日間平均	28.50	23.92
	営業 240 日間平均	29.53	26.53
2014_1	営業 60 日間平均	28.70	23.36
	営業 240 日間平均	29.15	25.02
2014_2	営業 60 日間平均	28.83	22.68
	営業 240 日間平均	27.80	24.50
2014_3	営業 60 日間平均	32.53	23.96
	営業 240 日間平均	29.17	25.01
2014_4	営業 60 日間平均	28.06	24.15
	営業 240 日間平均	28.46	25.72

5.2 既存の経済学的ファンダメンタルアプローチの評価と「提案モデルのファンダメンタルアプローチ」のモデルの評価の比較結果

まず「提案モデルのファンダメンタルアプローチ」のモデルの評価を示す。そして、5.1節で示した経済学的ファンダメンタルアプローチの評価結果と比較する。

「提案モデルのファンダメンタルアプローチ」のモデルの評価結果

提案モデルの「ファンダメンタルアプローチのモデル」の分類予測の評価結果は表 5.8 及び表 5.9 とおり。

表 5.8: 提案モデルの「ファンダメンタルアプローチのモデル」の分類予測の評価結果 (正例)

検証期間	予測対象	正解率	適合率	再現率	F 値
2013_1	営業 60 日間平均	0.5302	0.6152	0.4112	0.4929
	営業 240 日間平均	0.6963	0.7131	0.9018	0.7964
2013_2	営業 60 日間平均	0.5965	0.6968	0.6867	0.6917
	営業 240 日間平均	0.6792	0.6813	0.9129	0.7803
2013_3	営業 60 日間平均	0.4780	0.4245	0.7893	0.5521
	営業 240 日間平均	0.6896	0.7191	0.8331	0.7719
2013_4	営業 60 日間平均	0.6354	0.7240	0.7639	0.7434
	営業 240 日間平均	0.7470	0.8193	0.8616	0.8399
2014_1	営業 60 日間平均	0.5595	0.5474	0.8381	0.6623
	営業 240 日間平均	0.7059	0.7420	0.9059	0.8158
2014_2	営業 60 日間平均	0.6466	0.6916	0.8464	0.7612
	営業 240 日間平均	0.7421	0.7859	0.9111	0.8439
2014_3	営業 60 日間平均	0.6788	0.7632	0.8263	0.7935
	営業 240 日間平均	0.6544	0.6636	0.9225	0.7719
2014_4	営業 60 日間平均	0.5956	0.6246	0.8470	0.7190
	営業 240 日間平均	0.5335	0.4591	0.8489	0.5960

表 5.9: 提案モデルの「ファンダメンタルアプローチのモデル」の分類予測の評価結果 (負例)

検証期間	予測対象	正解率	適合率	再現率	F 値
2013_1	営業 60 日間平均	0.5302	0.4801	0.6789	0.5624
	営業 240 日間平均	0.6963	0.6120	0.2992	0.4019
2013_2	営業 60 日間平均	0.5965	0.4106	0.4221	0.4163
	営業 240 日間平均	0.6792	0.6683	0.2912	0.4056
2013_3	営業 60 日間平均	0.4780	0.6454	0.2639	0.3746
	営業 240 日間平均	0.6896	0.6098	0.4448	0.5144
2013_4	営業 60 日間平均	0.6354	0.3962	0.3473	0.3702
	営業 240 日間平均	0.7470	0.4380	0.3620	0.3964
2014_1	営業 60 日間平均	0.5595	0.6044	0.2631	0.3666
	営業 240 日間平均	0.7059	0.4481	0.1952	0.2719
2014_2	営業 60 日間平均	0.6466	0.4486	0.2488	0.3201
	営業 240 日間平均	0.7421	0.3978	0.1912	0.2583
2014_3	営業 60 日間平均	0.6788	0.3225	0.2439	0.2777
	営業 240 日間平均	0.6544	0.5859	0.1900	0.2869
2014_4	営業 60 日間平均	0.5956	0.4561	0.2014	0.2794
	営業 240 日間平均	0.5335	0.7557	0.3185	0.4481

提案モデルの「ファンダメンタルアプローチのモデル」の回帰予測の評価結果は表 5.10 のとおり。

表 5.10: 提案モデルの「ファンダメンタルアプローチのモデル」の回帰予測の評価結果

検証期間	予測対象	平均誤差 (%)	誤差の標準偏差 (%)
2013_1	営業 60 日間平均	14.52	157.82
	営業 240 日間平均	19.31	103.14
2013_2	営業 60 日間平均	11.21	74.43
	営業 240 日間平均	15.25	35.00
2013_3	営業 60 日間平均	25.55	251.99
	営業 240 日間平均	22.50	172.10
2013_4	営業 60 日間平均	11.84	73.26
	営業 240 日間平均	16.00	55.21
2014_1	営業 60 日間平均	9.64	12.94
	営業 240 日間平均	15.36	18.29
2014_2	営業 60 日間平均	8.73	8.44
	営業 240 日間平均	13.25	12.21
2014_3	営業 60 日間平均	9.07	9.07
	営業 240 日間平均	13.48	14.40
2014_4	営業 60 日間平均	8.55	9.02
	営業 240 日間平均	16.32	17.04

重要な特徴量

3.3 節で述べたように、ファンダメンタルアプローチのモデルでは XGBoost を用いて特徴量重要度を抽出し、特徴量選択を行なっている。

よって、ファンダメンタルアプローチにおいてどのファンダメンタル指標が予測に有効であるかを知ることができる。今回、検証期間の中でも 2014 年の第 4 四半期のファンダメンタルアプローチにおける重要な特徴量を、分類・回帰予測に分けて上位 50 個を表 5.11, 表 5.12, 表 5.13, 5.14 に示す。

表 5.11: 2014 年第 4 四半期・営業 60 日平均の分類予測におけるファンダメンタル指標重要度

順位	項目	順位	項目
1	会員権評価損	26	投資有価証券評価損
2	配当利回り	27	前年比法人税等
3	PBR	28	前年比売上総利益又は売上総損失
4	税引前当期純利益又は税引前当期純損失	29	前年比その他収入
5	前年比税引前当期純利益又は税引前当期純損失	30	前年比販売費及び一般管理費
6	EV/EBIDDA	31	PER
7	法人税等	32	前年比有形固定資産
8	前年比その他有価証券評価差額金	33	設立からの経過時間
9	前年比営業外費用	34	前年比たな卸資産の増減額
10	ROA	35	売上債権の増減額
11	持分法適用会社に対する持分相当額	36	その他費用
12	株価	37	従業員数
13	特別損失	38	繰延ヘッジ損益
14	前年比その他有価証券評価差額金	39	繰延税金資産
15	前年比その他の包括利益	40	前年比減価償却費
16	前年比当期純利益又は当期純損失	41	賞与引当金の増減額
17	前年比経常利益又は経常損失	42	前年比仕入債務の増減額
18	前年比為替差損	43	仕入債務の増減額
19	売上原価	44	前年比未払法人税等
20	その他流動負債	45	EV
21	前年比包括利益	46	前年比財務活動によるキャッシュ・フロー
22	前年比営業外収益	47	前年比買掛金
23	前年比売上高	48	為替換算調整勘定
24	前年比その他貸付金	49	前年比為替換算調整勘定
25	その他収入	50	法人税等調整額

表 5.12: 2014 年第 4 四半期・営業 60 日平均の回帰予測におけるファンダメンタル指標重要度

順位	項目	順位	項目
1	EV	26	自己株式
2	連結総従業員数	27	経常利益又は経常損失
3	株価	28	資本剰余金
4	株式発行数	29	前年比支払手形及び買掛金
5	PER	30	法人税等
6	PBR	31	当座比率
7	従業員数	32	敷金
8	BPS	33	破産更生債権等
9	有利子負債自己資本比率	34	電気機器の企業
10	未払法人税等	35	前年比現金及び預金
11	設立からの経過時間	36	前年比税引前当期純利益又は税引前当期純損失
12	短期借入金	37	給料及び賞与
13	陸運企業	38	現金及び現金同等物に係る換算差額
14	上場からの経過時間	39	EPS
15	包括利益	40	有価証券
16	東証一部か	41	貸倒引当金
17	配当利回り	42	営業利益又は営業損失
18	為替換算調整勘定	43	為替差益
19	その他金融企業	44	前年比法人税，住民税及び事業税
20	EV/EBIDDA	45	繰延税金負債
21	資産	46	法人税等の支払額
22	EBIDDA	47	利息及び配当金の受取額
23	その他有価証券評価差額金	48	利息の支払額
24	前年比貸倒引当金	49	固定資産圧縮損
25	長期借入金	50	投資有価証券

表 5.13: 2014 年第 4 四半期・営業 240 日平均の分類予測におけるファンダメンタル指標重要度

順位	項目	順位	項目
1	株価	26	たな卸資産の増減額
2	PBR	27	前年比たな卸資産の増減額
3	配当利回り	28	売上債権の増減額
4	前年比その他有価証券評価差額金	29	前年比経常利益又は経常損失
5	前年比受取配当金	30	未払消費税等の増減額
6	前年比貸倒引当金	31	前年比固定資産売却益
7	その他有価証券評価差額金	32	特別利益
8	前年比繰延税金資産	33	その他費用
9	前年比為替換算調整勘定	34	前年比財務活動によるキャッシュ・フロー
10	自己資本比率	35	前年比その他の包括利益
11	EBITDA	36	為替差損益
12	前年比為替換算調整勘定	37	前年比現金及び預金
13	特別損失	38	前年比その他資産
14	前年比包括利益	39	前年比支払利息
15	PER	40	前年比特別損失
16	貸倒引当金	41	前年比退職給付に係る負債
17	前年比売上総利益又は売上総損失	42	賞与引当金の増減額
18	前年比受取手形及び売掛金	43	発行株式数
19	前年比流動資産	44	前年比貸倒引当金
20	前年比負債	45	法人税等
21	前年比セール・アンド・リースバックによる収入	46	売上債権の増減額
22	前年比退職給付に係る負債の増減額	47	前年比その他費用
23	前年比利益剰余金	48	前年比小計
24	EV	49	貸倒引当金
25	従業員数	50	建物

表 5.14: 2014 年第 4 四半期・営業 240 日平均の回帰予測におけるファンダメンタル指標重要度

順位	項目	順位	項目
1	EV	26	流動資産
2	連結総従業員数	27	その他の営業収入
3	株価	28	自己株式
4	株式発行数	29	有利子負債自己資本比率
5	PBR	30	有価証券
6	PER	31	持分法による投資損益
7	従業員数	32	連結の範囲の変更を伴う子会社株式の売却による収入
8	配当利回り	33	営業利益又は営業損失
9	法人税等の支払額	34	建設仮勘定
10	配当金の支払額	35	為替予約
11	資産	36	前年比その他収入
12	資本剰余金	37	前年比為替換算調整勘定
13	不動産の企業	38	新規連結に伴う現金及び現金同等物の増加額
14	株主資本	39	未払法人税等
15	BPS	40	その他権利
16	利益剰余金	41	EV/EBITDA
17	短期借入金	42	繰延税金負債
18	貸倒引当金	43	有形固定資産の売却による収入
19	設立からの経過時間	44	当期純利益又は当期純損失
20	流動比率	45	法人税等調整額
21	前年比その他の包括利益	46	その他の資産・負債の増減額
22	税引前当期純利益又は税引前当期純損失	47	定期預金の増減額
23	前年比為替差益	48	保険積立金
24	長期借入金	49	為替換算調整勘定
25	支払利息	50	減価償却費

表 5.11, 表 5.13 と表 5.12, 表 5.14 の比較から, 分類問題では回帰問題に比べて前年比率がより予測に重要であることがわかる. これは, 分類予測は「変化」を予測する一方, 回帰予測は「株主価値の絶対値」を予測していることから理解できる結果である.

「EV」や「株価」, 「株式発行数」は, 現在の時価総額に関する指標である. 特に回帰予測に関しては, やはり現在の時価総額が将来の時価総額に近い値であり, 将来予測においても現在値を入力変数に加えることは予測精度を向上させるために重要であるようだ. 一

方、「PBR」が分類、回帰予測ともに上位に来ているということは、株主価値(株価)が純資産に近寄って行くという性質が推測できる。つまり、純資産と株主価値の相違が予測において重要であり、アセットアプローチは有意なアプローチであったと言える。

また、「EV」、「借入金」、「支払利息」などは、負債に関わる項目である。既存の企業価値推定モデルでは、 $\text{純資産} = \text{企業価値} - \text{負債}$ 、 $\text{株主価値} = \text{純資産}$ として株主価値を求めており、負債と株主価値を切り離して考えているが、負債に関する項目も株主価値(株価)の決定要因として重要であることが今回抽出された結果からわかる。

「法人税等」、「未払法人税等」など法人税に関わる項目が上位に来ていることも興味深い。会計上の利益は、期間業績の適正化の観点から、実際の値ではなく、必要に応じて費用を見積り計上して計算する。そのためファイナンスの分野では、純利益よりも事実ベースのフリーキャッシュフローを用いて企業価値推定を行うことが基本である。一方、法人税の計算は、法人税法等の規定によって会計計算とは切り離されて別個に行われるのもであり、実際の利益に関する値を反映させているといえることができる。企業を横断的に分析する際に、法人税のに関する項目から企業価値推定を行うことが有用であるという新たな知見が得られた。

また、今まで企業価値推定の入力素性として使われることのなかった「従業員数」や「設立からの経過時間」も特に回帰予測において重要な特徴量であることがわかった。

ベースラインとの比較

「提案モデルのファンダメンタルアプローチ」のモデルとベースラインである既存の経済学的ファンダメンタルアプローチの評価と比較することによって、「機械学習の手法をとることによって既存の経済学的なファンダメンタルアプローチの抱える問題を解決し、提案モデルがより優れた予測を行えるということ」を検証する。

分類予測精度の比較は表 5.15 の通り。

表 5.15: 経済学的ファンダメンタルアプローチと提案モデルの「ファンダメンタルアプローチのモデル」の分類予測の正解率の比較

検証期間	予測対象	経済学的ファンダメンタルアプローチ	提案モデルの「ファンダメンタルアプローチのモデル」
2013.1	営業 60 日間平均	50.4578	0.5302
	営業 240 日間平均	46.5693	0.6963
2013.2	営業 60 日間平均	45.5122	0.5965
	営業 240 日間平均	54.4291	0.6792
2013.3	営業 60 日間平均	56.4313	0.4780
	営業 240 日間平均	52.3716	0.6896
2013.4	営業 60 日間平均	42.9226	0.6354
	営業 240 日間平均	60.5753	0.7470
2014.1	営業 60 日間平均	52.2254	0.5595
	営業 240 日間平均	53.8833	0.7059
2014.2	営業 60 日間平均	40.5106	0.6466
	営業 240 日間平均	53.0373	0.7421
2014.3	営業 60 日間平均	34.9742	0.6788
	営業 240 日間平均	52.6087	0.6544
2014.4	営業 60 日間平均	52.2811	0.5956
	営業 240 日間平均	54.2336	0.5335

回帰予測精度の比較は表 5.16 の通り.

表 5.16: 経済学的ファンダメンタルアプローチと提案モデルの「ファンダメンタルアプローチのモデル」の回帰予測の平均誤差 (%) の比較

検証期間	予測対象	経済学的ファンダメンタルアプローチ	提案モデルの「ファンダメンタルアプローチのモデル」
2013_1	60 日平均	29.96	14.52
	240 日平均	32.39	19.31
2013_2	60 日平均	30.32	11.21
	240 日平均	31.64	15.25
2013_3	60 日平均	26.92	25.55
	240 日平均	30.30	22.50
2013_4	60 日平均	28.50	11.84
	240 日平均	29.53	16.00
2014_1	60 日平均	28.70	9.64
	240 日平均	29.15	15.36
2014_2	60 日平均	28.83	8.73
	240 日平均	27.80	13.25
2014_3	60 日平均	32.53	9.07
	240 日平均	29.17	13.48
2014_4	60 日平均	28.06	8.55
	240 日平均	28.46	16.32

表 5.15 及び表 5.16 の結果をまとめると、

検証1

- 既存の経済学的なファンダメンタルアプローチ = F_{old}
- 提案モデルのファンダメンタルアプローチ = F_{new}

とすると、検証範囲において、

分類予測の場合

$[F_{old}$ の正解率の平均 : 0.5019] < $[F_{new}$ の正解率の平均 : 0.6355]

16 検証パターンのうち 14 検証パターンで F_{new} が上回る

回帰予測の場合

$[F_{old}$ の誤差率の平均 : 29.51%] < $[F_{new}$ の誤差率の平均 : 14.41%]

16 検証パターンのうち 16 検証パターンで F_{new} が上回る

ことから、

[検証1]「機械学習の手法をとることによって既存の経済学的なファンダメンタルアプローチの抱える問題を解決し、提案モデルがより優れた予測を行えるということ」が検証された。

5.3 既存の機械学習を用いたテクニカルアプローチの評価と、「提案モデルのテクニカルアプローチ」のモデルの評価の比較結果

予測対象企業のテクニカル指標のみを入力素性としている既存の機械学習を用いたテクニカルアプローチと、他企業・他企業・指数のテクニカル指標を含めた「提案モデルのテクニカルアプローチ」のモデルの評価比較結果は表 5.17 とおり。

表 5.17: 予測対象が営業 60 日平均における既存の機械学習を用いたテクニカルアプローチと提案モデルの「テクニカルアプローチのモデル」の評価比較 (分類予測:正解率, 回帰予測:平均誤差率)

		既存の機械学習を用いたテクニカルアプローチ	提案モデルのテクニカルアプローチ
2013_1	分類予測	0.4577	0.4776
	回帰予測	0.0923	0.0918
2013_2	分類予測	0.4925	0.5024
	回帰予測	0.0838	0.0863
2013_3	分類予測	0.4752	0.5829
	回帰予測	0.0765	0.0711
2013_4	分類予測	0.5714	0.8199
	回帰予測	0.0821	0.0702
2014_1	分類予測	0.5317	0.5352
	回帰予測	0.0615	0.0585
2014_2	分類予測	0.4000	0.4634
	回帰予測	0.0987	0.0878
2014_3	分類予測	0.5122	0.4146
	回帰予測	0.0881	0.0747
2014_4	分類予測	0.4833	0.4216
	回帰予測	0.0743	0.0879

表 5.17 の結果をまとめると,

検証 2

- 既存の機械学習を用いたテクニカルアプローチ = T_{old}
- 提案モデルのテクニカルアプローチ = T_{new}

とすると、検証範囲において、

分類予測の場合

$$[T_{old} \text{の正解率の平均 : } 0.4905] < [T_{new} \text{の正解率の平均 : } 0.5272]$$

8 検証パターンのうち 6 検証パターンで T_{new} が上回る

回帰予測の場合

$$[T_{old} \text{の誤差率の平均 : } 8.22\%] < [T_{new} \text{の誤差率の平均 : } 7.85\%]$$

8 検証パターンのうち 6 検証パターンで T_{new} が上回る

であるから、自身のテクニカル指標だけでなく、市場のテクニカル指標を加えることは有効であり、

[検証 2] 「LSTM を用いることで、市場との時系列相関を学習しより高い精度を実現できるということ」が検証された。

5.4 ファンダメンタル分析とテクニカル分析の優位性の検証結果

4.6 節で述べた通り検証を行なった結果は表 5.18 の通り。

表 5.18: ファンダメンタルアプローチの重要性が全体に占める割合

検証期間	予測問題	営業 60 日間平均	営業 240 日間平均
2013.1	分類	0.78	0.80
	回帰	0.77	0.94
2013.2	分類	0.80	0.80
	回帰	0.66	0.98
2013.3	分類	0.81	0.77
	回帰	0.68	0.82
2013.4	分類	0.52	0.62
	回帰	0.47	0.83
2014.1	分類	0.63	0.78
	回帰	0.50	0.82
2014.2	分類	0.63	0.61
	回帰	0.55	0.94
2014.3	分類	0.64	0.78
	回帰	0.53	0.99
2014.4	分類	0.65	0.73
	回帰	0.51	0.98

まず、ファンダメンタルアプローチの重要性がテクニカルアプローチの重要性をほとんどの場合で上回っていることがわかる。このことから、指数でなく企業の株価を分析する際、ファンダメンタルアプローチを取り入れることが有効であることが言える。しかし、ファンダメンタルアプローチとテクニカルアプローチの重要度の比は、モデルの性能に依存するため、テクニカルアプローチのモデルが不適切であるという可能性に留意する必要がある。

そして、分類予測と回帰予測の比較を行うと、営業 60 日間平均の予測では分類問題の方が回帰問題に比べてファンダメンタルアプローチの重要性が高いのに対して、営業 240 日間平均の予測では回帰問題の方がファンダメンタルアプローチの重要度が高いことが言える。

さらに、営業 60 日間平均の予測と営業 240 日間平均の予測での比較を行うと、多くの場合でファンダメンタルアプローチの重要性が営業 240 日間平均の予測の方が高いことがわかる。

このことから、より長期的な期間における予測の方がファンダメンタルアプローチが重要であることが示された。

以上の結果より、

検証3

[検証3]「機械学習によるファンダメンタルアプローチとテクニカルアプローチの優位性は予測期間・問題によって異なる」ことが検証された。

また、このことから、予測期間・問題が異なれば、その場合に応じてモデルを構築する必要がある、異なるアプローチを柔軟に融合させることができるモデルが必要であることが確認される。

5.5 提案モデルの評価結果

提案モデルの精度結果

提案モデルの分類予測精度は表 5.19, 表 5.20 の通り。

表 5.19: 提案モデルの分類予測の精度結果 (正例)

検証期間	予測対象	正解率	適合率	再現率	F 値
2013_1	60 日平均	0.5843	0.6031	0.7357	0.6628
	240 日平均	0.7276	0.7600	0.8573	0.8057
2013_2	60 日平均	0.6282	0.7164	0.7216	0.7190
	240 日平均	0.7175	0.7475	0.8265	0.7850
2013_3	60 日平均	0.4780	0.4245	0.7893	0.5521
	240 日平均	0.7636	0.7741	0.8573	0.8248
2013_4	60 日平均	0.6008	0.7699	0.6037	0.6767
	240 日平均	0.7850	0.8362	0.8967	0.8654
2014_1	60 日平均	0.5640	0.5625	0.6911	0.6202
	240 日平均	0.6990	0.7893	0.7928	0.7910
2014_2	60 日平均	0.6083	0.7189	0.6756	0.6966
	240 日平均	0.7359	0.7998	0.8735	0.8350
2014_3	60 日平均	0.6249	0.8046	0.6573	0.7235
	240 日平均	0.6544	0.6636	0.9225	0.7719
2014_4	60 日平均	0.5932	0.6700	0.6575	0.6637
	240 日平均	0.5437	0.4677	0.9118	0.6183

表 5.20: 提案モデルの分類予測の精度結果 (負例)

検証期間	予測対象	正解率	適合率	再現率	F 値
2013_1	営業 60 日間平均	0.5843	0.5450	0.3953	0.4583
	営業 240 日間平均	0.7276	0.6338	0.4770	0.5444
2013_2	営業 60 日間平均	0.6282	0.4540	0.4477	0.4508
	営業 240 日間平均	0.7175	0.6508	0.5367	0.5882
2013_3	営業 60 日間平均	0.494257	0.7292	0.2338	0.3541
	営業 240 日間平均	0.7636	0.7368	0.5606	0.6368
2013_4	営業 60 日間平均	0.6008	0.4001	0.5943	0.4783
	営業 240 日間平均	0.7850	0.5418	0.4103	0.4670
2014_1	営業 60 日間平均	0.5640	0.5664	0.4288	0.4881
	営業 240 日間平均	0.6990	0.4650	0.4597	0.4623
2014_2	営業 60 日間平均	0.6083	0.4237	0.4744	0.4476
	営業 240 日間平均	0.7359	0.5418	0.4103	0.4670
2014_3	営業 60 日間平均	0.6249	0.3436	0.5291	0.4167
	営業 240 日間平均	0.661471	0.578947	0.276201	0.373984
2014_4	営業 60 日間平均	0.5932	0.4783	0.4923	0.4852
	営業 240 日間平均	0.5437	0.8297	0.2929	0.4329

提案モデルの回帰予測精度は表 5.21 の通り.

表 5.21: 提案モデルの回帰予測の平均誤差 (%)

検証期間	予測対象	平均誤差 (%)	誤差の標準偏差 (%)
2013_1	営業 60 日間平均	10.25	20.98
	営業 240 日間平均	18.44	51.87
2013_2	営業 60 日間平均	8.14	11.37
	営業 240 日間平均	14.73	30.31
2013_3	営業 60 日間平均	10.09	14.14
	営業 240 日間平均	17.03	55.94
2013_4	営業 60 日間平均	9.06	14.29
	営業 240 日間平均	14.77	20.69
2014_1	営業 60 日間平均	8.23	9.34
	営業 240 日間平均	13.71	14.65
2014_2	営業 60 日間平均	7.46	7.71
	営業 240 日間平均	12.76	12.07
2014_3	営業 60 日間平均	7.55	7.81
	営業 240 日間平均	12.86	12.56
2014_4	営業 60 日間平均	7.59	7.63
	営業 240 日間平均	15.02	13.85

各アプローチ及び真のベースラインとの比較検証結果

次に、提案モデルの「ファンダメンタルアプローチのモデル」、「テクニカルアプローチのモデルの代替モデル」の評価と比較することによって、「アンサンブルモデルによって複数のアプローチを融合させたより汎化性能が高くかつ拡張性のあるモデルが実現できること」を検証する。また、4.7 節で述べた真のベースラインとの比較により、提案モデルの実用性を評価する。

提案モデルの分類予測精度比較は表 5.22 の通り。

表 5.22: 提案モデルの分類予測の正解率比較

検証期間	予測対象	ファンダメンタルモデル	テクニカルモデル	提案モデル	市場の分布
2013_1	60 日平均	0.5302	0.4835	0.5843	<i>0.5553</i>
	240 日平均	0.6963	0.3830	0.7276	<i>0.6589</i>
2013_2	60 日平均	0.5965	0.5572	0.6282	<i>0.6591</i>
	240 日間平均	0.6792	0.6357	0.7175	<i>0.6241</i>
2013_3	60 日平均	0.4780	0.5484	0.4780	<i>0.5929</i>
	240 日平均	0.6896	0.5017	0.7636	<i>0.6304</i>
2013_4	60 日平均	0.6354	0.7313	0.6008	<i>0.6915</i>
	240 日平均	0.7470	0.6155	0.7850	<i>0.7705</i>
2014_1	60 日平均	0.5595	0.5711	0.5640	<i>0.5152</i>
	240 日平均	0.7059	0.4870	0.6990	<i>0.7186</i>
2014_2	60 日平均	0.6466	0.3560	0.6083	<i>0.6655</i>
	240 日平均	0.7421	0.5963	0.7359	0.7651
2014_3	60 日平均	0.6788	0.3995	0.6249	<i>0.7468</i>
	240 日平均	0.6544	0.5454	0.6615	<i>0.6339</i>
2014_4	60 日平均	0.5956	0.4535	0.5932	<i>0.6106</i>
	240 日平均	0.5335	0.4605	0.5437	<i>0.5947</i>

提案モデルの回帰予測精度比較は表 5.23 の通り。

表 5.23: 提案モデルの回帰予測の平均誤差 (%) 比較

検証期間	予測対象	ファンダメンタルモデル	テクニカルモデル	提案モデル	終値変化率
2013.1	60 日平均	14.52	12.44	10.25	<i>11.58</i>
	240 日平均	19.31	38.80	18.44	<i>23.59</i>
2013.2	60 日平均	11.21	11.54	8.14	<i>8.60</i>
	240 日平均	15.25	20.58	14.73	<i>15.67</i>
2013.3	60 日平均	25.55	9.10	10.09	<i>7.73</i>
	240 日平均	22.50	20.91	17.03	<i>16.75</i>
2013.4	60 日平均	11.84	12.63	9.06	<i>9.63</i>
	240 日平均	16.00	25.70	14.77	<i>22.66</i>
2014.1	60 日平均	9.64	8.24	8.23	<i>8.18</i>
	240 日平均	15.36	16.83	13.71	<i>20.14</i>
2014.2	60 日平均	8.73	7.90	7.46	<i>8.55</i>
	240 日平均	13.25	15.64	12.76	<i>22.26</i>
2014.3	60 日平均	9.07	10.31	7.55	<i>8.87</i>
	240 日平均	13.48	14.11	12.86	<i>18.24</i>
2014.4	60 日平均	8.55	8.36	7.59	<i>8.29</i>
	240 日平均	16.32	14.88	15.02	<i>20.84</i>

表 5.22 及び表 5.23 から,

検証4

- 提案モデルのファンダメンタルアプローチ = F_1
- 提案モデルのテクニカルアプローチ = T_1

とすると、検証範囲において、

分類予測の場合

$[F_1, T_1$ の正解率の平均 : 0.5779] < [提案モデルの正解率の平均 : 0.6395]

16 検証パターンのうち 8 検証パターンで提案モデルが上回る

回帰予測の場合

$[F_1, T_1$ の誤差率の平均 : 14.95%] < [提案モデルの誤差率の平均 : 11.73%]

16 検証パターンのうち 14 検証パターンで F_1, T_1 双方を提案モデルが上回る

ことから、

[検証 4] 「アンサンブルモデルによって複数のアプローチを融合させたより汎化性能が高くかつ拡張性のあるモデルが実現できること」が検証された。

また、表 5.22 及び表 5.23 から提案モデルの実用性を検証すると、

提案モデルの真の実用性

検証範囲において、

分類予測の場合

[真のベースライン : 0.6520] > [提案モデルの正解率の平均 : 0.6395]

16 検証パターンのうち 7 検証パターンで提案モデルが上回る

回帰予測の場合

[真のベースライン : 14.47%] < [提案モデルの誤差率の平均 : 11.73%]

16 検証パターンのうち 13 検証パターンで提案モデルが上回る

ことから、

回帰予測において提案モデルが真のベースラインを上回っており、回帰予測においては提案モデルが実用的であることが示された。一方で、分類予測では真のベースラインを上回ることができず、モデルが真に実用的であるとは言えない。

以上、検証実験の結果について述べた。次章では、考察を述べる。

第6章 考察

6.1 本研究の株式分析に対する貢献

本研究の目的は、証券アナリストの予測が当たらなくなってしまった「証券アナリスト不在」という社会的問題の解決のために、「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」の提案によって既存の企業価値推定モデルの潜在的問題を解決し、より優れた予測を行うことであった。

5章では、「提案モデルのファンダメンタルアプローチ」のモデルと、既存の機械学習のアプローチで行われていなかった企業間の時系列の相関を反映することのできる「提案モデルのテクニカルアプローチ」のモデルによって、経済学的ファンダメンタルアプローチ及び既存の機械学習的テクニカルアプローチの双方よりも高い精度を実現できることを示した。

また、提案モデルの広義のアンサンブルモデルにおいて、機械学習の手法においてもファンダメンタル分析とテクニカル分析の優位性が予測期間及び予測問題によって異なることを示し、異なるアプローチを融合させるモデルが必要であることを示した。

そうして、異なるアプローチを融合させた提案モデルが、より汎化性能が高いモデルとなることを示した。

さらに、特に回帰予測において、提案モデルの精度が「真のベースライン」を上回り、モデルの予測精度が実用的な水準であることを示した。

本研究は、証券アナリストたちの株価予測が当たらなくなってしまった「アナリスト不在」という社会的問題に対して、機械学習の手法を取り入れたより高精度な予測を行えるモデルを提案した。さらに、提案モデルによって今まで独立に提案されていた複数の既存手法を予測問題に応じて組み合わせることが可能であり、独立していた企業価値推定に関する既存研究・手法の価値が高まった。

留意する点として、本研究の意図はあくまで既存の企業価値推定モデルより精度が高く、

複数のアプローチを融合させることのできるモデルを提案することであって、証券アナリストの存在及びファイナンス理論を否定するものではない。今後も証券アナリストによるインタビューなどを通じた「深い」分析は有用であるし、提案モデルが複数のアプローチを融合させることのできるモデルであり、証券アナリストによる「深い」分析による入力をもモデルの素性とすることが期待されるため、むしろ証券アナリストによる分析の価値は高まったと言える。

6.2 今後の展望

本研究の今後の展望として、検証実験の課題と提案モデルの拡張性と実用性について述べる。

6.2.1 検証実験の課題

本研究では、検証実験において以下のような課題を残している。

1. データの質と量の限界
2. 計算コストの限界
3. ハイパーパラメタ、検証範囲の恣意性の排除の限界
4. ベースラインの設定

1つ目のデータの質と量の限界に関しては、ファンダメンタル指標の欠損値の存在や、株式分割などによるデータの「歪み」の存在によるデータの不完全性を排除しきれていないこと、また特にファンダメンタルアプローチにおいて、四半期ごとのデータであるため、データの量を増やすにも限界があるといった課題がある。データの不完全性を解消し、データ量をさらに増やすことができれば、より高い精度を出すことができる可能性がある。

2つ目の計算コストの限界に関しては、特に深層学習の学習において計算コストが高く、今回検証実験のすべての場合に関して理想的な検証ができていないという課題がある。具体的には、提案モデルの「テクニカルアプローチのモデル」の作成において、本来ならばすべての企業に固有のモデルを作成することが理想であるが、4.4節で述べた通り、すべての企業の株価が同様のモデルによって表現されるという仮定をし、検証実験においては

「テクニカルアプローチのモデル」の代替モデルを使用している。

3つ目のハイパーパラメタ、検証範囲の恣意性の排除の限界に関しては、計算コストの限界と関係する部分でもあるが、深層学習のハイパーパラメタを恣意的に選択していること、ハイパーパラメタサーチをしていてもその探索範囲が限定的に選択されたものであるといった課題がある。また、検証したモデルが特定期間において過適合したモデルである可能性や、特定予測対象にのみ適合したモデルである可能性がある。

こうした可能性をできるだけ排除するために、本稿の検証実験では検証期間を2013年と2014年の計8四半期とし、また予測対象期間を営業60日間平均と営業240日間平均とすることで複数の検証範囲をもうけたが、十分な検証範囲である確証はない。

4つ目のベースラインの設定に関しては、今回の検証実験において経済的ファンダメンタルアプローチを評価し提案モデルのベースラインの一つとして設定したが、経済的ファンダメンタルアプローチは1.1.1項でも述べた通り、本来インタビューなどを通して対象企業や業界を「深く」分析し、解像度の高い情報を元に行われるものであり、今回の検証実験はそうした「深い」分析を行っていない。インカムアプローチなどでは将来FCFを既知とすることでそうした点を補っているものの、本来ベースラインが今回の検証実験よりも高い精度である可能性は否定できない。

6.2.2 提案モデルの拡張性

3.4節で述べた通り、今回提案する「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」は、広義のアンサンブルモデルを用いることで複数のアプローチを融合したモデルである。5.5節で示した通り、広義のアンサンブルモデルにより汎化性能が高いモデルを実現することができることを示した。

提案モデルは、異なるアプローチを追加できる拡張性を持っており、さらに汎化性能が高いモデルを実現できる可能性を持っている。例えば今回、ファンダメンタルアプローチとして主にファンダメンタル指標の数値情報を特徴量としているが、実際の株式分析においては、決算短信の文字情報などを参考にすることが普通である。提案モデルは、そうした文字情報から予測するアプローチを加えることが可能であり、より汎化性能を上げられる可能性を持っている。

以上、考察について述べた。次章では、結論を述べる。

第7章 結論

1章で証券アナリストの予測が当たらなくなってしまった現状と機械学習の研究背景について整理し、本研究の目的を明確にした。2章で株式評価、予測の関連研究を俯瞰し、機械学習の手法を含めた周辺概念、知識を整理することで本研究の学術的見地を整理した。3章で提案モデルである「深層学習を用いたアンサンブルモデルによる企業価値推定モデル」について説明し、4章で述べた方法で検証実験を行った。5章で検証実験の結果を述べ、6章で検証結果に基づいて提案モデルの有用性を示し、最後に今後の展望として検証実験の課題と提案モデルの拡張性について述べた。

特に、

- 機械学習でファンダメンタルアプローチを試みること
- LSTMを用いることで、市場との時系列相関を学習させること

によって、データサンプル数を増やした帰納的推論による予測を実現し、またその過程で重要な市場の価格決定要因を抽出することでより高い精度を出すことができることを示した。

また、アンサンブルモデルによって異なるアプローチを融合させた提案モデルが、より汎化性能が高いモデルとなることを示し、特に回帰予測において実用的な精度であることを示した。そして、提案モデルによって今まで独立で研究されていた複数の既存手法を予測期間・対象に応じて組み合わせることが可能となり、さらに優れた予測を行えるようになる可能性について述べた。

本研究は、株式市場のデータ化、機械学習の発展など、多分野に渡る様々な成果によって初めて可能になったものである。本研究が、日本の金融の発展に貢献することを願っている。

参考文献

- [1] 川崎健. アナリスト不在の不幸 強まる規制、荒れる株価. 日本経済新聞 電子版, 11 2016. <http://www.nikkei.com/article/DGXLZ010041570Y6A121C1EN1000/>.
- [2] インターナレッジ・パートナーズ IKP 税理士法人. 株式のバリュエーションシリーズ | 株式評価の基礎 | ナレッジ情報 | インターナレッジ・パートナーズ (公認会計士・税理士. http://www.ikpi.co.jp/knowledge/valuation/valuation_file030.html.
- [3] Jeffrey A Frankel and Kenneth A Froot. Using survey data to test some standard propositions regarding exchange rate expectations, 1985.
- [4] Jeffrey A Frankel and Kenneth Froot. Chartists, fundamentalists, and trading in the foreign exchange market. 1990.
- [5] William Brock, Josef Lakonishok, and Blake LeBaron. Simple technical trading rules and the stochastic properties of stock returns. *The Journal of finance*, Vol. 47, No. 5, pp. 1731–1764, 1992.
- [6] W Kreesuradej, Donald C Wunsch, and M Lane. Time delay neural network for small time series data sets. 1994.
- [7] Emad W Saad, Danil V Prokhorov, and Donald C Wunsch. Advanced neural network training methods for low false alarm stock trend prediction. 1996.
- [8] Hyun-jung Kim and Kyung-shik Shin. A hybrid approach based on neural networks and genetic algorithms for detecting temporal patterns in stock markets. *Applied Soft Computing*, Vol. 7, No. 2, pp. 569–576, 2007.
- [9] Lijuan Cao and Francis EH Tay. Financial forecasting using support vector machines. *Neural Computing & Applications*, Vol. 10, No. 2, pp. 184–192, 2001.
- [10] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, Vol. 9, No. 8, pp. 1735–1780, 1997.

- [11] Kai Chen, Yi Zhou, and Fangyan Dai. A lstm-based method for stock returns prediction: A case study of china stock market. In *Big Data (Big Data), 2015 IEEE International Conference on*, pp. 2823–2824. IEEE, 2015.
- [12] Ryo Akita, Akira Yoshihara, Takashi Matsubara, and Kuniaki Uehara. Deep learning for stock prediction using numerical and textual information. In *Computer and Information Science (ICIS), 2016 IEEE/ACIS 15th International Conference on*, pp. 1–6. IEEE, 2016.
- [13] Rohit Choudhry and Kumkum Garg. A hybrid machine learning system for stock market forecasting. *World Academy of Science, Engineering and Technology*, Vol. 39, No. 3, pp. 315–318, 2008.
- [14] Thomas G Dietterich. Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pp. 1–15. Springer, 2000.
- [15] Baruch Lev and S Ramu Thiagarajan. Fundamental information analysis. *Journal of Accounting research*, pp. 190–215, 1993.
- [16] Rudiger Dornbusch. Expectations and exchange rate dynamics. *Journal of political Economy*, Vol. 84, No. 6, pp. 1161–1176, 1976.
- [17] ジョン J. マーフィー. 先物市場のテクニカル分析, p. 5. 一般財団法人 金融財政事情研究会, 1990.
- [18] 貝増眞北川哲雄. 証券アナリストのための企業分析, 第 4 巻, pp. 220,213. 東洋経済新報社, 2013.
- [19] 貝増眞北川哲雄. 証券アナリストのための企業分析, 第 4 巻, pp. 219,220. 東洋経済新報社, 2013.
- [20] 貝増眞北川哲雄. 証券アナリストのための企業分析, 第 4 巻, pp. 215,216,217. 東洋経済新報社, 2013.
- [21] William F Sharpe. Capital asset prices: A theory of market equilibrium under conditions of risk. *The journal of finance*, Vol. 19, No. 3, pp. 425–442, 1964.
- [22] Eugene F Fama and Kenneth R French. Common risk factors in the returns on stocks and bonds. *Journal of financial economics*, Vol. 33, No. 1, pp. 3–56, 1993.

- [23] Yu-Hon Lui and David Mole. The use of fundamental and technical analyses by foreign exchange dealers: Hong kong evidence. *Journal of International Money and Finance*, Vol. 17, No. 3, pp. 535–545, 1998.
- [24] Frank Rosenblatt. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological review*, Vol. 65, No. 6, p. 386, 1958.
- [25] Geoffrey E Hinton and Ruslan R Salakhutdinov. Reducing the dimensionality of data with neural networks. *Science*, Vol. 313, No. 5786, pp. 504–507, 2006.
- [26] Geoffrey E Hinton, Simon Osindero, and Yee-Whye Teh. A fast learning algorithm for deep belief nets. *Neural computation*, Vol. 18, No. 7, pp. 1527–1554, 2006.
- [27] Florian Schroff, Dmitry Kalenichenko, and James Philbin. Facenet: A unified embedding for face recognition and clustering. *arXiv preprint arXiv:1503.03832*, 2015.
- [28] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. *arXiv preprint arXiv:1409.4842*, 2014.
- [29] Ilya Sutskever, Oriol Vinyals, and Quoc VV Le. Sequence to sequence learning with neural networks. In *Advances in neural information processing systems*, pp. 3104–3112, 2014.
- [30] Daxiang Dong, Hua Wu, Wei He, Dianhai Yu, and Haifeng Wang. Multi-task learning for multiple language translation. In *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing*. ACL, 2015.
- [31] Geoffrey Hinton, Li Deng, Dong Yu, George E Dahl, Abdel-rahman Mohamed, Navdeep Jaitly, Andrew Senior, Vincent Vanhoucke, Patrick Nguyen, Tara N Sainath, et al. Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups. *Signal Processing Magazine, IEEE*, Vol. 29, No. 6, pp. 82–97, 2012.
- [32] Dzmitry Bahdanau, Jan Chorowski, Dmitriy Serdyuk, Philemon Brakel, and Yoshua Bengio. End-to-end attention-based large vocabulary speech recognition. *arXiv preprint arXiv:1508.04395*, 2015.

- [33] Thomas F Dapp, Lars Slomka, Deutsche Bank AG, and Ralf Hoffmann. Fintech—the digital (r) evolution in the financial sector. Deutsche Bank Research ”, Frankfurt am Main, 2014.
- [34] Burton G Malkiel and Eugene F Fama. Efficient capital markets: A review of theory and empirical work. *The journal of Finance*, Vol. 25, No. 2, pp. 383–417, 1970.
- [35] Robert J Shiller. Do stock prices move too much to be justified by subsequent changes in dividends?, 1980.
- [36] Hyun-Joo Kim, Youngki Lee, Byungnam Kahng, and In-mook Kim. Weighted scale-free network in financial correlations. *Journal of the Physical Society of Japan*, Vol. 71, No. 9, pp. 2133–2136, 2002.
- [37] David R Cox. The regression analysis of binary sequences. *Journal of the Royal Statistical Society. Series B (Methodological)*, pp. 215–242, 1958.
- [38] J. Ross Quinlan. Induction of decision trees. *Machine learning*, Vol. 1, No. 1, pp. 81–106, 1986.
- [39] Vladimir Vapnik. Pattern recognition using generalized portrait method. *Automation and remote control*, Vol. 24, pp. 774–780, 1963.
- [40] Bernhard E Boser, Isabelle M Guyon, and Vladimir N Vapnik. A training algorithm for optimal margin classifiers. In *Proceedings of the fifth annual workshop on Computational learning theory*, pp. 144–152. ACM, 1992.
- [41] Leo Breiman. Bagging predictors. *Machine learning*, Vol. 24, No. 2, pp. 123–140, 1996.
- [42] Bradley Efron. Bootstrap methods: another look at the jackknife. In *Breakthroughs in Statistics*, pp. 569–593. Springer, 1992.
- [43] Andy Liaw and Matthew Wiener. Classification and regression by randomforest. *R news*, Vol. 2, No. 3, pp. 18–22, 2002.
- [44] Yoav Freund and Robert E Schapire. A decision-theoretic generalization of on-line learning and an application to boosting. In *European conference on computational learning theory*, pp. 23–37. Springer, 1995.

- [45] Jerome H Friedman. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, pp. 1189–1232, 2001.
- [46] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. *arXiv preprint arXiv:1603.02754*, 2016.
- [47] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, Vol. 86, No. 11, pp. 2278–2324, 1998.
- [48] Ronald J Williams and David Zipser. A learning algorithm for continually running fully recurrent neural networks. *Neural computation*, Vol. 1, No. 2, pp. 270–280, 1989.
- [49] John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, Vol. 12, No. Jul, pp. 2121–2159, 2011.
- [50] Matthew D Zeiler. Adadelta: an adaptive learning rate method. *arXiv preprint arXiv:1212.5701*, 2012.
- [51] Tijmen Tieleman and Geoffrey Hinton. Lecture 6.5-rmsprop: Divide the gradient by a running average of its recent magnitude. *COURSERA: Neural Networks for Machine Learning*, Vol. 4, No. 2, 2012.
- [52] Diederik Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [53] Timothy Dozat. Incorporating nesterov momentum into adam.
- [54] Alex Graves and Jürgen Schmidhuber. Offline handwriting recognition with multidimensional recurrent neural networks. In *Advances in Neural Information Processing Systems*, pp. 545–552, 2009.
- [55] Jérôme Louradour and Christopher Kermorvant. Curriculum learning for handwritten text line recognition. In *Document Analysis Systems (DAS), 2014 11th IAPR International Workshop on*, pp. 56–60. IEEE, 2014.

- [56] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk. Session-based recommendations with recurrent neural networks. *arXiv preprint arXiv:1511.06939*, 2015.
- [57] Kelvin Xu, Jimmy Ba, Ryan Kiros, Aaron Courville, Ruslan Salakhutdinov, Richard Zemel, and Yoshua Bengio. Show, attend and tell: Neural image caption generation with visual attention. *arXiv preprint arXiv:1502.03044*, 2015.
- [58] Oriol Vinyals, Alexander Toshev, Samy Bengio, and Dumitru Erhan. Show and tell: A neural image caption generator. *arXiv preprint arXiv:1411.4555*, 2014.
- [59] Edward Choi, Mohammad Taha Bahadori, and Jimeng Sun. Doctor ai: Predicting clinical events via recurrent neural networks. *arXiv preprint arXiv:1511.05942*, 2015.
- [60] Zachary C Lipton, David C Kale, Charles Elkan, and Randall Wetzell. Learning to diagnose with lstm recurrent neural networks. *arXiv preprint arXiv:1511.03677*, 2015.
- [61] Vinod Nair and Geoffrey E Hinton. Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th International Conference on Machine Learning (ICML-10)*, pp. 807–814, 2010.
- [62] Djork-Arné Clevert, Thomas Unterthiner, and Sepp Hochreiter. Fast and accurate deep network learning by exponential linear units (elus). *arXiv preprint arXiv:1511.07289*, 2015.
- [63] Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. *Neural Networks, IEEE Transactions on*, Vol. 5, No. 2, pp. 157–166, 1994.
- [64] Razvan Pascanu, Tomas Mikolov, and Yoshua Bengio. On the difficulty of training recurrent neural networks. *arXiv preprint arXiv:1211.5063*, 2013.
- [65] Sepp Hochreiter. The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, Vol. 6, No. 02, pp. 107–116, 1998.

-
- [66] Tomáš Mikolov. Statistical language models based on neural networks. *Presentation at Google, Mountain View, 2nd April, 2012.*

謝辞

本研究の遂行や本論文の執筆にあたり、非常に多くの方からご指導、ご支援をいただきました。心より御礼申し上げます。

指導教官である松尾 豊特任准教授 には、研究構想や本論文の論理構成について、貴重なご指導をいただきました。ここに、深く謝意を表します。

本研究に必要不可欠であった分析サーバや GPU 解析環境の用意等、物理的な研究環境の構築に多大なご協力を下さった研究室の教官である中山 浩太郎先生 に、深く感謝致します。

上野山 勝也助教授には、研究の方向性や論文の構成、さらには適語表現など細部に渡り、多大なご指導をいただきました。深く感謝致します。

田中 謙司特任准教授には、指導教員でないにもかかわらず、企業価値推定手法などについて多大なご助力をいただきました。深く感謝いたします。

松尾研究室の皆様には、多大なご協力、ご支援いただきました。学術支援職員であるグスタボ・ベゼーラさん、椎橋 徹さん、Alfredo Solano Martinez さん、Emilio Castillo さん、Emilio Castillo さん、Michael Bawiec さん、中野 佐恵子さん、永本 登代子さん、浪岡 亮子さん、木全 やえさんは、分析サーバや GPU 解析環境の構築、秘書業務など、日頃から研究室の環境を整えて下さり、研究生活を支えてくださいました。特にグスタボ・ベゼーラさんには、金融分野に関する相談に乗っていただいただけでなく、株価情報を高速並列処理するシステムを構築していただき、使用させていただきました。深く感謝致します。松尾研究室の博士・修士課程の先輩である岩澤 有祐さん、関 喜史さん、落合 桂一さん、山本裕樹さん、飯塚 修平さん、野中 尚輝さん、鈴木 雅大さん、金子 貴輝さん、那須野 薫さん、黒滝 紘生さん、保住 純さん、塩谷 碩彬さん、富山 翔司さんには、未熟な自分の研究の相談に幾度も乗っていただき、多大なご助力をいただきました。研究室同期である大野 峻典氏、中川 大海氏は、卒業論文の構想や執筆に関して率直に意見を交わし、互いに切磋琢磨し合いながら研究を進めさせていただきました。ここに、松尾研究室の皆様

様へ謝意を表します。

東京大学工学部システム創成学科

C コース

松尾研究室 学部4年

田村浩一郎

平成29年3月